

文章编号:0253-9993(2012)12-1999-07

基于 GA-SVM 的露天矿抛掷爆破抛掷率预测

刘希亮¹,赵学胜²,陆 锋¹,孙文彬²

(1. 中国科学院 地理科学与资源研究所 资源与环境信息系统国家重点实验室,北京 100101;2. 中国矿业大学(北京) 地球科学与测绘工程学院,北京 100083)

摘 要:分析了高台阶抛掷爆破的机理过程,并从自然地质、爆破设计和人为操作3个角度出发,结合某矿区的实际开采情况,提取其中10个参数作为影响该矿区抛掷爆破效果的主要因素,以爆破领域中广泛接受的抛掷率作为抛掷爆破效果的评价因子,采用此矿区爆破生产中的实际数据建立了基于遗传算法优化的支持向量机模型 GA-SVM。基于建立的 GA-SVM 模型,采用平均影响值(Mean Impact Value, MIV)作为评价标准,对各因素的影响程度进行了评定。结果表明:① GA-SVM 模型能够比较快速、准确地根据此矿区的爆破设计参数预测出抛掷爆破的抛掷率,平均预测精度稳定在83.75%,与其他智能算法如BP,RBF,GRNN相比,GA-SVM具有更好的鲁棒性和更佳的预测精度。由于计算流程的统一性和预测方法的普适性,GA-SVM模型对于其他抛掷爆破参数(如最远抛距、松散系数等)也具有良好的外推性;②对于此露天矿区而言,在其自然因素(如岩性等)和爆破设计因素(如炸药类型、起爆顺序、装药结构等)已确定的情况下,台阶高度、炸药单耗与抛掷率正相关,且台阶高度比炸药单耗对抛掷率的影响更大;而最小抵抗线、坡面角和剖面宽对于抛掷率呈现负相关,其他影响因素对于此露天矿抛掷率的影响较弱。

关键词:高台阶抛掷爆破;抛掷率;GA-SVM模型;平均影响值;遗传算法;支持向量机

中图分类号:TD824

文献标志码:A

A GA-SVM based model for throwing rate prediction in the open-pit cast blasting

LIU Xi-liang¹, ZHAO Xue-sheng², LU Feng¹, SUN Wen-bin²

(1. State Key Laboratory of Resources and Environmental Information System, Institute of Geographic Sciences and Natural Resources Research, Chinese Academy of Sciences, Beijing 100101, China; 2. College of Geoscience and Surveying Engineering, China University of Mining and Technology (Beijing), Beijing 100083, China)

Abstract: This paper probed into the whole height bench cast blasting process and described the influence factors from 3 major perspectives: natural geological, blasting scheming and factitious ones, and selected the throwing rate which was generally accepted in the cast blasting field to assess the blasting performance. Then a novel GA-SVM model was constructed to analyze the real collected explosion data from open pit mining, and verified in a certain open-pit. Also the MIV method was employed to analyze the influence factor at each input factor. The study indicate that: ① the presented GA-SVM model performs more robust and accurate than other artificial intelligence models such as BP, RBF, GRNN and GA-BP, which has a more stable prediction accuracy of 83.75%. Moreover, due to the ubiquitous paradigm of the presented approach, it provides a single, unified approach to evaluating other blasting performance factors such as the longest thrown distance and loose coefficient etc; ② for this certain open pit which maintains a steady lithological character and design parameters, the bench height, explosive specific charge possess a positive correlation coefficient with the throwing rate, while line of least resistance, the slope angle and the profile width perform

收稿日期:2011-12-06 责任编辑:韩晋平

基金项目:国家自然科学基金资助项目(41171306)

作者简介:刘希亮(1983—),男,河北衡水人,博士研究生。Tel:010-64889015, E-mail:liuxl@lreis.ac.cn

the opposite.

Key words: height bench cast blasting; throwing rate; GA-SVM model; MIV; GA; SVM

高台阶露天抛掷爆破^[1]是目前露天矿开采中比较流行的技术方法。由于爆破过程的复杂性和现场试验条件的有限性,在实际的露天矿抛掷爆破过程中主要存在以下两个问题:

(1) 高台阶抛掷爆破的影响参数众多,涉及自然地质、爆破设计以及人为操作施工等诸多因素,很难利用传统的数学建模方式将爆破过程归结为一个统一的数学方程;

(2) 高台阶抛掷爆破效果的评价体系不惟一。如何结合工矿企业的实际情况,选择一个合适的抛掷爆破效果评价因子成为目前露天矿业开采的当务之急。

本文从露天矿开采的实际需求出发,选取抛掷率作为露天矿抛掷爆破设计的评价因子。抛掷率是反映露天矿抛掷爆破效果的重要因子,直接影响露天矿一次抛掷爆破作业之后采掘工作的展开。抛掷率的计算如图 1 所示。




图 1 抛掷率计算示意

Fig. 1 Throwing rate calculation schemes

图 1 为一次抛掷爆破前后地形的侧剖面叠加,实线表示爆前地形面,点划线表示爆后地形面,右侧为岩石的 38° 自然安息角面。抛掷率即为 A 部分岩石所占抛掷爆破破碎岩石总体积的百分比,表示如下:

$$E_a = \frac{V_A}{V_A + V_B + V_C} \times 100\% \quad (1)$$

目前,有关论述露天矿抛掷爆破抛掷率预测的文献仍然十分稀少,李祥龙验证了 BP 神经网络用于露天矿抛掷爆破中抛掷率预测的可行性,但建模过程复杂,不利于实际操作^[2]。刘希亮进一步完善了露天矿抛掷爆破 BP 神经网络的建模流程,并采用遗传算法对 BP 神经网络的初始权值进行了进一步的优化,大大提高了 BP 神经网络在露天矿抛掷爆破抛掷率预测方面的精度^[3]。但由于 BP 神经网络初始权值赋值的随机性,GA-BP 神经网络模型并不能保证最终预测结果的惟一性。同时由于露天矿抛掷爆破数据的稀缺性,对于需要大量训练数据才能得到比较好

的预测效果的 BP 神经网络模型,在露天矿抛掷爆破方面的应用亦受到一定限制。

本文采用专门研究小样本事件的支持向量机 (Support Vector Machine, SVM) 作为建模的理论基础^[4]。SVM 是近年来比较流行的一种从统计学习理论中发展出来的机器学习算法,将低维空间下不能线性分割的学习样本通过不同的核函数映射到一个高维空间,得到一个高维空间下惟一的最优超平面,从而使得原始分类问题得到解决。值得注意的是,在由低维空间向高维空间映射的过程中,不同类型核函数以及核函数参数的选择将对最后的结果产生较大的影响,同时惩罚项的大小直接决定了 SVM 用于回归预测效果的优劣,因此在将 SVM 用于回归预测就必须考虑其参数惩罚项与核函数参数的选择与优化^[5]。在参数寻优策略上,直接采用试凑法调节 SVM 参数进行预测的效果并不理想,目前研究的重点集中在启发式算法与 SVM 参数优化的结合^[6-8]。

本文首先对 SVM 和 GA 进行简单的回顾,提出 GA-SVM 模型的优化原理和流程;在分析露天矿抛掷爆破过程机理基础上,从自然地质因素、爆破设计因素以及人为施工因素 3 个方面出发,结合某矿区爆破设计与实际开采的操作流程,提炼出适用于此矿区实际抛掷爆破作业的 10 个参数作为影响因子,利用其 2009—2010 年实际爆破数据,采用 GA-SVM 模型对抛掷率进行预测。一方面论证了 GA-SVM 模型在此矿区露天矿抛掷率预测中的可行性与优越性,同时,由于计算流程的统一性,GA-SVM 模型对于露天矿区其他抛掷爆破参数(如最远抛距、松散系数等)也具有较好的适用性;另一方面,以神经网络领域普遍采用的平均影响值 (Mean Impact Value, MIV) 作为评价标准,分析了各个影响因素对抛掷率的敏感度和作用大小,以便指导进一步的实际生产。最后,给出研究结论及进一步的工作方向。

1 GA-SVM 算法

1.1 SVM 用于回归预测的理论基础

支持向量机是 20 世纪 90 年代由 Vapnik 等提出的一种研究小样本、小概率事件的神经网络模型,能够根据有限的样本信息在模型的复杂性和学习能力之间寻求最优解。设样本训练集包含 d -维特征空间的 N 个向量, $x_i \in R^d (i = 1, 2, \dots, N)$, 目标 $y_i \in \{-1, 1\}$,

1} 与每个向量 x_i 相关联。寻找最优超平面的问题转化为解决凸二次方程的问题,即

$$\begin{cases} \text{Minimize: } \frac{1}{2} \|w\|^2 \\ \text{Subject to: } y_i(w \cdot x_i + b) \geq 1, i = 1, 2, \dots, N \end{cases} \quad (2)$$

其中, w, b 代表超平面方程 $f(x) = w \cdot x + b$ 的系数。按照最优化理论中凸二次规划的解法,构造 Lagrange 函数,即

$$L(w, \alpha, b) = \frac{1}{2} \|w\|^2 - \sum_{i=1}^N \alpha_i y_i \times (w \cdot x_i + b) + \sum_{i=1}^N \alpha_i \quad (3)$$

式中, $\alpha_i (i = 1, 2, \dots, N)$ 为引入的拉格朗日乘子。

为了将支持向量机用于回归分析, Cortes 等通过向目标函数中加入惩罚项 C , 并设定阈值控制一定的错分比例将上述方程转化^[4]为

$$\begin{cases} \text{Maximize: } \sum_{i=1}^N \alpha_i - \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j (x_i \cdot x_j) K(x_i, x_j) \\ \text{Subject to: } \sum_{i=1}^N \alpha_i y_i = 0 \text{ and} \\ 0 \leq \alpha_i \leq C, i = 1, 2, \dots, N \end{cases} \quad (4)$$

其中, $K(x_i, x_j)$ 代表支持向量机由低维空间向高维空间转换所采用的核函数类型,这就得到了 SVM 用于回归预测最一般的表述。

1.2 GA 原理

遗传算法^[9]是 Holland 等 1975 年提出的一种基于生物遗传和进化机制的适用于复杂系统优化自适应概率优化技术。与传统的搜索算法不同,遗传算法并不是基于单一的评估函数的梯度或者较高次统计,以产生一个确定性的试验解序列,而是通过模拟自然界的进化过程来搜索全局最优解。遗传算法是一种普遍适用的优化技术,发展极为迅速,影响范围也越来越大。

本文采用标准遗传算法 (Simple Generic Algorithm, SGA) 对 SVM 回归预测模型的参数进行寻优。SGA 给出了所有适用于遗传算法求解的基本框架,是其他遗传算法的基础。SGA 可以表示为

$$SGA = (C, E, P_0, M, \varphi, F, \psi, T) \quad (5)$$

式中, C 为遗传算法中染色体的编码方法; E 为遗传算法中的个体适应度函数; P_0 为生成的初始种群; M 为初始种群的规模; φ 为遗传算法选择算子; F 为遗传算法交叉算子; ψ 为遗传算法变异算子; T 为给定的遗传算法终止条件。

1.3 GA-SVM 原理

Fernandez 等归纳了 GA 用于 SVM 参数寻优的一般策略^[10]。本文结合露天矿区的具体特点,提出基于 SGA 优化 SVM 回归预测模型参数的流程。

(1) 染色体编码、解码与种群的初始化。

采用基于实数的编码方式,首先对原始 SVM 的惩罚项 C 与 SVM 所采用的核函数参数 r 给定一个较宽的搜索范围,其次在此预设范围之内将各个具有可行性的惩罚项 C 与核函数参数 r 的值转换为能够被遗传算法所接受的具体的染色体,完成了从可行性解空间到染色体搜索处理空间的转化。在原始数据集中随即抽取 p 个个体对完成种群的初始化处理。

(2) 种群个体适应度的确定。

种群个体适应度体现了种群中某个染色体相对于其他染色体在进化过程中的优劣性。结合准格露天矿区的实际需求,以预测模型在训练过程中的标准差作为个体适应度评价标准。某个染色体适应度越高,其参与下一次遗传迭代的几率就越大,从而使得整个种群向最优染色体即全局最优解进化。

(3) 染色体的选择、交叉、变异。

为了消除超级个体的影响,避免 GA 过早收敛,本文按照锦标赛原则来进行个体的选择。当个体的选择概率给定后,产生 $[0, 1]$ 之间的均匀随机数来决定个体的交配几率,使种群中生命力强、适应度高的个体参与新群体生成的过程,同时对原有群体中的个体进行优胜劣汰,使群体中每个个体的适应度值均迭代接近全局最优解。

交叉算子决定了遗传算法的全局搜索能力,交叉算子按照个体适应度值的大小以较大的概率从原始群体中选出适应度较大的两个个体,并对这两个个体的某些基因位进行随机交换,从而产生出具有父代的基本数据特征的新生子代。变异算子模拟自然进化过程中的小概率基因位的突变,通过 GA-SVM 模型中设定的较小的概率改变个体染色体编码串上的基因位,从而产生一个新的个体,决定了遗传算法的局部搜索能力。

综合以上论述,给出 GA-SVM 回归预测模型的具体流程,如图 2 所示。

2 实 验

2.1 研究区域及爆破效果影响因素分析

实验对象选择为内蒙古自治区某露天矿。该矿采用 MDL 三维激光仪进行爆前爆后的地形扫描,同时根据以往地质勘探资料在 AutoCAD 平台下进行爆破设计。结合矿区实际的数据观测方案,从自然地

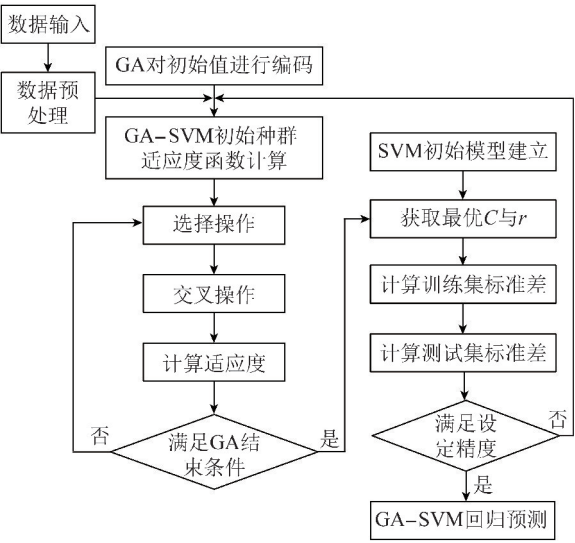


图2 GA 优化 SVM 流程
Fig. 2 Flow chart of optimizing SVM with genetic algorithm

质、爆破设计和人为操作 3 个角度描述露天矿抛掷爆破效果的影响因素。

自然地质条件是露天矿抛掷爆破设计中需要考虑的首要因素,此露天煤矿地层由上至下由第四系(Q)、第三系(N)、二叠系(P)、石炭系(C)地层组成,地质构造及岩石特性较为单一,故在抛掷爆破设计中

将岩性条件视为同质,本文提取台阶高度、煤层厚度、采掘带宽度(可细化为采空区上口宽和采空区下口宽)以及设计区域的剖面宽度和坡面角作为自然地质方面的影响因素,此处剖面宽度是指过前排每个炮孔垂直于设计区域后排预裂孔组成的边界线所做的剖面与设计区域坡顶面的交线长度;在爆破设计方面,结合矿区实际爆破施工流程,每次现场作业中的装药结构、炸药类型、起爆顺序、起爆网路方案、炮孔倾角等爆破设计因素基本不变,而每次抛掷爆破设计方案的不同主要体现在炸药单耗、装药量、孔距、排距、最小抵抗线等爆破参数上,因此主要采取这几个爆破参数作为影响抛掷率的爆破设计参数。人为因素主要是指实际的施工质量,包括钻孔质量、炸药的装载和填塞质量等,作为同质因素处理。

综合以上论述,选定以下 10 个参数作为 GA-SVM 回归预测模型的输入层:① 炸药单耗;② 台阶高度;③ 煤层厚度;④ 采空区上口宽;⑤ 采空区下口宽;⑥ 最小抵抗线;⑦ 坡面角;⑧ 孔距;⑨ 排距;⑩ 剖面宽。

2009—2010 年该矿共进行了 16 次有效爆破,通过对矿区两年来的现场抛掷爆破实验进行数据搜集和处理,获得了 188 组可用数据,见表 1。

表 1 GA-SVM 数据集(部分)
Table 1 GA-SVM data set (part)

剖面	输入层										输出层
	炸药单耗 $q/(\text{kg} \cdot \text{m}^{-3})$	台阶高度 H/m	煤层厚度 H_c/m	采空区上口宽 L_{k1}/m	采空区下口宽 L_{k2}/m	抵抗线 W/m	坡面角 α_1	孔距 a/m	排距 b/m	剖面宽 c/m	抛掷率 ζ
09e1-2	0.72	34.61	28.50	131.38	95.91	8	56	11.20	7.11	66.50	0.28
09e1-3	0.72	31.40	30.35	128.37	92.96	7	59	11.00	8.18	75.11	0.35
09e1-4	0.72	30.60	35.11	132.99	99.50	7	63	11.00	8.25	74.56	0.37
09e1-5	0.72	30.36	30.88	133.50	98.70	7	66	11.01	8.01	74.19	0.33
...

2.2 GA-SVM 回归预测模型

采用 LIBSVM 工具箱^[11]作为 SVM 计算基础,首先将式(4)中核函数 K 设置为 RBF 类型,采用此核函数将 10 个输入向量投影到一个高维的 Hilbert 空间进行分析,以降低整个模型的分析复杂度。为了使模型达到较高的预测精度,需要对 RBF 核函数的参数 g 和式(4)中惩罚项 C 进行智能优化选取。将两者代入式(5)中的标准遗传算法 SGA,此时,以 10 个影响因素“炸药单耗 q 、台阶高度 H 、煤层厚度 H_c 、采空区上口宽 L_{k1} 、采空区下口宽 L_{k2} 、最小抵抗线 W 、坡面角 α_1 、孔距 a 、排距 b 、剖面宽 c ”作为原数据集输入层的每条记录(行向量)对应于 SGA 算法中一个染色

体,采用实数编码的方式将所有的染色体整体归一化到 $[-3,3]$ 范围,同时,设置 SGA 初始化种群规模 M 为 30,即随机将所有输入数据按照初始化种群规模 M 分成多组作为初始的分析组群,采用锦标赛选择方法,锦标赛规模为 10,即每个种群中染色体的抽选概率 φ 为 0.33 (10/30);种群中个体的交叉概率 T 为 0.4,变异概率 ψ 设定为 0.1,将 GA 模型优化后的参数 γ 和惩罚项 C 代入原 SVM 模型,选择其预测精度作为 GA 模型的适应度函数 E 。为了保证 GA 算法的收敛性,设定最大迭代次数作为遗传算法的终止条件 T ,本文最大迭代次数设置为 $T=150$,这样,通过不同组群之间的选择交叉和种群内个体之间的交叉变

异,所有数据向全局最优解迭代进化,最终得到全局最优解。

在数据预处理方面,为了消除原始样本数量级之间较大的差异,对原始数据集进行 $[-1,1]$ 区间归一化处理。由于智能算法的观测样本来源于 16 次爆破试验的 188 组数据,而每次爆破试验所面对的实际地形、地质条件、人员操作、施工质量等方面均略有不同,因此,为了消除样本集差异对结果的影响,随机选取 172 组观测数据作为 GA-SVM 网络的训练集数据,剩下的 16 组观测数据作为最后的测试数据,并对训练数据集进行随机排序,然后代入 GA-SVM 模型进行计算。

GA-SVM 回归预测模型经过 150 次进化计算得到一个最佳适应度的稳定迭代值,如图 3 所示。




图 3 GA-SVM 进化代数曲线

Fig. 3 GA-SVM evolution graph

通过图 3 可知,适用于 GA-SVM 模型的最佳惩罚项 C 与核函数参数 r 的值各为 8.248 7 和 2.216 1,此时训练集的最小均方差为 0.097 3。将这两个参数代入 SVM 模型进行计算,得到训练数据集的训练结果如图 4(a) 所示。

采用 GA-SVM 回归预测模型对测试集的测试结果如图 4(b) 所示。

由图 4 可以直观地看出,GA-SVM 能够较好地拟合训练数据集,其最小均方差接近于零($9.904\ 56 \times 10^{-5}$)。而 GA-SVM 的对测试样本模拟的最小均方差为 0.034 6,预测结果与真实值比较一致。

2.3 不同模型回归预测效果对比

为了测试 GA-SVM 回归预测模型是否较其他智能算法模型在露天矿抛掷爆破预测方面具有优越性,本文选择常用的 BP 神经网络、RBF 神经网络^[12]、Wavelet 神经网络^[13]和广义回归(General Regression, GR)神经网络^[14]以及 GA-BP 神经网络模型与 GA-SVM 模型进行回归预测精度对比,从训练标准差、预测标准差和预测精度 3 个角度对模型的精度进行描述,结果见表 2。




图 4 GA-SVM 训练结果和测试结果

Fig. 4 GA-SVM training and forecasting results

表 2 不同模型效果对比

Table 2 Comparison of different model effects

算法类型	训练集标准差	测试集标准差	预测精度/%
BP	0.03	0.07	56.25
GA-BP	0.53	0.05	75.00
SVM	0.04	0.04	87.50
GA-SVM	0	0.03	93.75
RBF	0	0.12	31.25
Wavelet	0.05	0.06	81.25
GR	0.05	0.04	81.25

从表 2 可以看出,RBF 与 GA-SVM 对原始训练数据的拟合效果最好。RBF 产生了“过学习”的现象,造成了很大的误差。GR 神经网络、Wavelet 神经网络虽然在训练时间和模拟精度上较一般的神经网络和 GA-BP 神经网络有一定的优势,但劣于原始未经优化的 SVM 与 GA-SVM 回归预测模型。从整体的训练精度和预测精度分析,GA-SVM 回归预测模型的效果为最佳,反映出 GA-SVM 回归预测模型在露天矿抛掷爆破抛掷率预测方面具有很好的适用性。

为了进一步验证 GA-SVM 预测模型的有效性和稳定性,对原始数据集进行了 10 次 10-折交叉验证。在每一次的每一折验证过程中将原始数据集等分为 10 份,选取其中 1 份作为测试样本集,剩余 9 份数据作为训练样本,分别代入 BP 神经网络、RBF 神经网络、Wavelet 神经网络和 GR 神经网络、GA-BP 神经网络与 GA-SVM 模型进行回归预测精度分析,记录

每次试验中训练集标准差、测试集标准差和预测精度,最后以 10 次 10-折交叉验证的均值作为对各个模型有效性和稳定性的描述,结果如图 5 所示。

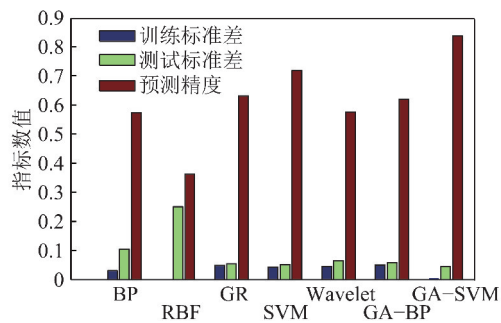


图 5 10 次 10-折交叉验证结果

Fig. 5 Results of 10-time 10-fold cross validations

由图 5 可以直观地看出,RBF 神经网络和小波神经网络在露天矿抛掷爆破效果的预测方面表现不佳。GA-BP 神经网络模型虽然对原始 BP 神经网络的性能有了一定程度的提高,但效果明显劣于 GR 神经网络和 SVM 神经网络。从训练标准差和测试标准差角度分析,虽然 GR 神经网络与 SVM 神经网络效果相当,但是 GR 神经网络的预测精度明显低于 SVM 神经网络。GA-SVM 通过对惩罚项 C 与核函数参数 g 的优化,在对训练样本的拟合和预测精度方面与原始 SVM 模型相比均有了显著的提高,并且预测精度稳定在 83.75%,这有力地证明了 GA-SVM 模型在露天矿抛掷爆破抛掷率预测方面的稳定性。

3 抛掷爆破影响因素权重分析

采用神经网络领域广泛接受的平均影响值 (Mean Impact Value, MIV) 作为评价指标,分析各个影响因素对抛掷率的敏感度和作用效果。MIV 评价方法被认为是神经网络中评价变量相关性最好的指标之一^[15],具体计算过程如下:在 GA-SVM 模型训练成熟后,将训练样本 P 中的每一个自变量特征在其原值的基础上分别加减某个比率,构成两个新的训练样本 P_1 和 P_2 ,将 P_1 和 P_2 分别作为仿真样本,利用已经建成的网络进行仿真,得到两个仿真结果 A_1 和 A_2 ,求 A_1 和 A_2 的差值,即为变动后该自变量对输出产生的影响变化值 (Impact Value, IV),最后将 IV 值按照观测样本数进行平均,得出该自变量对应于应变量的网络输出 MIV。按照上述步骤依次计算各个自变量的 MIV,根据其绝对值的大小进行排序,得到各自变量对于网络输出影响的相对重要性的位次表,从而判断出输入向量对于网络结果的影响程度。

基于 Matlab 平台,利用训练成熟的 GA-SVM 模型,将 MIV 变化率 δ 设置为 10%,对抛掷率进行

了 100 次 MIV 实验,结果如图 6 所示。




图 6 输入向量对抛掷率的权重影响分布

Fig. 6 Weight affect distribution of input vectors to throwing rate

由图 6 可以看出,对于此露天煤矿而言,台阶高度对抛掷率的影响最大,其次是炸药单耗和采空区下口宽,三者与抛掷率正相关;最小抵抗线、坡面角和抛掷爆破设计排距均与抛掷率呈负相关,并且最小抵抗线的负面影响最大;其余变量对于抛掷率的作用不大。台阶高度、炸药单耗以及最小抵抗线权值绝对值的累加值已经超过了 70%,这 3 个元素可以作为影响此矿区抛掷爆破效果的主要因素。因此,对于此矿区而言,为了达到较高的抛掷率,在实际抛掷爆破设计和施工中应该保证台阶高度和炸药单耗,同时在一定范围减小最小抵抗线,这将在一定程度上提高抛掷爆破的有效抛掷率,从而改进爆破效果,这对于实际生产具有一定的指导意义。

4 结论与展望

(1) GA-SVM 回归预测模型对露天矿抛掷爆破抛掷率预测具有很强的适用性,在训练精度和预测精度上优于传统的 BP 神经网络、GA-BP 神经网络、GRNN 广义回归神经网络、RBF 神经网络、小波神经网络以及未优化的原始 SVM 模型,其平均预测精度稳定在 83.75%,具有良好的推广性。

(2) 对于此露天矿区而言,在其自然因素 (如岩性等) 和爆破设计因素 (如炸药类型、起爆顺序、装药结构等) 已确定的情况下,台阶高度、炸药单耗与抛掷率正相关,且台阶高度比炸药单耗对抛掷率的影响更大;而最小抵抗线、坡面角和剖面宽对于抛掷率呈现负相关,其他影响因素对于此露天矿抛掷率的影响较弱。因此在实际抛掷爆破设计和施工中应该保证台阶高度和炸药单耗,同时在一定范围减小最小抵抗线,这将在一定程度上提高抛掷爆破的有效抛掷率,从而改进爆破效果。这对于实际生产具有一定的指导意义。

下一步工作主要研究真三维条件下矿区模型参

数的提取和其他设计参数的加入,使得 GA-SVM 模型能够在三维矿山爆破设计中得到更加广泛的应用。

参考文献:

- [1] 潘井澜. 北美露天煤矿开采中抛掷爆破法的应用[J]. 世界煤炭技术,1993(10):19-22.
Pan Jinglan. Cast blasting used in North America's surface coal mine[J]. World Coal Mine Technology,1993(10):19-22.
- [2] 李祥龙. 高台阶抛掷爆破技术与效果预测模型研究[D]. 北京:中国矿业大学(北京),2010.
- [3] 刘希亮. 基于 GA-BP 神经网络抛掷爆破效果预测与分析[D]. 北京:中国矿业大学(北京),2011.
- [4] Corinna C, Vapnik V. Support-vector networks[J]. Machine Learning,1995,20(3):273-297.
- [5] Fröhlich H, Chapelle O, Schölkopf B. Feature selection for support vector machines by means of genetic algorithms[A]. Proceedings of 15th IEEE International Conference on Tools with Artificial Intelligence[C], Sacramento, California, USA, 2003, 11(3-5):142-148.
- [6] Chen K Y, Wang C H. Support vector regression with genetic algorithms in forecasting tourism demand[J]. Tourism Management, 2007,28:215-226.
- [7] Lin S W, Ying K C, Chen S C, et al. Particle swarm optimization for parameter determination and feature selection of support vector machines[J]. Expert Systems with Applications, 2008, 35:1817-1824.
- [8] Hong W C. Chaotic particle swarm optimization algorithm in a support vector regression electric load forecasting model[J]. Energy Conversion and Management,2009,50:105-117.
- [9] Holland J. Adaptation in natural and artificial systems[M]. Michigan:University of Michigan Press,1975.
- [10] Fernandez M, Caballero J, Fernandez L, et al. Genetic algorithm optimization in drug design QSAR: bayesian-regularized genetic neural networks (BRGNN) and genetic algorithm optimized support vectors machines (GA-SVM)[J]. Mol Divers,2011,15:269-289.
- [11] Chang C C, Lin C J. LIBSVM: a library for support vector machines[R]. Taiwan: National Taiwan University, 2001.
- [12] 张旭隆, 谭国俊, 崩松岩, 等. 基于径向神经网络的无位置传感器开关磁阻电机采煤机牵引系统[J]. 煤炭学报, 2011, 36(9):1570-1574.
Zhang Xulong, Tan Guojun, Kuai Songyan, et al. Position sensorless control of switched reluctance motor for shearer traction system based on RBF neural network[J]. Journal of China Coal Society, 2011, 36(9):1570-1574.
- [13] 谷松, 崔洪庆, 冯文丽. 基于灰色理论的小波神经网络对瓦斯涌出量的预测[J]. 煤炭学报, 2007, 32(9):964-966.
Gu Song, Cui Hongqing, Feng Wenli. Mine gas gushing forecasting based on grey model and wavelet neural network[J]. Journal of China Coal Society, 2007, 32(9):964-966.
- [14] 付小平, 薛新华, 李洪涛. GRNN 模型在煤与瓦斯突出及瓦斯含量预测中的应用[J]. 中国安全科学学报, 2012, 22(1):24-28.
Fu Xiaoping, Xue Xinhua, Li Hongtao. Application of GRNN model in predicting coal and gas outburst and gas content[J]. China Safety Science Journal, 2012, 22(1):24-28.
- [15] Dombi G W, Nandi P, Saxe J M, et al. Predication of rib fracture injury outcome by an artifical neural network[J]. The Journal of Trauma, 1995, 39(5):915-921.

更 正

《煤炭学报》2011 年第 4 期第 655 页 1.1 节第 1 段中“粉煤灰来自当地燃煤电厂”应改为“粉煤灰来自美国西弗吉尼亚大学当地(摩根城)燃煤电厂”。

本刊编辑部