

基于经验模态分解和支持向量机的 短期风电功率组合预测模型

叶林, 刘鹏

(中国农业大学信息与电气工程学院, 北京市 海淀区 100083)

Combined Model Based on EMD-SVM for Short-term Wind Power Prediction

YE Lin, LIU Peng

(College of Information and Electrical Engineering, China Agricultural University, Haidian District, Beijing 100083, China)

ABSTRACT: A wind power prediction method based on empirical mode decomposition (EMD) and support vector machine (SVM) is proposed to treat with the nonlinearity and nonstationarity of wind speed data. Firstly, the wind speed data is decomposed into a series of components with stationarity by using EMD to reduce the influence between different feature information. Then, different models were built and different kernel functions and parameters were chosen to deal with each group of data by using SVM in order to improve the forecasting accuracy. Finally, short term wind power forecasting was made based on wind speed data through a practical wind power curve. Case study was carried out to investigate the validity of the novel algorithm and the results illustrated that the forecasting error of EMD-SVM combined model decreased by 5%~10% compared to single statistics model. The proposed combined model can improve the short term forecasting accuracy of wind power effectively by tracking the change of wind power.

KEY WORDS: empirical mode decomposition (EMD); support vector machine (SVM); wind speed; short-term wind power prediction; combined forecasting model

摘要: 针对风速序列随时间、空间呈现非平稳性变化的特征, 提出一种基于经验模态分解(empirical mode decomposition, EMD)和支持向量机(support vector machine, SVM)的 EMD-SVM 短期风电功率组合预测方法。该方法首先利用

EMD 将风速序列分解为一系列相对平稳的分量, 以减少不同特征信息间的相互影响; 然后利用 SVM 法对各分量建立预测模型, 针对各序列自身特点选择不同的核函数和相关参数来处理各组不同数据, 以提高单个模型预测精度。最后将风速预测结果叠加并输入功率转化曲线以得到风电功率预测结果。研究表明, EMD-SVM 组合预测模型能更好地跟踪风电功率的变化, 其预测误差比单一统计模型降低了 5%~10%, 有效地提高了短期风电功率预测的精度。

关键词: 经验模态分解; 支持向量机; 风速; 短期风电功率预测; 组合预测模型

0 引言

随着风电技术的不断发展和风电场的规模不断增大, 为了保证电力系统的稳定运行和供电可靠性, 必须对风电系统进行有效的规划和调度^[1-2]。由于风电本身所特有的间歇性和不确定性, 增加了电网调度的难度, 为了解决风电场的发电量不确定问题, 电网必须提供足够的旋转备用容量, 而旋转备用容量的增加间接地增加了风力发电的整体运营成本, 所以需要风电场的输出功率进行预测, 通过对风电场发电量进行准确的预测, 可以大幅降低电网旋转备用容量, 从而有效降低风力发电系统的运行成本, 为电网调度运行提供可靠依据^[3-5]。

目前常用的风电功率预测方法包括持续法、时间序列法、卡尔曼滤波法、人工神经网络法、模糊逻辑法、支持向量机法、空间相关性法、物理预测法等^[6-8]。其中持续法认为风速预测值等于最近几个风速历史值的滑动平均值。通常, 只是简单地把最近一点的风速观测值作为下一点的风速预测值。该模型的预测误差较大, 且预测结果不稳定。随机时

基金项目: 国家自然科学基金项目(51077126, 51174290); 教育部科学技术重点研究项目(109017); 教育部新世纪优秀人才支持计划(NCET-08-0543); 北京市自然科学基金项目(3113029)。

Project Supported by National Natural Science Foundation of China (51077126, 51174290); Key Project of Chinese Ministry of Education (109017); Program for New Century Excellent Talents in University (NCET-08-0543); Beijing Natural Science Foundation (3113029).

间序列法利用大量的历史数据来建模, 经过模型识别、参数估计、模型检验来确定一个能够描述所研究时间序列的数学模型, 进而推导出预测模型, 达到预报的目的, 但存在低阶模型预测精度低、高阶模型参数估计难度大的缺点^[9]。卡尔曼滤波法需将风速作为状态变量建立状态空间模型, 用卡尔曼滤波算法实现风速预测。该方法的有效性是建立在噪声统计特性已知的前提下, 对于统计特性未知的情况, 该方法存在较大局限性^[10]。人工神经网络法旨在模仿人脑结构及其功能, 由大量简单处理元件以某种拓扑结构大规模连接而成, 具有并行处理、分布式存储与容错性等特征, 具有自学习、自组织和自适应能力, 可用于短期风速预测。但其具有难以科学确定网络结构、学习速度慢、存在局部极小点、记忆具有不稳定性等固有缺陷, 预测精度通常难以达到要求^[11]。模糊逻辑法应用模糊逻辑和预报人员的专业知识将数据和语言形成模糊规则库, 然后选用一个线性模型逼近非线性动态变化的风速, 但是, 对于风速预测, 单纯的模糊方法效果往往不佳, 这主要是因为模糊预测学习能力较弱, 模糊系统的辨识还未形成完善的理论, 在预测系统中选择模糊系统的结构尚需作进一步的研究^[12]。支持向量机法采用结构风险最小化原则, 通过对大量数据的训练得到预测模型, 进而对风速数据进行预测, 此方法解决了局部最小化问题, 有较强的泛化能力, 但核函数及相关参数的确定依赖设计者的经验, 且对风速数据依赖较大^[13-15]。物理方法的目标是尽可能准确估算出风电机组轮毂高度处的气象信息, 其首先利用数值天气预报系统的预测结果得到风速、风向、气压、气温等气象数据, 然后根据风机周围的物理信息得到风力发电机组轮毂高度的风速、风向等信息, 最后利用风机的功率曲线计算得出风机的实际输出功率, 该方法的难点是很难获得完善的数值天气预报信息来建立预测模型^[16]。

以上各种风电功率预测方法都有其特点, 但在应用时都存在一定的局限性。目前, 采用单一预测方法所得到的风电功率预测误差较大, 一般为 25%~40%^[17], 主要是由于风能本身的间歇性和不确定性以及预测方法本身的局限性所造成的, 由此可见, 单个预测模型已无法满足预测精度的需要, 所以风电功率预测的发展方向为采用组合预测模型^[18], 即针对各模型自身的特点, 通过优势互补的

思想建立组合模型, 提高预测精度。

针对风速序列非线性和非平稳性的特点, 本文提出了一种基于经验模态分解和支持向量机(empirical mode decomposition and support vector machines, EMD-SVM)的风电功率短期组合预测模型, 该方法首先利用经验模态分解(empirical mode decomposition, EMD)将风速分解为一系列具有不同特征尺度的数据序列, 将信号中真实存在的不同尺度波动或趋势逐级分解出来, 然后针对每组序列的自身特点构建不同的支持向量机(support vector machine, SVM)模型, 选取各自的最佳参数和核函数, 并对各分量进行预测, 将各分量预测结果叠加得到风速预测值, 进而通过功率曲线将风速预测值转化为风电功率预测值, 以期得到较好的预测效果。

1 经验模态分解

经验模态分解是一种基于信号局部特征的信号分解方法。该方法吸取了小波变换多分辨的优势, 同时克服了小波变换中需选取小波基与确定分解尺度的困难, 因此更适用于非线性非平稳信号分析, 是一种自适应的信号分解方法, 可用于风速时间序列的分析。经验模态分解方法假设: 任何复杂的信号都是由简单的固有模态函数(intrinsic mode function, IMF)组成, 且每一个 IMF 都是相互独立的^[19-20]。该方法可以将风速数据时间序列中真实存在的不同尺度或趋势分量逐级分解出来, 产生一系列具有相同特征尺度的数据序列, 分解后的序列与风速原始数据序列相比具有更强的规律性, 可以提高预测精度。

风速时间序列的 EMD 分解步骤如下:

1) 识别出信号中所有极大值点并拟合其包络线 $e_{up}(t)$ 。

2) 提取信号中的极小值点和拟合包络线 $e_{low}(t)$, 计算上下包络线的平均值 $m_1(t)$ 。

$$m_1(t) = \frac{e_{up}(t) + e_{low}(t)}{2} \quad (1)$$

3) 将 $x(t)$ 减去 $m_1(t)$ 得到 $h_1(t)$, 将 $h_1(t)$ 视为新的信号 $x(t)$, 重复第 1) 步, 经过 k 次筛选, 直到 $h_1(t) = x(t) - m_1(t)$ 满足 IMF 条件, 记 $c_1(t) = h_1(t)$, 则 $c_1(t)$ 为风速序列的第 1 个 IMF 分量, 它包含原始序列中最短的周期分量。

从原始信号中分离出 IMF 分量 $c_1(t)$, 得到剩余

分量:

$$r_1(t) = x(t) - c_1(t) \quad (2)$$

将剩余分量 $r_1(t)$ 作为新的原始数据, 重复上述步骤可得到其余 IMF 分量和 1 个余量, 结果如下:

$$\begin{cases} r_1(t) - c_2(t) = r_2(t) \\ r_2(t) - c_3(t) = r_3(t) \\ \vdots \\ r_{N-1}(t) - c_N(t) = r_N(t) \end{cases} \quad (3)$$

原始风速序列 $x(t)$ 可被分解为

$$x(t) = \sum_{i=1}^N c_i(t) + r_N(t) \quad (4)$$

本文使用 Rilling 等提出的终止条件^[21], 它是对 Huang 等人提出的限定标准差(standard deviation, SD)准则的改进。

若 e_{\max} 、 e_{\min} 分别为上、下包络线, 设

$$\delta(t) = \frac{|e_{\max} + e_{\min}|}{|e_{\max} - e_{\min}|} \quad (5)$$

设定 3 个门限值 θ_1 、 θ_2 和 α , 相应的终止条件有 2 个: 条件①是满足 $\delta(t) < \theta_1$ 的时刻个数与全部持续时间之比不小于 $1 - \alpha$, 即

$$\frac{S\{t \in D | \delta(t) < \theta_1\}}{S\{t \in D\}} \geq 1 - \alpha \quad (6)$$

式中: D 为信号持续范围; $S(A)$ 为集合 A 中元素个数; $\theta_1 = 0.05$; $\alpha = 0.05$ 。

条件②是对每个时刻 t 有

$$\delta(t) < \theta_2, \theta_2 = 10\theta_1 \quad (7)$$

2 支持向量机原理

支持向量机植根于统计学习理论的 VC(Vapnik-Chervonenkis)维理论和结构风险最小化(structural risk minimization, SRM)原则, 它根据优先的风速序列样本信息在预测模型的复杂性和学习能力之间寻求最佳折衷, 以期获得最好的泛化能力^[22-23]。

SVM 用于风电功率预测的基本思想是寻找一个函数 $f \in F$ (F 是函数集), 使期望风险函数 $R(f)$ 最小, 即

$$R(f) = \int l(y - f(x)) dP(x, y) \quad (8)$$

式中 l 为损失函数, 它可以为任意凸函数。其常用形式为 $l(x) = |y - f(x)|^p$, 其中 p 为某个正整数。因为

风速样本概率 $p(x, y)$ 不能事先知道, 所以不能利用式(8)直接计算期望风险最小值 $R(f)$ 。

根据结构风险最小化^[24], 有

$$R(f) \leq R_{\text{emp}} + R_{\text{gen}} \quad (9)$$

式中: R_{emp} 为经验风险; R_{gen} 为 $f(x)$ 复杂度的一种度量。因此, 可以用 $R_{\text{emp}} + R_{\text{gen}}$ 来确定 $R(f)$ 的上限。

用 SVM 来预测风电功率的基本思想如下: 给定以 $p(x, y)$ 为概率的风速序列观测样本集 $\{(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)\} \in \mathbf{R}^n \times \mathbf{R}$, 设回归函数为

$$F = \{f | f(x) = \mathbf{w}^T \mathbf{x} + b, \mathbf{w} \in \mathbf{R}^n\} \quad (10)$$

引进结构风险函数 R_{reg} :

$$R_{\text{reg}} = \frac{1}{2} \|\mathbf{w}\|^2 + CR_{\text{emp}}[f] \quad (11)$$

式中: $\|\mathbf{w}\|^2$ 为描述函数; $f(x)$ 为模型复杂度; C 为常数。它的作用是在经验风险和模型复杂度之间取一个折衷。

式(10)的回归问题等价于最小化代价泛函:

$$\min \frac{1}{2} \mathbf{w}^T \mathbf{w} + C \sum_{i=1}^n (\zeta_i + \zeta_i^*) \quad (12)$$

$$\begin{cases} \text{s.t. } y_i - \mathbf{w}^T \mathbf{x}_i - b \leq \varepsilon + \zeta_i \\ \mathbf{w}^T \mathbf{x}_i + b - y_i \leq \varepsilon + \zeta_i^* \\ \zeta_i, \zeta_i^* \geq 0 \end{cases} \quad (13)$$

式中: ε 为估计精度; ζ_i 、 ζ_i^* 为模型中引进的松弛变量, 目的是处理函数 f 在 ε 精度下不能估计的数据, 使回归函数的解存在。

由于风速为随时间空间变化的非线性序列, 不适用于上述线性回归过程, 因此可以通过一个非线性映射 ϕ 将风速数据 \mathbf{x} 映射到高维特征空间, 通过构造核函数来实现将低维输入空间的非线性回归转化为高维特征空间的线性回归, 该核函数为

$$k(\mathbf{x}_i, \mathbf{x}_j) = \phi(\mathbf{x}_i) \phi(\mathbf{x}_j) \quad (14)$$

最小化代价泛函可写为

$$\min_{\alpha, \alpha^*} \frac{1}{2} [\alpha, \alpha^*] \begin{bmatrix} \mathbf{Q} & -\mathbf{Q} \\ -\mathbf{Q} & \mathbf{Q} \end{bmatrix} \begin{bmatrix} \alpha \\ \alpha^* \end{bmatrix} + [\varepsilon \mathbf{I}^T + \mathbf{y}^T \quad \varepsilon \mathbf{I}^T - \mathbf{y}^T] [\alpha \quad \alpha^*]^T \quad (15)$$

$$\text{s.t. } [\mathbf{I}^T \quad -\mathbf{I}^T] [\alpha \quad \alpha^*]^T = 0, \quad 0 \leq \alpha, \alpha^* \leq C \quad (16)$$

式中: $\mathbf{Q}_{ij} = \phi^T(\mathbf{x}_i) \phi(\mathbf{x}_j)$; $\mathbf{I} = [1, \dots, 1]^T$; α 、 α^* 为拉格朗日乘子。求解此二次规划可求得 α 的值, 同时求得

$$w = \sum_{i=1}^n (\alpha_i - \alpha_i^*) \phi(x_i) \quad (17)$$

将式(17)带入回归函数得

$$f(x) = \sum_{i=1}^n (\alpha_i - \alpha_i^*) (x_i \cdot x) + b \quad (18)$$

式中 $\alpha_i - \alpha_i^*$ 为不为零时所对应的风速样本数据, 是预测模型的支持向量。利用 KKT(Karush-Kuhn-Tucker)条件来计算常值偏差 b :

$$b = y_j - \varepsilon - \sum_{i=1}^l (\alpha_i - \alpha_i^*) K(x_i, x_j), \alpha_i \in (0, C) \quad (19)$$

$$b = y_j + \varepsilon - \sum_{i=1}^l (\alpha_i - \alpha_i^*) K(x_j, x_i), \alpha_i^* \in (0, C) \quad (20)$$

采用支持向量机进行风速预测的具体步骤如下:

1) 对历史数据进行归一化处理, 即将原始数据线性变化至 $[-1, 1]$ 区间中, 作为训练数据集。

2) 对训练数据选用不同核函数和不同参数进行试验, 生成不同核函数和不同参数的训练表。在此步骤要对每一组分解出的 IMF 序列预测模型的核函数和参数进行优化。

3) 从训练结果表中, 根据训练误差大小和不同参数的综合表现挑选出合适的核函数, 然后选择对应的最佳参数。

4) 利用选择的核函数和对应参数对训练数据进行学习后产生训练模型, 然后输入预测数据并对产生的预测结果进行检验。如果预测结果不符合预

测精度要求则返回第 3) 步, 重新选择参数进行学习; 如果预测结果符合预测精度, 进行第 5) 步。

5) 在核函数和相关参数确定后, 输入预测数据序列进行预测, 最后进行误差分析。

3 基于 EMD-SVM 的风电场短期风电功率组合预测方法

风速时间序列具有较强的非线性、非平稳性与随机性, 因此在使用常规学习预测方法时难以取得较好的效果。鉴于 EMD 技术在非平稳数据处理中的突出优势, 本文提出了一种基于 EMD-SVM 的风电场短期风电功率组合预测方法。首先对风速时间序列进行 EMD 分解, 使其产生一系列不同尺度的 IMF 分量, 实现风速序列平稳化。然后针对各分量特点选取最优的模型参数和核函数, 分别建立适合自身的 SVM 预测模型。最后将各分量的预测值叠加得到风电功率预测值。具体预测步骤如图 1 所示。

1) 利用 EMD 方法对原始风速序列进行分解, 得到 IMF 各分量 $c_i(t)$ 和余量 r_n 。

2) 分别对各 IMF 分量 $c_i(t)$ 和 r_n 建立 SVM 回归模型, 选取最佳参数和核函数, 得到各分解序列的预测值。

3) 将各分量预测值叠加得到风速预测值。

4) 将风速预测值输入功率转换曲线, 得到风电功率预测值。

5) 与实际数据对比, 计算误差指标并进行误

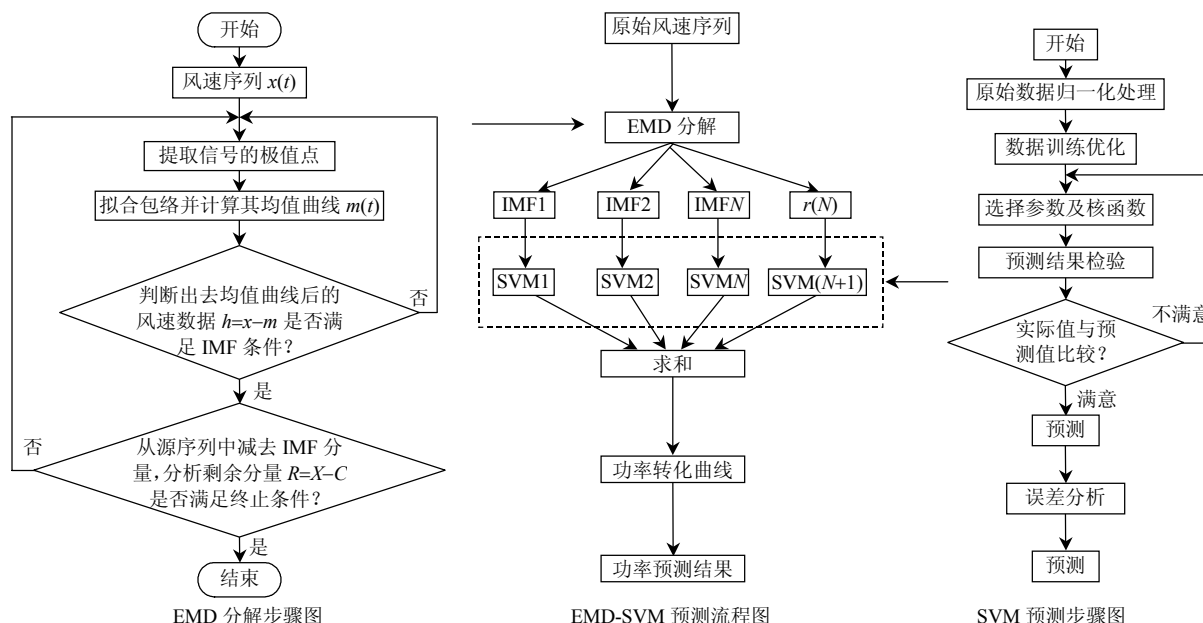


图 1 EMD-SVM 组合预测流程图

Fig. 1 Flowchart of EMD-SVM combined prediction

差分析。

4 算例及结果分析

本文以中国某风电场 2009 年 6 月的实测风速数据为实验数据样本。该输入样本为每 10 min 采样 1 个点, 取其中的前 3 d 数据, 即前 432 个采样点为实验样本。其中, 前 288 个采样点为模型输入样本, 后 144 个采样点为测试样本。

风速原始输入序列如图 2 所示。首先, 对实验样本风速序列进行 EMD 分解, 逐个分离出相应的 IMF 分量, 通过给出终止条件作为迭代终止的依据。本文将 2 个连续的处理结果之间的标准差大小作为终止条件来实现对原始风速序列进行 EMD 分解(如图 3 所示)。从图 3 可以看出, 原本的非线性风速序列被分解为 5 个波动较小的时间序列分量 IMF(C₁—C₅)分量和 1 个剩余分量 r_5 。根据不同 IMF 分量的自身特点, 分别建立 SVM 模型进行预测。本文通过分析样本序列的复杂度来选择相适应的 SVM 模型核函数及其参数, 对于波动频率大、复杂度较高的本征模态分量 IMF1、IMF2 和 IMF3 采用泛化能力强、处理非线性序列效果较好的径向基核函数进行预测; 对于变化较平稳的中低频分量 IMF4 和 IMF5 采用多项式核函数进行预测; 剩余分量采用线性核函数进行预测, 其他参数可通过交叉

检验的方法确定, 最后将各分量预测结果叠加即可得到风速预测值, 进一步将风速预测值输入功率曲线得到短期风电功率的预测值。

本文采用提前 12 步的风电功率预测, 因为测风点采样频率为每 10 min 采样一次, 所以本文中的预测结果为提前 2 h 的风电功率预测曲线。为了更好地验证本文所提算法的有效性, 分别对风速输入数据建立 EMD-SVM 组合预测模型和单一方法的 SVM 预测模型及灰色预测模型, 并将各自的预测结果与实际功率值对比, 分别计算均方根误差(root mean square error, RMSE)和平均百分比误差(mean absolute percentage error, MAPE)。其中 RMSE 反映的是误差的统计学特性, 也就是样本的离散程度。MAPE 反映的是误差的总体水平, 即预测数据




图 2 原始风速时间序列

Fig. 2 Original wind speed series

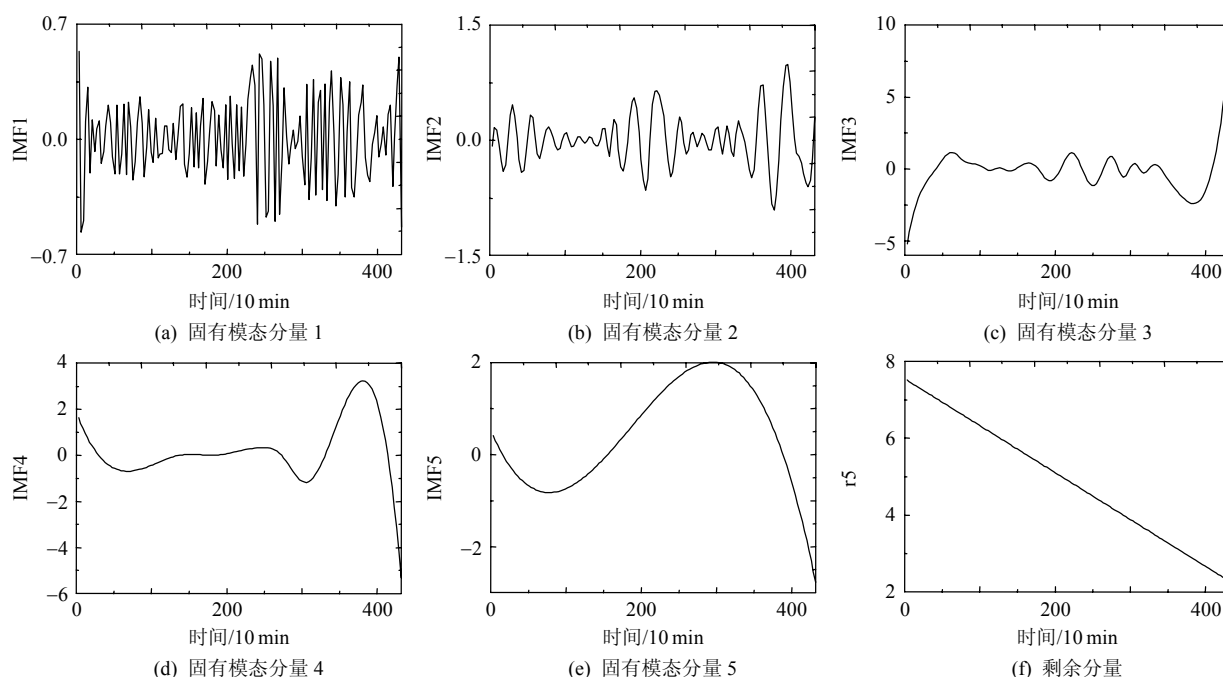


图 3 风速数据 EMD 分解图

Fig. 3 EMD results of wind speed data

整体上与实际数据的接近水平。两模型的误差指标如表 1 所示。

表 1 不同风电功率预测方法的误差对比

Tab. 1 Compared errors of wind power prediction under RMSE and MAPE

预测方法	均方根误差/%	平均百分比误差/%
EMD-SVM	18.7	13.4
SVM	23.6	19.6
灰色预测	29.3	23.7

图 4 为风电功率预测结果对比图。从图中可以观察到 EMD-SVM 法提前 2 h 的风电功率预测值与实际值吻合较好。可以看出，EMD-SVM 法与单一统计方法相比，预测精度有了一定的提高，尤其在一些功率波动较大的转折点附近最为明显，这表明使用 EMD 法对风速进行分解能够在一定程度上提高风电场风电功率预测的准确性。虽然受风机发电功率最大值和发电功率曲线限制，在风速小于起动风速或接近极限风速时 2 种方法的精度差较小，但改进的预测方法可以更好地找出数据内在的趋势和规律，在风速变化较大时模型更快地做出反应，使预测曲线更好地跟踪实际功率曲线。由此可见，本文所提出的方法不仅在总体上提高了预测的精度，而且各预测点的值与实际值的接近程度都有了一定的提高，实现了较高精度的短期风电功率预测。




图 4 未来 2 h 风电功率预测值与实际值对比图

Fig. 4 Comparison of actual wind power and the predicted results ahead 2 hours

虽然 EMD-SVM 法已经实现了较高精度的短期风电功率预测，但在风速波动大的时段仍然会出现较大的误差，这是由风速序列的随机性和不确定性造成的，只分析历史风速数据无法得出风速序列将会在哪里突变，只能被动地通过反馈和参数修改来减小误差，这也是产生误差的主要原因之一。若在模型输入中引入数值天气预报数据可以有效地

对大气运动进行模拟，则可依据大气条件分析并确定风速将在何时发生突变，从而大幅提高风电功率的预测精度。

5 结论

1) 本文提出的 EMD-SVM 短期风电功率组合预测方法可以将风速时间序列中真实存在的相同尺度波动或趋势量逐级分解出来，将非线性非平稳的风速序列平稳化，产生一系列具有相同特征尺度的风速数据序列。

2) 针对每一个具有近似特性的平稳序列分别建立预测模型，选择各自适合的核函数和相关参数，从而降低了风速数据非线性和非平稳性对风电功率预测结果的影响。

3) 算例表明，EMD-SVM 组合预测模型可以更好地跟踪风电功率的变化规律，有效提高短期风电功率的预测精度。

参考文献

[1] Damousis I G, Alexiadis M C, Theocharis J B, et al. A fuzzy model for wind speed prediction and power generation in wind parks using spatial correlation[J]. IEEE Transactions on Energy Conversion, 2004, 19(2): 352-361.

[2] Ernst B, Oakleaf B, Ahlstrom M L, et al. Predicting the wind[J]. IEEE Transactions on Power & Energy Magazine, 2007, 11(2): 79-89.

[3] Cao Lei, Li Ran. Short-term wind speed forecasting model for wind farm based on wavelet decomposition[C]// Proceedings of 3rd International Conference on Deregulation & Reconstruction and Power Technologies. Nanjing, China: Northeast University Press, 2008: 2525-2529.

[4] Pinson P, Kariniotakis G N. Wind power forecasting using fuzzy neural networks enhanced with on-line prediction risk assessment[C]//Proceedings of IEEE Conference on Power Conference. Bologna, Italy: European Commission, 2003: 23-26.

[5] 张丽英, 叶廷路, 辛耀中, 等. 大规模风电接入电网的相关问题及措施[J]. 中国电机工程学报, 2010, 30(25): 1-9.

Zhang Liying, Ye Tinglu, Xin Yaozhong, et al. Problems and measures of power grid accommodating large scale wind power[J]. Proceedings of the CSEE, 2010, 30(25): 1-9(in Chinese).

[6] 杨秀媛, 肖洋, 陈树勇. 风电场风速和发电功率预测研

- 究[J]. 中国电机工程学报, 2005, 25(11): 1-5.
Yang Xiuyuan, Xiao Yang, Chen Shuyong. Wind speed and generated power forecasting in wind farm [J]. Proceedings of the CSEE, 2005, 25(11): 1-5(in Chinese).
- [7] 谷兴凯, 范高峰, 戴慧珠. 风电功率预测技术综述[J]. 电网技术, 2007, 31(2): 335-338.
Gu Xingkai, Fan Gaofeng, Dai Huizhu. Summarization of wind power prediction technology[J]. Power System Technology, 2007, 31(2): 335-338(in Chinese).
- [8] 王丽婕, 廖晓钟. 风电场发电功率的建模和预测研究综述[J]. 电力系统保护与控制, 2009, 37(13): 118-121.
Wang Lijie, Liao Xiaozhong. Summarization of modeling and prediction of wind power generation[J]. Power System Protection and Control, 2009, 37(13): 118-121(in Chinese).
- [9] 李丽, 叶林. 基于改进持续法的短期风电功率预测[J]. 农业工程学报, 2010, 26(12): 182-187.
Li Li, Ye Lin. Short-term wind power forecasting based on an improved persistence approach[J]. Transactions of the CSAE, 2010, 26(12): 182-187(in Chinese).
- [10] 范高峰, 王伟胜, 戴慧珠, 等. 基于人工神经网络的风电功率预测[J]. 中国电机工程学报, 2008, 28(34): 118-123.
Fan Gaofeng, Wang Weisheng, Dai Huizhu, et al. Wind power prediction based on artificial neural network [J]. Proceedings of the CSEE, 2008, 28(34): 118-123(in Chinese).
- [11] Cameron W P, Negnevitsky M. Very short-term wind forecasting for Tasmanian power generation[J]. IEEE Transactions on Power Systems, 2006, 21(2): 965-972.
- [12] Damousis I G, Alexiadis M C, John B. A fuzzy model for wind speed prediction and power generation in wind parks using spatial correlation[J]. IEEE Transactions on Energy Conversion, 2004, 19(2): 352-361.
- [13] Bludszuweit H, Dominguez-Navarro J A, Llombart, A. Statistical analysis of wind power forecast error [J]. IEEE Transactions on Power Systems, 2008, 23(3): 983-991.
- [14] James W T, Patrick E, Sharry M. Wind power density forecasting using ensemble predictions and times series models[J]. IEEE Transactions on Energy Conversion, 2009, 24(3): 775-782.
- [15] Dorman L I, Pustil'nik L A, Sternlieb A, et al. Monitoring and forecasting of great solar proton events using the neutron monitor network in real time[J]. IEEE Transactions on Plasma Science, 2004, 32(4): 1478-1488.
- [16] 冯双磊, 王伟胜, 刘纯, 等. 风电场功率预测物理方法研究[J]. 中国电机工程学报, 2010, 30(2): 1-6.
Feng Shuanglei, Wang Weisheng, Liu Chun, et al. Study on the physical approach to wind power prediction [J]. Proceedings of the CSEE, 2010, 30(2): 1-6(in Chinese).
- [17] Barthelmie R, Giebel G, Badger J. Short-term forecasting of wind speeds in the offshore environment[C]// Copenhagen Offshore Wind Conference. Copenhagen: University of Copenhagen, 2005: 24-35.
- [18] Kariniotakis G, Stavrakis G, Nogaret E. Wind power forecasting using advanced neural network models [J]. IEEE Transactions on Energy Conversion, 1996, 11(4): 762-767.
- [19] Huang N E, Shen Z, Long S R. The empirical mode decomposition and the Hilbert spectrum for nonlinear and non-stationary time series analysis[J]. Proceedings of The Royal Society Soc Lond, 1998, 454(1971): 903-995.
- [20] Vapnik V N. The nature of statistical learning theory [M]. New York: Springer-Verlag, 2000: 35-39.
- [21] Yang Weiqin, Gu lan. Time series analysis and dynamical modeling[M]. Beijing: Beijing University of Technology Press, 1988: 26-33.
- [22] Burges C. A tutorial on support vector machines for pattern recognition[J]. Data Mining and Knowledge Discovery, 1998, 2(2): 121-127.
- [23] Chih W H, Chih C C, Chih J L A practical guide to support vector classification[EB/OL]. 2003 [2008-08-10]. <http://www.csie.ntu.edu.tw/~cjlin/talks/freiburg.pdf>.
- [24] 王晓兰, 李辉. 风电场输出功率年度预测中有效风速预测研究[J]. 中国电机工程学报, 2010, 30(8): 117-122.
Wang Xiaolan, Li Hui. Effective wind speed forecasting in annual prediction of output power for wind farm [J]. Proceedings of the CSEE, 2010, 30(8): 117-122(in Chinese).



叶林

收稿日期: 2011-05-11。

作者简介:

叶林(1968), 男, 教授, 博士生导师, 德国洪堡学者, 主要研究方向为电力系统自动化、新能源发电与超导电力应用, 通信作者, yelin@cau.edu.cn;

刘鹏(1987), 男, 硕士研究生, 从事风电机组建模、风电并网分析及风电功率预测等领域的研究工作, lp19870804@cau.edu.cn。

(责任编辑 刘浩芳)