

EMD 和 CSP 融合最优波长空间滤波脑电特征提取方法

张学军^{1,2}, 王龙强¹, 黄婉露¹, 黄丽亚^{1,2}, 成谢锋^{1,2}

ZHANG Xuejun^{1,2}, WANG Longqiang¹, HUANG Wanlu¹, HUANG Liya^{1,2}, CHENG Xiefeng^{1,2}

1. 南京邮电大学 电子与光学工程学院, 南京 210023

2. 南京邮电大学 射频集成与微组装技术国家地方联合工程实验室, 南京 210023

1. School of Electronic and Optical Engineering, Nanjing University of Posts and Telecommunications, Nanjing 210023, China

2. Nation-Local Joint Project Engineering Lab of RF Integration & Micropackage, Nanjing University of Posts and Telecommunications, Nanjing 210023, China

ZHANG Xuejun, WANG Longqiang, HUANG Wanlu, et al. EEG signals feature extraction based on EMD and CSP combined WOSF. *Computer Engineering and Applications*, 2018, 54(24): 149-155.

Abstract: A feature extraction method based on Empirical Mode Decomposition(EMD), Common Spatial Pattern(CSP) and Wavelength Optimal Spatial Filter(WOSF) is proposed. Firstly, the EMD is used to decompose the EEG signal, and get a set of stationary time series called Intrinsic Mode Functions(IMFs). Secondly, selecting the appropriate IMFs for signal reconstruction, then the signal can be transformed into optimal signal through WOSF, the optimal signal is mapped to high-dimensional space through CSP, extracting the corresponding feature vector. Finally, the classification is performed using Support Vector Machine(SVM). After analyzing the result of the 9 subjects, the average accuracy classification rate obtained is over 95%, confirming the feasibility and availability of this method.

Key words: Empirical Mode Decomposition(EMD); Common Spatial Pattern(CSP); Wavelength Optimal Spatial Filter(WOSF); Intrinsic Mode Functions(IMF)

摘 要: 基于经验模式分解和共空间模式, 结合最优波长空间滤波, 提出了三者相结合的特征提取方法。该方法首先利用经验模式分解进行分解, 得到固有模态函数, 选择合适的固有模态函数进行信号的重构, 然后将重构的信号进行最优波长空间滤波变换, 得到最优的波长选择信号, 再经共空间模式投影映射, 提取相应的特征向量, 最后利用支持向量机进行分类。运用该方法对9位受试者进行分类结果分析, 平均分类准确率在95%以上, 实验表明, 提出的算法具有较好的分类识别性。

关键词: 经验模式分解; 共空间滤波模式; 最优波长空间滤波; 固有模态函数

文献标志码: A **中图分类号:** TP391 **doi:** 10.3778/j.issn.1002-8331.1709-0021

1 引言

传统的运动通道是由大脑神经和肌肉组成, 神经传导冲动, 肌肉配合完成相应的动作, 而脑-机接口(Brain-Computer Interface, BCI)则提供了另一种运动通道, 不依赖传统的运动通道, 由大脑意识直接与外部设备相连^[1], 建立运动通道, 用人的大脑意识控制外部设备, 不需要经过神经传导和肌肉运动, 为神经损伤或肌肉损伤

的病人提供了一种新的运动方式, 不再需要依靠别人的照顾, 自己即可完成运动。脑机接口技术领域的发展不仅可以帮助瘫痪病人使用计算机、神经假体、机械臂等电子设备, 也实现了包括: 运动恢复、通信、环境控制甚至娱乐等其他功能^[2]。

脑机接口技术主要包含信号采集、预处理、特征提取、特征分类和接口设备控制等五个步骤。其中, 由特

基金项目: 国家自然科学基金(No.61271334)。

作者简介: 张学军(1969—), 男, 博士, 教授, 研究领域为主要研究方向为智能信息处理、认知网络频谱感知、无线射频识别技术等, E-mail: xjzhang@njupt.edu.cn; 王龙强(1993—), 男, 硕士研究生, 研究领域为智能信息处理; 黄婉露(1993—), 女, 硕士研究生, 研究领域为智能信息处理; 黄丽亚(1972—), 女, 博士, 教授; 成谢锋(1956—), 男, 教授, 博士生导师。

收稿日期: 2017-09-04 **修回日期:** 2017-10-26 **文章编号:** 1002-8331(2018)24-0149-07

CNKI网络出版: 2018-03-22, <http://kns.cnki.net/kcms/detail/11.2127.TP.20180321.1714.020.html>

征提取得到的特征信号可以标识不同想象运动脑电信号的判别信息,对后续的分类识别有很大的影响,因此特征提取在BCI研究界受到广泛的关注^[2]。

有效的特征提取方法是改善识别精度的关键,目前,时间-频率方法被广泛应用于脑电信号的研究。传统的时间-频率方法包括:短时傅里叶变换(Short-Time Fourier Transform, STFT)、小波变换(Wavelet Transform, WT)等,但是这些方法的本质都是基于傅里叶变换,根据海森堡不确定性原理,该方法不可能同时得到时间-频率的良好分辨率。近年,希尔伯特黄变换(Hilbert-Huang Transform, HHT)作为另一种时间-频率分析法已经变得越来越流行,同时它也十分适合分析非线性和非平稳信号。原信号经过经验模式分解(Empirical Mode Decomposition, EMD)被分解为一系列固有模态函数(Intrinsic Mode Functions, IMFs),随后对每个固有模态函数进行希尔伯特黄变换,求其相应的能量谱和边际谱,作为特征进行分类。HHT不涉及海森堡不确定性原理可以获得时域和频域的高分辨率。目前被广泛应用于许多信号处理领域,如雷达探测、地震信号和生物医学信号等^[3]。

再者,由于EEG信号低空间分辨率,EEG信号构成的BCI系统需要进行有效的空间滤波,从而确保从受试的相关脑域中提取特征信息。在这一方面,常用的算法有:共空间模式(Common Spatial Pattern, CSP)、独立主成分分析(Independent Component Analysis, ICA)和共域空间谱模式(Common Spatial Spectral Pattern, CSSP)、滤波器CSP(Filter Bank Common Spatial Pattern, FBCSP)、判别滤波CSP(Discriminant Filtering Common Spatial Pattern, DFBCSP)等多种CSP改进算法。Koles于1991年首先在文献[4]中提出使用基于小波变换的CSP方法来提取EEG信号中的非正常成分,紧接着文献[5]首次将该方法运用到运动想象EEG信号分类中,文献[6]采用CSP方法对多导EEG信号进行了特征提取,文献[7]在此基础上提出的sub-CSP算法对运动想象脑电信号的分类识别做出了进一步研究。

然而,传统的CSP需要大量的输入通道,同时缺乏频率信息。CSP算法主要是通过对脑电源的空间信息的判定来实现不同分类间的差异极大化,算法本质是利用代数上矩阵同时对角化的理论,寻找一组空间滤波器,脑电信号通过这组滤波器的投影获得较明显的特征向量。由于脑电信号是极复杂的非线性,不平稳信号,采集到的信号中,不止有脑电信号,还有其他的杂质信号,即使在脑电信号的频带范围内依旧存在其他的混叠信号,这些杂质与混叠信号将会影响特征提取的有效性,而单纯的CSP滤波,只是通过空间信息来判定脑电信号的有效性,存在一定的不足,可能不会将杂质与混叠信号从频段中去除干净,如果许多与运动想象无关的

频率信号混在其中,严重影响了特征向量的有效性^[8]。本文提出了基于EMD和CSP,同时结合最优波长空间滤波(Wavelength Optimal Spatial Filter, WOSF)的算法。该算法在利用CSP对多通道的脑电数据进行分析,提取脑电特征向量的基础上,采用EMD与之组合,将脑电信号分解为IMFs,不需要实际的多通道脑电信号,利用IMFs模拟多通道信号,同时在进行IMFs的选择时,考虑到脑电信号的频域信息,因此在CSP的基础上加入了EMD的频域信息,最后利用WOSF对CSP输入信号进行优化,选择最优的脑电信号,得到更加适合的空间特征,为更好地进行想象运动判别提供了一个可选的途径,达到提高分类识别的目的。主要步骤:(1)利用EMD将预处理后的EEG分解为IMFs;(2)利用傅里叶变换FFT得到IMFs的频谱图,选择频谱在 μ 和 β 节律的IMFs;(3)利用WOSF,对IMFs进行最优波长选择;(4)将最优信号进行CSP空间滤波,选择合适的特征向量;(5)采用支持向量机(SVM)分类器对特征进行分类。

2 实验数据

实验数据来自BCI Competition 2008 data sets 2b数据^[9],包含9个受试者的脑电EEG数据,受试者都是右利手,有正常或矫正正常视力,受试者坐在有扶手的舒适椅子上,全身放松,注视距离眼部1 m距离的屏幕。受试者根据屏幕出现的箭头方向,进行相应的手运动想象,两天完成两个sessions,其中每个session包含6个run,每个run包含20次实验,10次左手,10次右手,则一个session共包含60次左手,60次右手,共120次实验。实验进程如图1所示。




图1 实验进程

每个实验持续8~9 s,前2 s受试者处于放松状态,不进行任何想象活动;在第2 s时,有蜂鸣音提示受试者,实验即将开始,同时屏幕上显示十字光标,持续1 s;在第3 s,屏幕上出现视觉提示线索(一个箭头,随机向左,或向右),持续1.25 s,在第4 s,受试者根据提示箭头方向,进行相应手的运动想象,想象运动持续时间为3 s,在第7 s受试者停止想象,进行休息。实验采集电极位置如图2所示。

采用Ag/AgCl电极,分别采集C3、Cz和C4三个电极的脑电数据,,其中Cz为参考电极,而C3、C4电极位置则包含了想象手运动最丰富的信息,本文使用C3、C4




图2 采样电极位置

通道的数据进行分析,采样频率为250 Hz,采样数据通过0.5~100 Hz带通滤波器滤波,50 Hz陷波滤波器。

3 特征提取和分类

3.1 经验模态分解

文章首先对脑电信号进行经验模式分解,得到多个频带的子信号,同时该过程可以实现去噪。经验模态分解(EMD)^[3],可将信号分解为不同的本征模态函数(IMFs),EMD分解的基函数由信号本身决定,具有很好的自适应性并且能够精确地表征信号^[10]。本征模态函数必须满足两个条件:一是在整个信号时间域内,信号幅值的极大值数目与过零点的数目相等,或最多相差一个,二是信号幅值极大值形成的包络与幅值极小值形成的包络的平均值为零。

EMD的具体步骤为:

步骤1 识别信号 $X(t)$ 的极大值与极小值。

步骤2 对于极大值,利用三次样条插值函数拟合上包络 $e_{\max}(t)$;对于极小值,利用三次样条插值函数拟合下包络 $e_{\min}(t)$ 。

步骤3 计算两个包络间的均值 $m(t)$ 为:

$$m(t) = \frac{e_{\max}(t) + e_{\min}(t)}{2} \quad (1)$$

步骤4 从信号中减去均值,得到似模态函数 $c(t)$:

$$c(t) = x(t) - m(t) \quad (2)$$

步骤5 验证 $c(t)$ 是否满足本征模态函数条件,若 $c(t)$ 满足,则为一个IMF分量,原始信号变为 $x_{n+1}(t)$:

$$x_{n+1}(t) = x_n(t) - c(t) \quad (3)$$

若不满足,则返回步骤3。

步骤6 当所得信号少于两个极值点时,则保留为残余分量 $r(t)$,分解结束。原始信号被分解为 n 个IMF,剩余分量为 $r(t)$:

$$x(t) = \sum_{i=1}^n c_i(t) + r(t) \quad (4)$$

3.2 共空间模式

共空间模式(CSP)主要是对输入的脑电数据进行投影映射,得到区分度最大的特征向量,是基于对两个不同类别的协方差矩阵来完成的,对两个类别的协方差

矩阵进行同时对角化来设计空间滤波器,将原始脑电数据进行投影映射,得到分离度最大的特征^[10]。具体步骤为:

步骤1 设第 k 次实验的脑电信号为 $x(t) \in \mathbb{R}^{M \times n}$,其中 M 是采样点数, n 是采样通道数, $Y(k) \in \{A; B\}$ 代表第 k 次实验的类标签,两类分别为 A 和 B ,则标准化空间协方差矩阵 C 为:

$$C = \frac{x(t)^T x(t)}{\text{trace}\{x(t)^T x(t)\}} \in \mathbb{R}^{n \times n} \quad (5)$$

步骤2 T_A 和 T_B 分别代表类别 A 和 B 的个数,计算两个类别的平均协方差为:

$$\begin{cases} C_A = \frac{1}{T_A} \sum_{k=1}^{T_A} C_{Y^k=A} \\ C_B = \frac{1}{T_B} \sum_{k=1}^{T_B} C_{Y^k=B} \end{cases} \quad (6)$$

由此得到总体的协方差为:

$$C_M = C_A + C_B \quad (7)$$

步骤3 对于协方差 C_M ,求取其特征值与相应的特征向量,特征值组成对角矩阵 $\Lambda_M \in \mathbb{R}^{n \times n}$,特征向量为 $U_M \in \mathbb{R}^{n \times n}$

$$C_M = U_M \Lambda_M U_M^T \quad (8)$$

步骤4 将特征值按顺序进行排列,组成对角矩阵 Λ_{Md} ,对应的特征向量组成向量矩阵 U_{Md} ,则白化矩阵 P 为:

$$P = \Lambda_{Md}^{-\frac{1}{2}} U_{Md}^T \quad (9)$$

步骤5 将协方差矩阵 C_A 和 C_B 进行白化,计算 S_A, S_B 为:

$$\begin{cases} S_A = P C_A P^T \\ S_B = P C_B P^T \end{cases} \quad (10)$$

将经过白化之后的矩阵 S_A 和 S_B 重写为:

$$\begin{cases} S_A = {}^B \Lambda_A B^T \\ S_B = {}^B \Lambda_B B^T \end{cases} \quad (11)$$

步骤6 此时 S_A 和 S_B 有相同的特征向量 B ,且 $\Lambda_A + \Lambda_B = I$,则投影矩阵 W 为:

$$W = P^T B \quad (12)$$

步骤7 则脑电信号 $x(t)$ 经CSP投影之后得到 Z_0 为:

$$Z_0 = X(t) \cdot W \quad (13)$$

将投影信号 Z_0 按列进行划分,得 $Z_0 = [z_1, z_2, \dots, z_{2m}] \in \mathbb{R}^{N \times 2m}$,取其前 m 阶与后 m 阶组成特征矩阵,其中 $m < \frac{n}{2}$,亦组成的特征矩阵的阶数小于通道数,因此对于CSP来说,输入数据的通道数应该是以多为宜,适合多通道的数据。

3.3 波长最优空间滤波器

对于经验模式分解后得到的子频带脑电信号,对其进行波长最佳空间滤波处理,以此获得更加明显的分类

特征。WOSF^[11-12]作为一种特征提取技术,目的是设计一个基于波长特征的最优空间滤波器,依据信号分析的累积长度,可以进行信号复杂度的度量,具体步骤如下:

步骤1 将原始脑电信号进行处理

$$\Delta x = x^{2:N} - x^{1:N-1} \quad (14)$$

其中 x 为 CSP 的原始脑电输入信号, N 为信号的总采样点数, x^{ij} 代表信号矩阵从第 i 行到第 j 行,原始 WOSF 对信号矩阵进行行变换。

步骤2 计算空间滤波器,将 Δx 作为输入信号输入 CSP 中,重新使用公式(5)~(13),求取最佳空间滤波器。

步骤3 将滤波后的数据作为特征向量,使用 SVM 进行分类识别。

3.4 支持向量机

支持向量机(SVM)^[13]通过将低维度的信号映射到高维度的特征空间,从而实现将特征向量更好的分离,采用超平面进行数据的分类,例如二维平面数据使用一条直线即可划分,三维立体数据需使用二维平面进行划分,即 N 阶高维数据空间采用 $N-1$ 阶超平面进行划分。选取最优分类面时,既要求能够将数据正确分离。又要求分类间隔最大,即离超平面最近的数据点到超平面的距离应该尽可能的大^[14]。

SVM 分类性能主要受核参数和误差惩罚因子的影响,核参数影响数据空间投影的分布,而惩罚因子则决定了支持向量机的容错能力;因此对核参数和惩罚因子的选择很大程度上影响了脑电信号的识别率。本文采用网格搜索法确定惩罚因子和核参数,通过3折交叉验证的方法对训练数据进行网格搜索。

4 实验结果

4.1 EMD 预处理

由脑电信号的先验知识可知:大脑在进行运动想象时,所产生的信号频率主要集中于 30 Hz 以下,其中 5 Hz 以下,又多为伪迹信号,因此首先对脑电信号数据进行 8~30 Hz 的带通滤波预处理,之后选取一位受试者,对其脑电信号进行 EMD 分解。如图 3 所示:(a)进行左手想象 C3 通道 EMD 分解结构,(b)进行右手想象 C3 通道 EMD 分解结构。

表征运动想象的最突出节律为 μ 和 β 节律,两者的频带范围为 7~13 Hz 和 13~30 Hz,根据上述分解后的 IMF 频谱图,前两阶 IMF 包含 μ 和 β 节律频带范围,剩余的 IMF 则为低频信号,多为伪迹信号与噪声信号,因此本文选取前两阶 IMF 重构脑电信号,将其余的 IMF 舍弃。使用 EMD,不仅可以提取 μ 和 β 节律,还可以有效地达到去除无关信号的目的,增大信噪比。如图 4 所示:(a)左手运动想象 C3 通道原始脑电波形及频谱图,(b)重构后左手 C3 通道脑电波形及频谱图。如图 5 所

示:(a)右手运动想象 C3 通道原始脑电波形及频谱图,(b)重构后右手 C3 通道脑电波形及频谱图。

4.2 改进的 WOSF

在使用经验模态分解 EMD 之前,文章在进行原始数据提取时,进行了改动,提取左手实验数据的 C3、C4 通道数据,提取右手实验的 C3 通道数据,将 C3、C4 通道的数据进行分解,得到多个本征模态函数 IMFs,取其包含 μ 和 β 节律的前两阶作为新的输入信号,则相当于共有 2 个通道的数据,构成一个 2×2000 的矩阵 X_i ($i=L$ 表示想象左手运动, $i=R$ 表示想象右手运动),其中,2 为 IMF 数,可看作通道数,2000 为一次实验的采样点数。同时由于信号矩阵行数较少,使用改进后的 WOSF 对脑电信号进行处理: $\Delta x = x^{2:N} - x^{1:N-1}$,其中 x 为 CSP 的原始脑电输入信号, N 为信号的总采样点数, x^{ij} 代表信号矩阵从第 i 列到第 j 列,改进后的 WOSF 对信号矩阵进行列变换,同时保留矩阵第一列作为参考。因此文章中左手特征数据来自于 C3、C4 通道,而右手特征数据只来自于 C3 通道,将右手 C3 通道分别于左手 C3、C4 通道进行对比。

4.3 实验结果分析

将每次实验的 C3、C4 通道前两阶 IMF 分量合并成观察向量,为进一步验证观察向量对源空间位置区分的有效性,图 6(a)、(b)为受试者 01 左右手运动想象运动时,单次实验的脑电信号 EMD 分解后前两阶 IMF 分量的脑地形图,由图可见:在进行两类想象运动时,C3、C4 电极能量相差较大,同时想象左手运动时,C4 电极明显比 C3 电极活跃,想象右手运动时刚好相反,表现为 C3 电极比 C4 电极活跃,这与运动想象中按相关同步去同步特性刚好相符,由此说明,该特征可以有效表征出“源”的空间位置信息,可以作为分类特征。

本文方法中将原始脑电信号进行 EMD 分解之后,得到多个固有模态函数 IMF,结合最优波长滤波 WOSF,变换得到信号,再进行 CSP 空间滤波,采用 SVM 分类器进行分类。

首先,图 7(a)、(b)给出了 9 位受试单次实验(包含 120 组左右手想象运动)的分类正确率,图 7(c)给出了各个受试者的平均分类正确率以及总体的平均分类正确率;由图可见:9 位受试想像运动的所有实验平均分类准确度在 96.5%~98% 之间浮动,其中,受试 02 达到最高 98.01%;受试 03 最低为 96.53%,分析原因:一是采集数据不够准确有效,二是选取的 SVM 最优参数对该组数据并不是最优;但总体上,9 位受试所有实验平均分类准确度达到了 97.35%,可见本文方法具有较为有效且稳定的分类正确率。

其次,将本文方法与其他方法比较,如表 1 所示,列出了第三届 BCI 竞赛中成绩较好的三组,采用相同数据

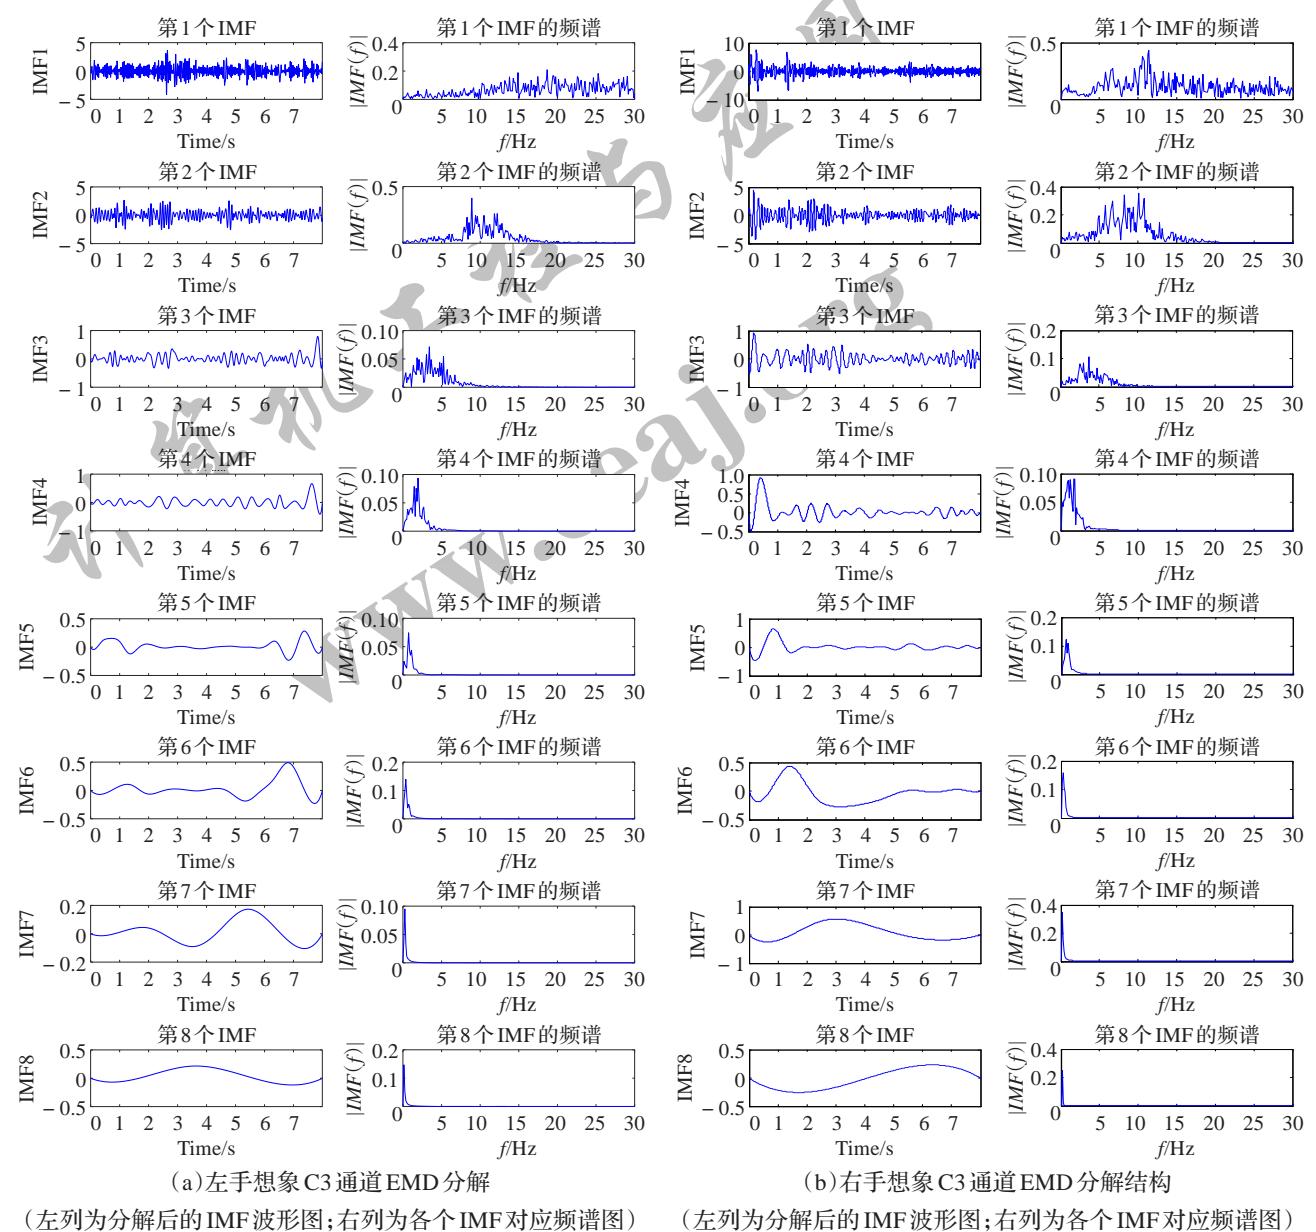


图3 想象左右手的EMD分解图

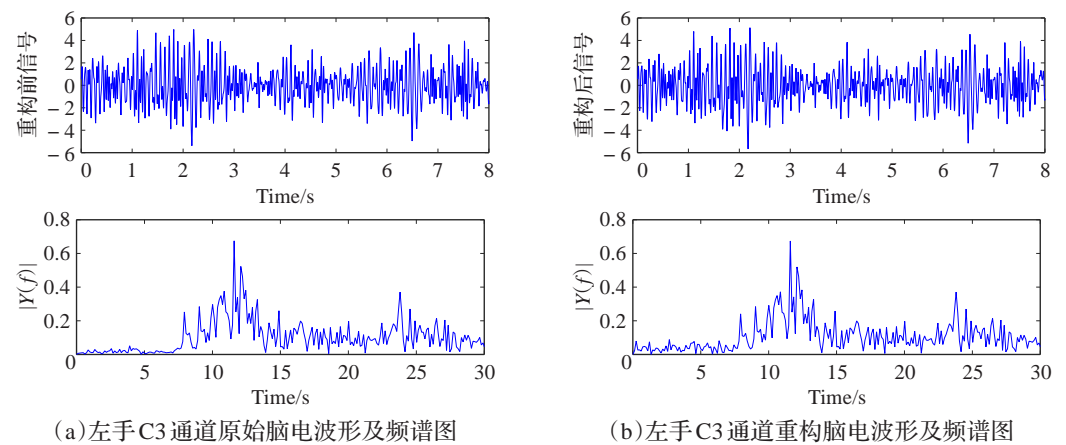


图4 重构前后左手C3通道脑电波形及频谱图

集的情况下,本文提出的方法的分类准确度高于其他三组;本文仅采用了C3、C4通道的信号进行分析,在保证一定分类准确度的情况下,大大减少了通道数,另外,如图8所示,9位受试所有实验的平均分类响应时间在1~1.5 s之间,由于计算复杂度增大,响应时间必然也随之增大。

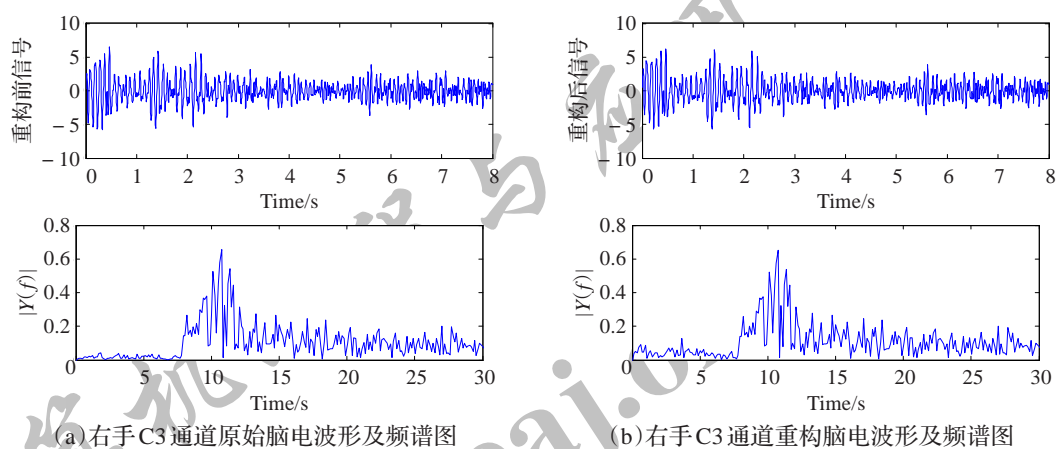


图5 重构前后右手C3通道脑电波形及频谱图

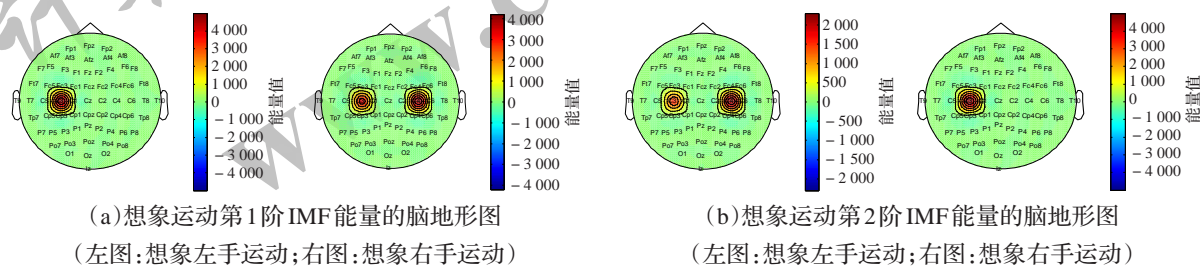


图6 想象运动前2阶IMF能量脑地形图




图7 平均分类准确率比较

表1 BCI竞赛成绩和本文结果比较			
特征提取方法	通道	分类器	结果/%
共域子空间分解+ Fisher 判别分析 ^[14]	64	支持向量机	91.00
频谱功率+小波系数 ^[15]	33	正则逻辑回归	87.00
频谱功率 ^[16]	—	逻辑回归	86.00
多变量经验模式分解+ 短时傅里叶变换 ^[17]	—	k-最近邻	90.71
本文方法	2	支持向量机	97.35

5 总结

传统的共空间模式适用于多通道数据,且缺少频域信息,本文提出了EMD和CSP相结合算法,信号经EMD模拟多通道,同时添加了EMD的频域信息,与此同时,采用WOSF对CSP输入信号做进一步优化处理。先将信号进行经验模式分解得到多个固有模态函数,选




图8 9位受试所有实验平均响应时间

取包含 μ 节律和 β 节律的固有模态函数,组合成多通道信息簇,利用WOSF对信息簇进行最优波长选择,将优化的信号矩阵经共空间模式滤波,提取特征,最后经支持向量机分类后得到所有9位受试平均分类正确率为97.35%,其中,最高的受试达到98.01%。但由于该方法

的计算复杂度较高,因此响应时间相较于延长,平均响应时间在1.5 s以内,最低平均响应时间为1.03 s。可见,改进的CSP算法,所需通道数较少,分类识别率较高,但响应时间较长。

参考文献:

- [1] Yang B, Li H, Wang Q, et al. Subject-based feature extraction by using fisher WPD-CSP in brain-computer interfaces[J]. Computer Methods & Programs in Biomedicine, 2016, 129: 21-28.
- [2] Önder A. Common spatial pattern-based feature extraction from the best time segment of BCI data[J]. Turkish Journal of Electrical Engineering & Computer Sciences, 2016, 24(5): 3976-3986.
- [3] Li M, Cui Y, Hao D, et al. An adaptive feature extraction method in BCI-based rehabilitation[J]. Journal of Intelligent & Fuzzy Systems Applications in Engineering & Technology, 2015, 28(2): 525-535.
- [4] Koles Z J. The quantitative extraction and topographic mapping of the abnormal components in the clinical EEG[J]. Electroencephalography & Clinical Neurophysiology, 1991, 79(6): 440.
- [5] Müller-Gerking J, Pfurtscheller G, Flyvbjerg H. Designing optimal spatial filters for single-trial EEG classification in a movement task[J]. Clinical Neurophysiology, 1999, 110(5): 787-798.
- [6] Ramoser H M J P G. Optimal spatial filtering of single trial EEG during imagined hand movement[J]. IEEE Transactions on Rehabilitation Engineering A Publication of the IEEE Engineering in Medicine & Biology Society, 2000, 8(4): 441.
- [7] 杨帮华, 陆文字, 何美燕, 等. 脑机接口中基于WPD和CSP的特征提取[J]. 仪器仪表学报, 2012, 33(11): 2560-2565.
- [8] Novi Q, Guan C, Dat T H, et al. Sub-band common spatial pattern (SBCSP) for brain-computer interface[C]// International IEEE/EMBS Conference on Neural Engineering, 2007: 204-207.
- [9] Davies S R, James C J. Novel use of empirical mode decomposition in single-trial classification of motor imagery for use in brain-computer interfaces[C]// Engineering in Medicine and Biology Society, 2013: 5610-5613.
- [10] Li M, Guo S, Yang J, et al. A novel EEG feature extraction method based on OEMD and CSP algorithm[J]. Journal of Intelligent & Fuzzy Systems, 2016, 30(5): 2971-2983.
- [11] Gupta S S, Soman S, Raj P G, et al. Improved classification of motor imagery datasets for BCI by using approximate entropy and WOSF features[C]// International Conference on Signal Processing and Integrated Networks, 2014: 90-94.
- [12] Lotte F. A new feature and associated optimal spatial filter for EEG signal classification: waveform length[C]// International Conference on Pattern Recognition, 2012: 1302-1305.
- [13] Leeb R, Lee F, Keinrath C, et al. Brain-computer communication: motivation, aim, and impact of exploring a virtual apartment[J]. IEEE Trans Neural Syst Rehabil Eng, 2007, 15(4): 473-482.
- [14] Wei Qingguo. Studies on classification algorithms of motor imagery-based brain-computer interfaces[D]. Beijing: Tsinghua University, 2006.
- [15] Ehrsson H H, Geyer S, Naito E. Imagery of voluntary movement of fingers, toes, and tongue activates corresponding body-part-specific motor representations[J]. Journal of Neurophysiology, 2003, 90(5): 3304-3316.
- [16] Blankertz B. Results of the BCI competition III[EB/OL]. (2005). <http://www.bbci.de/competition/iii/results>.
- [17] Bashar S K, Bhuiyan M I H. Classification of motor imagery movements using multivariate empirical mode decomposition and short time Fourier transform based hybrid method[J]. Engineering Science & Technology An International Journal, 2016, 19(3): 1457-1464.
- [14] Jin F F, Ni Z W, Chen H Y. Note on "Hesitant fuzzy prioritized operators and their application to multiple attribute decision making"[J]. Knowledge-Based Systems, 2016, 96: 115-119.
- [15] Tan C, Yi W, Chen X. Hesitant fuzzy Hamacher aggregation operators for multicriteria decision making[J]. Applied Soft Computing, 2015, 26: 325-349.
- [16] Xing Y, Zhang R, Xia M, et al. Generalized point aggregation operators for dual hesitant fuzzy information[J]. Journal of Intelligent & Fuzzy Systems, 2017, 33(1): 515-527.
- [17] 张美, 马盈仓. Frank三角范数的一类模糊逻辑系统的真度理论[J]. 计算机工程与应用, 2011, 47(2): 32-34.
- [18] Yager R R. On some new classes of implication operators and their role in approximate reasoning[J]. Information Sciences, 2004, 167(1): 193-216.
- [19] Qin J, Liu X, Pedrycz W. Frank aggregation operators and their application to hesitant fuzzy multiple attribute decision making[J]. Applied Soft Computing, 2016, 41: 428-452.
- [20] 王剑, 黄朝光, 王健, 等. 面向农业科学数据的分布式存储方法研究[J]. 计算机工程与应用, 2016, 52(11): 248-253.