

◎信号处理◎

改进的深度卷积网络及在碎纸片拼接中的应用

段宝彬^{1,2}, 韩立新²DUAN Baobin^{1,2}, HAN Lixin²

1. 合肥学院 数学与物理系, 合肥 230601

2. 河海大学 计算机与信息学院, 南京 211100

1. Department of Mathematics and Physics, Hefei University, Hefei 230601, China

2. College of Computer and Information, Hohai University, Nanjing 211100, China

DUAN Baobin, HAN Lixin. Improved convolutional neural networks and its application in stitching of scrapped paper. *Computer Engineering and Applications*, 2014, 50(9): 176-181.

Abstract: In recent years, deep convolutional networks are widely used in image recognition, speech recognition and natural language processing and other fields, which have achieved very good results. In this paper, in order to solve classification problems with all the samples being unlabeled data, deep convolutional neural network is improved and the corresponding learning algorithm is given, with the k -means clustering device replacing the classifier in deep convolutional network and adopting convolutional auto-encoder. The improved learning algorithm is used to solve the stitching of scrapped paper. The experiments show that, this method is effective and feasible, which improves the accuracy and robustness of the stitching of scrapped paper.

Key words: convolutional neural networks; k -means clustering; stitching of scrapped paper; convolutional auto-encoder; deep learning

摘 要: 近年来,深度卷积网络在图像识别、语音识别和自然语言处理等领域广泛使用,取得了很好的效果。为解决全部样本均为无标签数据的分类问题,对深度卷积神经网络进行了改进,采用卷积自动编码器学习输入样本的特征,用 k -均值聚类器代替深度卷积网络中的分类器,建立了改进的深度卷积网络结构,给出了相应的学习算法,将其用于解决碎纸片拼接问题。实验表明,该方法有效可行,提高了碎纸片拼接的准确性和鲁棒性。

关键词: 卷积神经网络; k -均值聚类; 碎纸片拼接; 卷积自动编码器; 深度学习

文献标志码: A **中图分类号:** TP301 **doi:** 10.3778/j.issn.1002-8331.1312-0134

1 引言

2006年以来,深度学习研究日益受到学术界、工业界的关注,已经在图像识别、语音识别、自然语言处理等方面获得广泛应用,Google、百度等著名的互联网公司开始投入大量资金和人力支持深度学习技术的研发。深度学习通过模拟人脑的分层模型结构,可以利用大量无标签样本数据,逐层提取输入数据从低层到高层的特征,并利用小部分的有标签数据进行网络参数的微调,从而可以学习得到输入数据更本质的特征^[1]。

卷积神经网络是由LeCun等^[2]于1989年首先提出的一种网络结构,在手写数字识别上取得了当时最好的结果。卷积神经网络将局部连接、权值共享和空间下采样结合起来,不仅大大减少了网络的训练参数,还使得学习得到的特征对输入样本的平移、缩放、扭曲保持不变性,从而提高了分类的鲁棒性。2012年,Alex Krizhevsky等^[3]将卷积神经网络的层次结构进一步加深,建立的深度卷积网络在著名的大型图像数据集ImageNet的分类问题中获得巨大成功。在这个深度卷积网络中,原始图

基金项目: 江苏省高校“青蓝工程”中青年学术带头人培养对象资助项目;合肥学院应用数学重点(建设)学科基金资助。

作者简介: 段宝彬(1975—),男,博士研究生,讲师,研究领域为机器学习,数据挖掘;韩立新(1967—),男,教授,博士生导师,研究领域为web技术,信息检索,模式识别,数据挖掘。E-mail: duanbb@126.com

收稿日期: 2013-12-10 **修回日期:** 2014-01-28 **文章编号:** 1002-8331(2014)09-0176-06

像的像素直接作为输入数据,不但解决了浅层学习结构需要人工提取图像特征的局限性问题,而且提高了分类的准确性和模型的泛化能力。

除了深度卷积网络之外,2006年由Hinton等^[4]提出的深度信任网络也是一种典型的深度学习网络。该网络主要是由多层限制玻尔兹曼机(RBM)组成的概率生成模型,使用贪婪算法逐层学习相邻两个RBM层间的初始参数,最后利用少量有标签数据对整个网络参数进行微调。另外,还出现了一些其他的深度学习网络结构,如去噪自编码器^[5]、稀疏自编码器^[6]等。

1967年,J.B.MacQueen^[7]提出的 k -均值聚类是基于划分方法解决聚类问题的一种经典算法,它的应用非常广泛。该算法的基本思想是基于某种距离对给定的数据样本进行聚类,使类内距离最小,类间距离最大,即使类内对象的相似度最大,不同类对象的相似度最小。设所给定 n 个样本的类别数为 k , k -均值聚类算法是先从样本集中随机选取 k 个样本作为初始聚类中心,对应 k 个类别,然后计算每个样本到聚类中心的距离,与它距离最小的那个距离中心对应的类就作为该样本所属的类。接下来计算每一类中所有样本的均值作为新的聚类中心,比较新的聚类中心与相邻的上一次聚类中心是否满足相应的收敛准则,若满足则聚类结束,否则重新计算每个样本与新的聚类中心的距离,根据计算结果决定是否调整样本类别,最后再根据调整后的样本重新计算聚类中心,如此迭代,直到满足收敛准则或达到规定最大迭代次数为止。

文档碎纸片拼接技术在司法物证鉴定、军事情报获取、历史文献修复等方面都有着广泛的应用。过去,碎纸片的拼接复原工作一般是由相关人员手工来完成,这样做虽然可以保证较高的准确率,但其效率却很低,尤其当碎纸片的数量巨大时,完全靠人工拼接很难完成复原任务,至少在短时间内难以完成。随着机器学习和模式识别技术的发展,人们试图开发碎纸片的计算机自动拼接技术,以提高拼接复原的效率。由于技术的局限性,对于复杂的文档碎纸片,完全利用计算机实现自动化拼接不太现实,在拼接过程中必须加入人工干预,以确保拼接的正确性^[8]。目前,碎纸片半自动拼接的常用方法是利用图像边缘检测技术等提取碎纸片的轮廓曲线,再根据边缘形状的相似度进行匹配^[9-10],但这种方法不太适合用于碎纸机等切出的边缘形状相同或相似的碎纸片。Cao等^[11]为解决来自多个不同照片的碎片拼接问题,同时利用碎片的形状和颜色等信息,通过构建候选匹配的加权图,并利用谱聚类方法将其划分成不同的子图,然后在每个加权子图中找出相应的最大生成树作为最可能的匹配,依最大生成树的构造次序作为碎片拼接顺序,并进行有效性检查,若拼接结果不理想,再按权重仅次于最大生成树的生成树进行拼接和有效性检查,

一般根据前几个权重较大的生成树就可以得到理想的拼接效果。

对于碎纸片拼接问题,首要的任务就是对大量的碎纸片进行分类,使得同一类的碎纸片可以拼接成一个较大的碎纸块,但在拼接完成前,碎纸片的类别标号并不知道。因此,碎纸片的分类是一个无监督学习问题,基于有监督学习的传统卷积神经网络结构并不能直接应用到碎纸片的分类中。碎纸片通常比较小,单个碎纸片所包含的信息相对偏少,从同一张印刷体文件上用碎纸机等切割下来的各碎纸片边缘相似性比较大,而且碎纸片图片中还存在噪声干扰和冗余信息,因此,使用传统的聚类分析方法,如 k -均值聚类等直接根据碎纸片边缘像素进行聚类通常难以得到满意的结果。由于深度卷积网络能够通过学习提取输入数据从低层到高层的本质特征,而且学习得到的特征对输入数据的畸变具有一定的容忍度,因此,本文尝试对深度卷积网络结构进行改进,采用堆栈卷积自动编码器,并用 k -均值聚类器代替深度卷积网络中的分类器,得到基于改进的深度卷积网络ICNN(Improved CNN),并将其用到碎纸片的分类问题中,从而可以充分发挥深度卷积网络自动学习输入数据本质特征的优势,有助于提高碎纸片分类的准确性和稳定性。实验结果表明,本文提出的ICNN对于碎纸片的拼接是有效可行的,提高了碎纸片拼接的效果。

2 深度卷积网络

2.1 深度卷积网络结构

一个典型的深度卷积网络结构^[12-13]如图1所示。




图1 深度卷积网络结构

深度卷积网络的第一层是输入层,接下来是若干个卷积层和下采样层,最后是一个分类器,如Softmax分类器等,由分类器输出相应的分类结果。通常,每一个卷积层后面都紧跟一个下采样层。在卷积层,利用局部连接和权值共享,可以减少网络的训练参数,降低计算的复杂性。通过卷积运算,得到的卷积结果通过Sigmoid等激活函数的输出得到这一层的特征图,然后作为下一层(下采样层)的输入。卷积层中每一个特征图不一定和前一层的所有特征图连接,而是连接其中的若干个。在下采样层,将前一层对应的特征图中相邻若干个特征通过池化操作(如平均池化或最大池化等)合并成一个

特征,以减小特征的分辨率,从而实现对平移、缩放、扭曲的不变性。输入的图像数据可以直接传送到第一个卷积层,进行逐层特征学习,最后利用有标签样本数据输入到 Softmax 等分类器,通过后向反馈微调整个网络的参数。

2.2 深度卷积网络的学习算法

卷积神经网络的学习过程如图2所示,主要包括卷积层的学习和下采样层的学习。




图2 卷积神经网络的学习过程

2.2.1 卷积层的学习

在一个卷积层中,用一个可学习的卷积核与上一层的若干个特征图进行卷积,然后通过一个激活函数 f ,如 Sigmoid 函数等,利用公式(1)就可以得到相应的输出特征。

$$h_j^k = f\left(\sum_{i \in M_j} h_i^{k-1} * W_{ij}^k + b_j^k\right) \quad (1)$$

其中 k 表示层数, W 是卷积核, $*$ 表示2维卷积, b 是偏置, M_j 表示所选择的输入特征图的集合。

2.2.2 下采样层的学习

下采样层进行池化操作,其特征图的个数与相邻前一层卷积层特征图的个数相同,但特征图变小,输出的特征可用公式(2)计算。

$$h_j^k = f(\text{down}(h_i^{k-1}) \cdot \omega_j^k + b_j^k) \quad (2)$$

其中 ω 是相应的权值, b 是相应的偏置, $\text{down}(\cdot)$ 是相应的下采样函数^[12],如果对输入特征图的 $p \times p$ 的块特征值求平均值或最大值等,这样输出特征图在两个维度上都缩小了 p 倍。

对于深度卷积网络,采用由前到后逐层学习的方式。所有卷积层和下采样层学习结束后,利用有标签数据输入网络,并将学习得到的特征输入分类器,通过 BP 算法对整个网络的训练参数进行微调。

3 改进的深度卷积神经网络及其学习算法

3.1 改进的深度卷积神经网络结构

为了使深度卷积网络适合无标签样本的分类问题,将其各卷积层改造为卷积自动编码器,并将输出层前面

的分类器,如 Softmax 分类器等用 k -均值聚类器来代替,得到改进的深度卷积网络(ICNN)结构,如图3所示。




图3 ICNN 结构

3.2 ICNN 的学习算法

3.2.1 卷积自动编码器

设某卷积层共有 H 个特征图,第 k 个特征图的权矩阵为 W^k ,偏置为 b^k ,采用的激活函数为 f ,如本文实验中的 Sigmoid 函数等,用输入图像 x 训练卷积层的神经元,得到第 k ($k=1, 2, \dots, H$) 个特征图:

$$h^k = f(x * W^k + b^k) \quad (3)$$

其中 $*$ 表示2维卷积。然后通过解码器,即利用公式(4)得到特征图式(3)的重构。

$$\hat{x} = f\left(\sum_{k=1}^H h^k * \overline{W}^k + c\right) \quad (4)$$

其中 \overline{W}^k 表示第 k 个特征图的权矩阵 W^k 的转置, c 为相应的偏置。

目标函数是最小化重构误差函数:

$$E(W, b) = \|\hat{x} - x\|^2 \quad (5)$$

采用与 BP 神经网络类似的误差反向传播算法,利用公式(6)来计算目标函数的梯度值。

$$\frac{\partial E(W, b)}{\partial W^k} = x * \delta h^k + \tilde{h}^k * \delta \hat{x} \quad (6)$$

其中 δh 和 $\delta \hat{x}$ 分别表示卷积层和重构层的残差。最后可以利用随机梯度下降法来更新权值^[14]。

3.2.2 k -均值聚类中最佳聚类数的确定

在 k -均值聚类中,必须事先给定类别数 k , k 对聚类结果的准确性至关重要。本文采用基于样本几何结构的 BWP 指标^[15-16]来进行聚类结果的有效性比较,通过搜索得到最佳聚类数 k_{opt} 。具体过程如下:首先确定最佳聚类数 k_{opt} 的搜索范围 $[k_{\min}, k_{\max}]$,根据普遍的聚类经验规则,通常 k_{\min} 取2, k_{\max} 为对样本数平方根取整后的值;接着循环对搜索范围内的 k ,进行 k -均值聚类,根据聚类结果利用公式(7)计算 BWP 指标值:

$$BWP(k) = \frac{1}{n} \sum_{i=1}^k \sum_{j=1}^{n_i} \frac{\min_{1 \leq m \leq k, m \neq i} \left(\frac{1}{n_m} \sum_{p=1}^{n_m} \|x_p^{(m)} - x_j^{(i)}\|^2 \right) - \frac{1}{n_i - 1} \sum_{q=1, q \neq j}^{n_i} \|x_q^{(i)} - x_j^{(i)}\|^2}{\min_{1 \leq m \leq k, m \neq i} \left(\frac{1}{n_m} \sum_{p=1}^{n_m} \|x_p^{(m)} - x_j^{(i)}\|^2 \right) + \frac{1}{n_i - 1} \sum_{q=1, q \neq j}^{n_i} \|x_q^{(i)} - x_j^{(i)}\|^2} \quad (7)$$

其中 i, m 表示类别, $x_j^{(i)}$ 表示第 i 类的第 j 个样本数据向量, n_m 表示第 m 类的样本数据个数。最后选择使 $BWP(k)$ 值最大的 k 作为最佳聚类数 k_{opt} 。

3.2.3 ICNN 的学习算法步骤

以图 3 所示两个卷积层、两个下采样层的 ICNN 为例,本文所提出的 ICNN 网络的学习算法主要步骤如下:

步骤 1 采用 ZCA 白化方法对输入小图片 x 进行预处理,得到输入小图片 x 的低冗余性表示 \tilde{x} 。

步骤 2 用预处理过的输入数据 \tilde{x} 输入网络的第一个卷积层(C1),利用卷积自动编码器训练得到最优权值,并将其代入公式(3)得到第一个卷积层的特征图 h^1 。

步骤 3 将第一层卷积的特征图 h^1 进行下采样,每相邻 $p \times p$ 个点下采样为一个点,取其平均值作为下采样后的特征值,从而得到第一个下采样层(S2)的特征图 h^2 。

步骤 4 将第一个下采样层(S2)的特征图 h^2 作为第二个卷积层(C3)的输入,利用卷积自动编码器继续训练,将训练得到的权值代入公式(3)得到第二个卷积层的特征图 h^3 。

步骤 5 将第二个卷积层(C3)的特征图 h^3 进行下采样,每相邻 $p \times p$ 个点下采样为一个点,取其平均值,得到第二个下采样层(S4)的特征图 h^4 。

步骤 6 将第二个下采样层(S4)的特征图 h^4 进行格式转换,得到相应的特征矩阵,每一行对应一个输入样本数据,利用 3.2.2 节的方法确定最佳聚类数,通过 k -均值聚类得到相应的聚类结果。

3.3 相关工作的比较

CNN 和本文提出的 ICNN 网络都是依次采用卷积层和下采样层将前一层的输出作为相邻的后一层的输入,都是利用逐层贪婪算法对网络参数进行训练的,都具有局部连接、权值共享、空间下采样的特点,得到输入数据从低层到高层的特征,并且学习得到的特征对输入数据的平移、缩放和扭曲具有不变性。

CNN 和本文提出的 ICNN 网络的不同点是 CNN 的后半部分采用的 Softmax 等分类器,需要利用有标签数据进行训练,可以利用后向反馈策略微调整个网络的参数;而 ICNN 采用卷积自动编码器,利用最小化重构误差调整网络权值,后半部分采用 k -均值聚类,对输入全部为无标签数据的情形比较适合。

与其他无监督学习算法比较,本文提出的 ICNN 网络学习算法由于先采用卷积自动编码器,学习获取输入数据图像的本质特征,该特征对输入数据的平移、缩放和扭曲具有不变性,从而可以得到更稳健的聚类结果。

4 实验及结果分析

本文实验是基于 Win7 64 操作系统,CPU 为 Intel

I5-2450M, 2.5 GHz,内存为 6 GB,所用软件为 Matlab 2013a。

4.1 文档碎纸片实验

文档碎纸片为同一页印刷文字文件用碎纸机通过既纵切又横切得到的 11×19 个碎片,均为 bmp 格式的图像文件,分别用 0~208 编号,大小为 180 像素 \times 72 像素,部分碎纸片如图 4 所示。



图4 部分文档碎纸片

实验可分为三个部分:(1)特征学习;(2) k -均值行聚类;(3)行聚类结果的微调。

(1)特征学习

实验时首先从每个大小为 180×72 碎纸片的图像中随机抽取 500 张 6×6 的小图片,共得到 104 500 张小图片,构成学习最低层局部特征的小图片集合。在将这些小图片输入卷积神经网络之前先用 ZCA 白化方法对其进行预处理,消除图像中相邻像素之间的冗余性。随机抽取的部分原始小图片和 ZCA 白化后的对应小图片分别如图 5 和图 6 所示。




图5 随机抽取的部分原始小图片




图6 ZCA 白化后的对应小图片

利用 ICNN 的学习算法训练网络,经过所有卷积层和下采样层,习得的特征经 ZCA 白化处理后如图 7 所示。




图7 习得的白化处理后特征

(2)特征的k-均值行聚类

利用 3.2.2 节的方法得到最佳聚类数 $k_{opt} = 11$,为减少随机初始化聚类中心对聚类结果的影响,采用 10 次 k-均值聚类,对学习到的特征进行行聚类,取其中迭代目标函数值最小的结果作为最终聚类结果,如图 8 所示(图中数字为文档碎纸片图像编号)。

依据最终的拼接结果,和其他方法进行比较,如表 1 所示。

由实验结果可见,k-均值聚类算法运行时间最短,但分类效果最差,本文所提出的只含一个卷积层和一个下采样层的 ICNN(浅层)次之,而本文所提出的含两个卷积层和两个下采样层的 ICNN(深层)网络虽然训练时间稍微长些,但较好地提高了对碎纸片的分类性能。相对其他两种方法,可以大大减少后续拼接中人工干预的次数和时间。

(3)行聚类结果的微调

利用 ICNN 网络对碎纸片按行聚类之后,结果有个别行的碎片数大于或小于 19,需要试拼接等进行人工微调,直到所有行的碎片数均恰好是 19 为止,最终得到经微调后的行聚类结果如图 9 所示(图中数字为碎纸片图像编号)。

最后根据图 9,先逐行按相似度匹配横向拼接成行碎片块,再将各行碎片块纵向拼接,即可得到复原后的碎片原文件,如图 10 所示。

表1 ICNN行聚类结果

方法类型	运行时间 /min	类内仅为同一行所有碎片的 类别数所占百分比/(%)	类内均为同一行碎片的 类别数所占百分比/(%)	最少须重新调整类别的 碎片数所占百分比/(%)
k-均值聚类	1	36.36	72.72	13.88
ICNN(浅层)	10	45.45	72.72	10.53
ICNN(深层)	15	63.63	81.81	1.91

16	21	66	106	109	110	139	145	150	157	173	181	184	187	197	204						
4	13	30	40	89	101	102	108	113	114	117	119	123	125	140	146	151	154	155	185	194	207
5	10	29	37	44	48	55	59	64	75	92	98	104	111	171	172	180	201	206			
1	18	23	26	41	50	62	76	86	87	100	120	142	147	168	179	191	195				
6	19	20	36	52	61	63	67	69	72	78	79	96	99	116	131	162	163	177			
8	9	24	25	35	38	46	74	81	88	103	105	122	130	148	161	167	189	193			
15	17	27	33	60	71	80	83	85	132	133	152	156	165	170	182	198	200	202	205		
3	12	14	31	39	51	73	82	107	115	128	134	135	159	160	169	176	199	203			
34	42	43	47	58	77	84	90	94	97	112	121	124	127	136	144	149	164	183			
0	7	32	45	53	56	68	70	93	126	137	138	153	158	166	174	175	196	208			
2	11	22	28	49	54	57	65	91	95	118	129	141	143	178	186	188	190	192			

图8 ICNN行聚类结果

2	11	22	28	49	54	57	65	91	95	118	129	141	143	178	186	188	190	192		
6	19	20	36	52	61	63	67	69	72	78	79	96	99	116	131	162	163	177		
1	18	23	26	30	41	50	62	76	86	87	100	120	142	147	168	179	191	195		
8	9	24	25	35	38	46	74	81	88	103	105	122	130	148	161	167	189	193		
15	17	27	33	60	71	80	83	85	132	133	152	156	165	170	198	200	202	205		
3	12	14	31	39	51	73	82	107	115	128	134	135	159	160	169	176	199	203		
34	42	43	47	58	77	84	90	94	97	112	121	124	127	136	144	149	164	183		
13	16	21	66	106	109	110	125	139	145	150	157	173	181	182	184	187	197	204		
5	10	29	37	44	48	55	59	64	75	92	98	104	111	171	172	180	201	206		
0	7	32	45	53	56	68	70	93	126	137	138	153	158	166	174	175	196	208		
4	40	89	101	102	108	113	114	117	119	123	140	146	151	154	155	185	194	207		

图9 调整后的行聚类结果



图10 拼接复原后的文档碎纸片

4.2 图像碎纸片实验

图像碎纸片为三张512像素×512像素的图像文件通过既纵切又横切得到的,每个图像包含2×8个碎片,均为bmp格式,共48个碎片,分别用0~47编号,大小为64像素×256像素,部分图像碎纸片如图11所示。



图11 部分图像碎纸片

实验步骤与4.1节中文档碎纸片实验完全类似,采用两层卷积神经网络进行特征学习,取最佳聚类数为3。为节省篇幅,下面仅给出利用本文所提算法与直接采用k-均值聚类方法得到的实验结果进行比较,如表2所示。

表2 两种不同图像碎纸片聚类算法结果对比				
方法类型	运行时间/s	需对聚类结果人工微调的类别数	聚类结果正确的碎片数	聚类结果正确率/(%)
k-均值聚类	9	3	9	60.42
本文所提算法	47	1	9	81.25

由实验结果可见,k-均值聚类算法运行时间短,但聚类效果不理想,本文所提出的ICNN网络算法虽然运行时间稍微长些,但较好地提高了对图像碎纸片的聚类效果,聚类结果正确率高,后续拼接中人工干预少。

对少量聚类错误的图像碎纸片人工微调后得到三

组碎纸片,分别对应每一张原始图像的所有碎片,再利用最大生成树匹配算法^[11]得到每一组图像碎片的拼接顺序,并进行有效性检查,最终得到复原后的原始图像,如图12所示。



图12 拼接复原后的图像碎纸片

5 结束语

本文对深度卷积网络结构进行了改进,采用卷积自动编码器,并用k-均值聚类器取代CNN后半部分的分类器,建立了可用于无标签数据分类的改进网络结构,并给出了其学习算法ICNN,最后将其用于碎纸片的分类问题中,取得了较好的分类效果。

此外,由于软硬件限制,本文只采用了含两个卷积层两个下采样层的改进深度卷积网络进行实验,进一步加深网络层数是否能显著提高无标签数据集的分类效果还有待进一步研究。本文只是利用原始碎纸片数据自学习得到的特征进行k-均值聚类,若同时考虑其他相关先验信息,可能会进一步提高碎纸片的分类效果,这些问题都有待进一步研究。

参考文献:

[1] 余凯,贾磊,陈雨强,等.深度学习的昨天、今天和明天[J].计算机研究与发展,2013,59(12):1799-1804.

[2] LeCun Y, Boser B, Denker J S, et al.Backpropagation applied to handwritten zip code recognition[J].Neural Computation,1989,1(4):541-551.

[3] Krizhevsky A,Sutskever I,Hinton G E.ImageNet classification with deep convolutional neural networks[C]//Neural Information Processing Systems Conference and Workshop (NIPS),Lake Tahoe,Nevada,2012:1106-1114.

[4] Hinton G E,Osindero S,Teh Y W.A fast learning algorithm for deep belief nets[J].Neural Computation,2006,18(7):1527-1554.

[5] Vincent P,Larochelle H,Lajoie I,et al.Stacked denoising autoencoders:learning useful representations in a deep network with a local denoising criterion[J].Journal of Machine Learning Research,2010,11(12):3371-3408.

[6] Nayak N,Chang H,Borowsky A,et al.Classification of tumor histopathology via sparse feature learning[C]//The 10th International Symposium on Biomedical Imaging (ISBI).San Francisco:IEEE,2013:410-413.

(下转270页)