

深度学习算法在问句意图分类中的应用研究

杨志明^{1,2,3}, 王来奇³, 王泳²

1. 中国科学院 软件研究所, 北京 100190

2. 中国科学院大学, 北京 100049

3. 深思考人工智能机器人科技(北京)有限公司, 北京 100085

摘要:在聊天机器人多轮对话中如何根据上下文理解用户的意图是多轮交互中的一个重点问题,也是一个难点问题。现有的问句理解方法大多是针对单句的,且侧重于某种句式结构的理解。如何根据上下文语境对当前用户的意图进行识别,而不仅仅是针对单轮进行一个个分析,使得对话在一个连续的语境下具备细粒度的理解能力,是一个亟待解决的问题。针对以上问题,提出了一种基于深度学习的自然语言问句多意图分类方法,其中涉及到的用户意图包含闲聊类、音乐类、新闻类、算术类、餐饮类、订票类、天气类、服务类等13类。首先使用自然语言处理的相关技术对多轮对话进行处理分析,识别出其中的关键词,然后使用深度学习方法和分层分类技术构建了二分类和多分类深度学习模型,学习上下文语境和语义关系,共同对用户意图进行识别。通过实验证明了构建的深度学习模型对用户意图识别的准确率分别为94.81%、93.49%。因此,所提方法基本能够解决自然语言问句意图识别的问题。

关键词:意图识别;自然语言处理;深度学习;分类

文献标志码:A **中图分类号:**TP312 **doi:**10.3778/j.issn.1002-8331.1802-0213

杨志明,王来奇,王泳.深度学习算法在问句意图分类中的应用研究.计算机工程与应用,2019,55(10):154-160.

YANG Zhiming, WANG Laiqi, WANG Yong. Application research of deep learning algorithm in question intention classification. Computer Engineering and Applications, 2019, 55(10): 154-160.

Application Research of Deep Learning Algorithm in Question Intention Classification

YANG Zhiming^{1,2,3}, WANG Laiqi³, WANG Yong²

1. Institute of Software, Chinese Academy of Sciences, Beijing 100190, China

2. University of Chinese Academy of Sciences, Beijing 100049, China

3. iDeepWise on Artificial Intelligence Robot Technology(Beijing) Co., Ltd., Beijing 100085, China

Abstract: How to understand a user's intention according to the context in multi-round chatting robots is a key and difficult issue. Most existing questions-understanding methods are for a single sentence, and focus on the understanding of a sentence structure. It is an urgent problem to be solved that how to identify the current user's intention according to the context instead of analyzing each single round individually, which can make the dialogue have fine-grained understanding ability in a continuous context. In order to solve the above problems, this paper presents a method of multi-intention classification of natural language questions based on deep learning. The user intents include 13 categories, such as chatting, music, news, arithmetic, catering, booking, weather, service categories and so on. Firstly, this paper uses the technology of natural language processing to process and analyze multi-round dialogues, identifies the key words therein, and then constructs the dichotomous and multi-category deep learning model to learn contexts by using the deep learning method and the hierarchical classification technology, they are both used to identify user's intention. Experiments show that the accuracy rate of user intention recognition with constructed deep learning model is 94.81% and 93.49% respectively. Therefore, the proposed method can basically solve the problem of understanding a user's intention with natural question language.

Key words: intent identification; natural language processing; deep learning; classification

作者简介:杨志明(1978—),男,博士研究生,主要研究领域为机器学习、深度学习、自然语言处理;王来奇,男,硕士,主要研究领域为机器学习、自然语言处理;王泳,通讯作者,男,博士,主要研究领域为模式识别、自然语言处理, E-mail: wangyong@ucas.ac.cn.

收稿日期:2018-02-27 **修回日期:**2018-04-09 **文章编号:**1002-8331(2019)10-0154-07

CNKI网络出版:2018-09-14, <http://kns.cnki.net/kcms/detail/11.2127.TP.20180913.0626.002.html>

1 引言

自然语言处理(Natural Language Processing, NLP)与自然语言理解(Natural Language Understanding, NLU)研究如何让计算机理解自然语言的语义,并运用自然语言与人交流,实现人机对话。因此,自然语言理解系统又叫自然语言问答系统(Question Answering System),简称问答系统(QA System)^[1]。问答系统是信息检索系统中的一种高级形式,主要包含三部分:问题理解、信息检索和答案抽取。用户使用自然语言的表达方式向问答系统提出问题,问答系统返回简洁准确的答案^[2-3]。其中,问题语义理解是问答系统中的核心任务,是提升问答系统整体性能的关键所在^[4-6]。问句理解的功能是通过确定问题答案的类别,从而为信息检索过程提供约束条件,缩小答案的查找范围,提高问答系统的准确率。Moldovan等^[7]学者曾研究过问答系统中各部分对系统性能的影响,其中问句意图分类对系统的影响最大。因此,为了得到一个好的问答系统,需要设计一个高准确率的问句意图分类器。

问句理解属于NLP领域的问题,一直都是NLP领域中非常热的一个研究方向,主要是通过NLP的相关技术对自然语言问句进行意图分类。最近几年,深度学习技术在NLP中得到了广泛的应用,并取得了较好的效果。比如2010年Mikolov等人^[8]设计了一种基于RNN(Recurrent Neural Network)的语言模型,相比于基于统计的语言模型,神经网络模型在多方面任务上取得了较大的突破。2014年Sutskever等人^[9]通过使用两个多层的长短期记忆网络(Long Short-Term Memory, LSTM)把输入句子映射成目标句子,该方法在机器翻译上得到了较好的效果。还有许多研究者在基于深度学习的自然语言问句分类任务上做了相关研究,并取得了突破性的进展。

现有的问句理解框架主要是解决单一领域的简单问句的理解和分析问题,比如音乐类、旅游类等单一领域简单问句的理解。针对上述问题本文提出了一种理解涉及多领域的基于深度学习的自然语言问句意图分类方法。利用Bagging的思想,把构建的两个深度神经网络模型进行集成,共同来解决自然语言问句意图分类的任务。此外还尝试了使用传统的机器学习方法如K最近邻算法(K-Nearest Neighbor, KNN)、逻辑回归算法(Logistic Regression, LR)以及集成模型如XGBoost、AdaBoost等进行了对比实验。目前对于基于深度学习的自然语言问句意图分类的研究方法还比较少,在该领域还有很大的研究空间。因此本研究方向具有较好的前景,对于促进人机交互方式的发展具有重要意义,是一个值得深入探索的研究课题。

2 相关工作

自然语言问句分类就是理解问句的意图,为问句赋予一个类别标签,确定问句所属的领域,方便业务进行处理。自然语言问句意图理解是聊天机器人系统中的核心技术,从1999年开始在一年一次的文本信息检索会议上(Text Retrieval Conference, TREC),自动问答系统主题一直是备受关注的主题之一,越来越多的工作者开始从事自然语言问句分类的相关研究。如今,国内外学者对于自然语言问句意图理解已经做了大量的相关研究。如:郭健等^[10]在解决句子理解的问题时通过找出含有事件信息的句子中的疑问焦点块、问题主题块、问题事件块来辅助句子的理解。马莉等提出了句子的模式匹配和关键词相结合的方法,改进了以前仅用模式匹配问句理解的方法。Li等^[11]把句子的依存关系和特征模板结合起来理解问句。Oliveira等^[12]将自然语言问句拆分为线索和子线索两部分,然后通过线索找到答案。经过调研发现,目前对于该问题的研究方法主要分为三大类:(1)基于规则的问句意图分类解决方法;(2)基于机器学习的问句意图分类解决方法;(3)基于混合模式的问句意图分类方法。

2.1 基于规则的自然语言问句意图分类研究

基于规则的问句意图分类解决方法是通过预先定义类别信息的启发式规则对自然语言问句意图进行分类^[13]。该方法通常根据预先定义好的规则构建一个基于规则的分类器。在分类器中利用提前定义好的规则来获取问句的关键词,并依据关键词来理解自然语言问句的意图,达到分类的目的。基于规则的问句意图分类方法在解决相同领域的问句时具有较好的分类效果,但是该方法具有相当大的局限性。首先,为了得到较好的实验结果,往往需要定义大量的规则,而这些规则都需要手工进行标注才可以得到,当语料数量很大时,需要耗费大量的人力^[14]。其次,对于同一类型的自然语言问句,可能会有多种表达方式。针对这种现象Li等人^[15]进行了相关论证,得出的结论是这种现象会导致规则数目随着句子数量的增加而急剧增加。再者就是构建大部分规则并没有泛化的能力,通过分析一个领域的语料构建的规则只能够用在与该领域相似的数据集上,用在其他领域或其他数据集上效果将会很差。因此,很难构建出一个通用的具有泛化作用的规则框架^[16]。

2.2 基于机器学习的自然语言问句意图分类研究

最近几年,对于基于机器学习的自然语言问句意图分类的研究比较多,是目前研究的热点。机器学习是人工智能领域的一种学科,就是让计算机在非精确编程的情况下做出正确反应的科学方法。近年来,国内外科研工作者针对基于机器学习的方法在生活中的应用进行了大量的研究。例如机器学习技术在语音识别、人脸识

别、无人驾驶、机器翻译等领域的应用。基于机器学习的自然语言问句意图分类方法主要是有监督的机器学习方法。有监督的机器学习方法是用带标签的语料训练分类模型,得到分类器。不同的分类模型主要是在特征提取方法和问题分类器上存在差别。目前,有监督学习的分类模型主要有LR、支持向量机(Support Vector Machine, SVM)、随机森林(Random Forest, RF)以及深度神经网络(Deep Neural Network, DNN)等。

深度学习是机器学习的子领域,是使用深度神经网络实现的一种机器学习方法。神经网络模型由一系列的基本的神经元相互连接而成,是通过对人类大脑的神经网络模拟构建的一种人工系统,通过学习将信息存储在神经网络当中。随着DNN技术在图像处理、语音识别等领域取得的进展和突破,许多研究人员开始把DNN技术应用在NLP领域中。最近几年,深度神经网络技术在自然语言处理任务中得到了广泛的应用,并取得了很好的效果^[17]。国内外学者都针对基于深度学习的方法在自然语言问句意图分类任务上进行了相应的研究。2014年, Kim^[18]在训练的词向量的基础上研究了卷积神经网络(Convolutional Neural Network, CNN)模型在自然语言问句分类上的应用; Kalchbrenner等人^[19]构建了一种动态卷积神经网络(Dynamic Convolutional Neural Network, DCNN)模型,用于模拟句子的语义信息,从而对自然语言问句进行分类。2015年, Mou等人^[20]依据句子的依存句法树和成分树构建了一种基于树的卷积神经网络(Tree-based Convolutional Neural Network, TBCNN),该模型提取了句子的结构特征,并采用最大池化方法(Max-pooling)对多种特征进行了融合。2016年, Komninos等人^[21]研究了word embedding对深度神经网络的影响,他们发现在自然语言问句多意图分类的实验中采用基于上下文的词嵌入可以获得较好的实验效果。另外还有学者采用基于语言模型的方法, 2007年Merkel等人^[22]使用贝叶斯分类器在基于语言模型生成自然语言问句的过程中对问句进行分类。

2.3 基于混合模式的自然语言问句意图分类研究

最近几年有些学者采用把多个分类模型进行集成

的方法来处理自然语言问句分类的任务。2008年, Xin等人^[23]在四种不同的特征上分别训练四个不同的SVM分类器,然后运用模型融合的方法把四个分类器集成在一起,分别使用Adaboost算法^[24]、神经网络算法与TBL(Transformation-Based Error-Driven Learning)算法^[25]进行了测试。Li等人^[26]在2008年提出了一种SVM和条件随机场模型(Conditional Random Field, CRF)相结合的策略^[27],把句子看成一个序列,首先使用CRF对自然语言问句中的每个词语添加标记,然后使用SVM分类器对自然语言问句进行分类。

3 算法流程

在整个自然语言问句意图理解分类项目中,算法流程主要包含输入、数据预处理、特征工程、模型训练、意图输出等过程。在每个流程中需要用到的技术以及要做的工作等详细内容如图1所示。

3.1 数据分析

每天人们都会面对各种类型的数据,如图像、文本、音频、视频等。显示世界中的数据大体上都是一些不完整、不一致的脏数据,无法直接用于数据挖掘或挖掘的结果差强人意。为了提高挖掘的质量,在实验之前需要对数据进行相应的预处理操作。数据预处理的方法有很多,如数据清洗、数据变换、数据集成、数据规约等。

3.1.1 数据预处理

在实验过程中,对数据集进行缺失值处理、错误字符纠正、相同类别数据合并等数据清洗操作,共获得53 117条样本,13个类别。通过预处理操作可以大大提高数据挖掘的质量,降低数据挖掘的时间。

3.1.2 数据分词

在使用深度学习技术解决文本意图分类任务过程中,中英文数据较大差别就在于中文需要做自动分词。目前,相关工具包已经有很多,如Jieba分词工具包、哈工大的LTP、北理工的ICTCLAS等。在实验过程中,本文使用Jieba分词工具对53 117条样本进行分词操作。

3.1.3 数据编码

由于构建的模型是针对数值进行计算的,从而对于

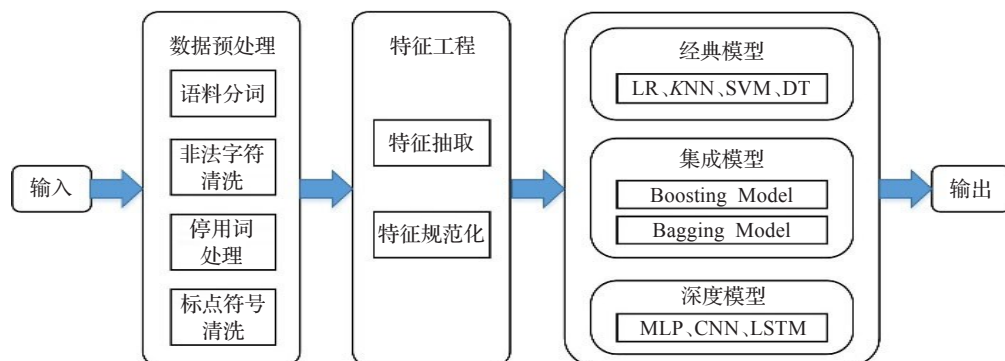


图1 算法流程框架

语料中的字符串类型需要转化成数值类型,主要使用的方法有:自己定义映射规则进行转化,使用LabelEncoder方法把字符串类型的数据转化为整型。针对无序的字符串,使用LabelEncoder方法是不合适的,因此本文会使用OneHotEncoder编码技术把没有顺序的特征值使用一个二进制数字进行表示。

3.1.4 数据规范化

在训练模型之前总是需要预先处理数据,这是一个必要的步骤。并且不同的算法对数据的要求不一样,需要进行不同的转换。许多机器学习算法性能会与数据的规模有关,常用的归一化方法有Normalizer,使每条数据各特征值的和为1。

$$\|X\|_p = (\sum_{i=1}^n |x_i|^p)^{\frac{1}{p}} \tag{1}$$

StandardScaler方法使得特征的均值为0,方差为1。

$$\chi_{std}^{(i)} = \frac{\chi^{(i)} - \mu_{\chi}}{\sigma_{\chi}} \tag{2}$$

3.2 特征工程

3.2.1 特征抽取

特征抽取是数据挖掘任务最为重要的一个环节,一般而言,它对最终结果的影响要高过数据挖掘算法本身。只有先把现实用特征表示出来,才能借助数据挖掘的力量找到问题的答案。特征选择的另一个优点在于:降低真实世界的复杂度,模型比现实更容易操纵。

在实验过程中对53 117条样本进行信息提取尝试的方法有:(1)CountVectorizer方法将文本转换为每个词出现的个数的向量;(2)使用TF-IDF(Term Frequency-Inverse Document Frequency)技术将文本转换为TF-IDF值的向量;(3)使用Google公司开源的word2vec技术将文本转化为词向量的形式^[28]。通过对比分析这三种方法发现前两种方法抽取的特征数据比较稀疏,维度比较高,没有考虑句子中的语序关系,最终选用word2vec技术进行特征抽取,把句子转化为连续、低维的词向量进行实验。

3.2.2 特征降维

主成分分析算法(Principal Component Analysis, PCA)的目的是找到能用较少信息描述数据集的特征组合,旨在发现彼此之间没有相关性、能够描述数据集的特征,确切地说这些特征的方差与整体方差没有多大差距,这样的特征被称为主成分。也就意味着,借助这种方法,能通过更少的特征捕获到数据集的大部分信息。运用PCA技术,依据方差解释率(Variance Explained Ration)对特征进行压缩,依据方差解释率与特征的主要成分之间的关系,从数据集中抽取方差解释率占95.38%的特征用于模型训练。使用该技术具有如下三方面的优点:(1)减少过拟合;(2)提高准确率;(3)减少模型训练时间。

3.3 数据不平衡

由于每个类别对应的数据量是不同的,而且差距挺大,这就是严重的数据不平衡问题,该问题会引起准确率悖论。解决该问题的常用方法是采样技术,采样技术分为上采样(over-sampling)和下采样(under-sampling),其中SMOTE是over-sampling中比较常用的一种。SMOTE算法的思想是对少数样本进行分析,并根据少数样本本人工合成新样本,具体操作流程如下:

(1)对于少数类中每一个样本 x ,以欧氏距离为标准计算它到少数类样本集中所有样本的距离,得到其 k 近邻。

(2)根据样本不平衡比例设置一个采样比例以确定采样倍率 N ,对于每一个少数类样本 x ,从其 k 近邻中随机选择若干个样本,假设选择的近邻为 x_n 。

(3)对于每一个随机选出的近邻 x_n ,分别与原样本构建新的样本,构建公式如下:

$$x_{new} = x + rand(0, 1) * (x_n - x) \tag{3}$$

3.4 建模

3.4.1 模型类型

在实验过程中,首先使用了几种传统的机器学习分类模型如LR、KNN、CART、NB(Naïve Bayes)、SVM进行了实验。其次选用了集成分类方法进行了相关实验:(1)Bagging方法利用训练数据集的不同子样本构建多个模型,常用的模型有RF、Extra Trees等;(2)利用Boosting方法建立多个相同类型的模型,序列中的每个模型对它先前的模型预测误差进行修正,常用的模型有Adaboost、XGBoost、GradientBoosting等。最后,运用Keras、Tensorflow深度学习框架构建深度神经网络模型用于训练分类模型。

3.4.2 模型优化

在实验中选用二值交叉熵(Binary Cross-Entropy)代价函数和多值交叉熵(Multi Cross-Entropy)代价函数来衡量模型的损失,采用小批量梯度递减方法(Mini-Batch Gradient Descent)对模型进行优化。

$$J(\theta) = -\frac{1}{m} \left[\sum_{i=1}^m y^{(i)} \text{lb}(h_{\theta}(x^{(i)})) + (1 - y^{(i)}) \text{lb}(1 - h_{\theta}(x^{(i)})) \right] \tag{4}$$

Want $\min_{\theta} J(\theta)$

Repeat {

$$\theta_j := \theta_j - \alpha \frac{\partial J(\theta)}{\partial \theta_j} = \theta_j - \alpha \frac{1}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)}) x_j^{(i)}$$

(Simultaneously update all θ_j)

}

3.4.3 模型验证与评估

训练学习模型的关键一步就是要对模型的泛化能力进行评估。一个模型如果性能不好,要么是因为模型过于复杂导致过拟合(高方差),要么是模型过于简单导

致欠拟合(高偏差)。因此选择一个好的方法来评价模型的性能是很重要的。本文选用 k 折交叉验证的方式和混合矩阵的方式对模型进行评价。 k 折交叉验证的机理如下:首先,运用不重复抽样策略,把原始数据集随机分割成 k 份。其次,选择 $k-1$ 份的数据用于模型的训练,剩下的一份数据用于模型的测试。然后,重复第二步操作 k 次,会得到 k 个模型和相应的评估结果。 k 折交叉验证方式是使用不重复的采样方法,优点是每个数据样本只会在训练集或测试集中出现一次,这样获得的对模型的评估成果才更可靠。

3.4.4 模型调参

使用 grid search 技术构建自动化的调节参数算法,对构建的模型的超参数进行调参,确定模型的最佳参数。

4 实验

下面将通过实验来研究本文提出的深度神经网络模型在自然语言问句意图识别任务上的性能,然后将其与其他模型的性能进行对比分析。

4.1 数据集

在本实验过程中用到的数据集是从 iDeepWise 公司第三代机器人——迪瓦积累的日志数据中选取的。总共包含 68 850 条自然语言问句,涉及到订票类、天气类、音乐类等 13 个领域。采用预处理技术对数据进行缺失值处理、错误字符纠正、数据类别合并、停用词处理、去重等操作,最终得到 53 117 条样本,每种类别样本数量和对应的类别标签如表 1 所示。

通过表 1 可知闲聊类样本数比较多。首先,把闲聊单独作为一类,其余 12 类作为一类构建了一个二分类的深度模型;其次,又构建了一个多分类的深度模型,用其余 12 类样本训练模型;最终,运用分层分类的技术把两个深度模型结合起来,共同对自然语言问句意图进行识别。为了验证本文所提方法的有效

表 1 样本类别和数量统计信息

类别	数量
闲聊类(chat)	27 177
服务类(cater)	3 267
机票类(airTicket)	2 650
算术类(arith)	493
酒店类(hotel)	2 598
音乐类(media)	6 774
导航类(navModule)	210
新闻类(news)	130
选择类(select)	5 232
系统类(system)	353
时间类(timemanager)	1 369
火车票类(trainTicket)	1 712
天气类(weather)	1 152

性,在实验过程中训练二分类和多分类模型时,都是对数据集进行随机分割,选取 80% 的数据作为训练集,20% 的数据作为测试集。

4.2 环境配置

实验是在公司的服务器上进行的,选用的研发环境软硬件配置详细信息如表 2 所示。

表 2 实验环境软硬件配置

名称	版本信息
Pycharm-professional	2017.3
Tensorflow-gpu	1.2
操作系统	Ubuntu16.04
内存	128 GB
硬盘	4 TB
GPU	TITAN X(Pascal)

4.3 模型架构与参数

实验过程中构建两层深度学习模型,第一层是二分类的模型,第二层是多分类的模型,把这两个模型集成在一起共同来识别自然语言问句的意图。详细的模型层次结构如图 2 所示。

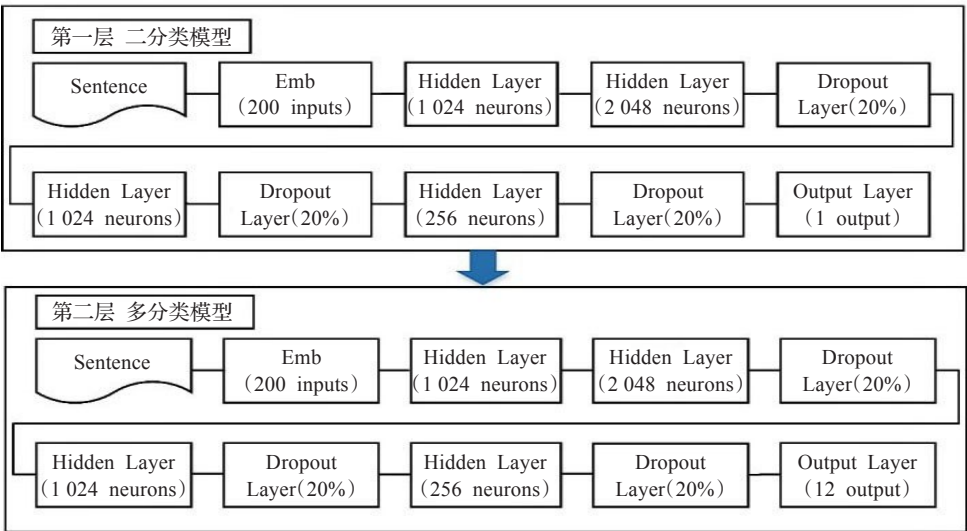


图 2 模型详细架构

实验中通过多次实验,使用网格搜索的方法对模型进行调参,二分类和多分类模型使用的参数如表3所示。

表3 模型参数设置		
参数	二分类模型	多分类模型
输入	词向量	词向量
词向量维度	200	200
激活函数	Relu、Sigmoid	Relu、Softmax
优化函数	Adam	Adam
损失函数	二值交叉熵	多值交叉熵
训练轮数	40	60
批量大小	32	32

4.4 实验结果分析

根据算法流程框架图,分别对自然语言问句进行了数据预处理和特征工程方面的操作,转化成机器学习模型能够进行处理的数据格式。分别选用了传统的机器学习方法,如LR、KNN、SVM等,集成学习方法Bagging和Boosting,深度学习方法多层感知机、CNN等进行了相关实验。运用k折交叉验证技术对实验结果进行了评估。

首先,选用了传统的机器学习模型进行相关实验,运用10折交叉验证技术,用准确率和标准差这两个指标对模型效果进行评估,得到的实验结果如图3所示。通过分析图3中对每个模型进行评估的量化值信息可知,LR模型在数据集上表现的效果比较好,SVM模型在数据集上表现的效果最差。




图3 传统机器学习方法实验结果

其次,针对相同处理过的数据集选用了集成学习模型和深度学习模型进行相关实验,同样使用10折交叉验证技术,用准确率和标准差这两个指标对集成模型和深度学习模型进行评估,获得的实验结果如图4所示。通过图4中对集成模型和深度学习模型进行衡量的实验结果可知,无论从准确率还是标准差的角度来说,深度学习模型在数据集上表现的效果都比集成模型效果要好。

通过分析图3和图4中准备率与标准差对各个模型在相同数据集上的表现效果,本文最终选用深度学习模型来完成自然语言问句意图理解的任务。通过对表1中各个类别对应的样本数量分析可知,闲聊类对应的样本数量最多,远远超过了其他业务类的数量。这样在实




图4 集成方法和深度学习方法实验结果

验过程中有些表示业务类的数据会被分到闲聊类别,造成实验效果不好。为了进一步解决数据不平衡的问题,本文把深度学习方法和分层分类的技术进行结合,分别构建了二分类和多分类模型来学习上下文语境和语义关系,共同完成对自然语言问句意图识别的任务。使用交叉熵代价函数对二分类和多分类模型进行估量,使用小批量梯度递减的方法对模型进行优化,使用k折交叉验证技术和准确率指标对模型效果进行评估,详细的实验结果如图5所示。




图5 二分类和多分类DNN模型实验结果

通过一系列实验证明,深度学习模型的性能明显优于传统的机器学习模型如LR、KNN和一些集成学习模型如Adaboost、RF的性能。深度学习能够处理不断增加的海量数据,通过不断训练来自行掌握概念。这种学习方式更接近于人脑,因此深度学习算法可以输出更加准确的结果。

5 结束语

本文首先介绍了自然语言问句理解问题的背景与意义,以及针对自然语言问句意图分类的解决方法;其次介绍了国内外学者在自然语言理解方面所做的工作和取得的进展;最后详细分析了解决自然语言意图分类方法的流程和相关技术,并对实验结果进行了分析。本文方法同样在SMP2017国内首届中文人机对话技术评测过程中得到了应用,并获得第一名(<http://ir.hit.edu.cn/SMP2017-ECDT-RAN>),证明了所提方法的有效性与可行性,为其他学者进行相关研究提供了重要的参考价值,也极大地推动了该模型和方法在NLP领域的应用。

参考文献:

- [1] 冯志伟. 自然语言问答系统的发展与现状[J]. 外国语(上海外国语大学学报), 2012, 55(6): 2-16.
- [2] 冶忠林, 贾真, 尹红凤. 多领域自然语言问句理解研究[J]. 计算机科学, 2017, 44(6): 216-221.
- [3] 霍帅, 张敏, 刘奕群, 等. 基于微博内容的新词发现方法[J]. 模式识别与人工智能, 2014, 27(2): 141-145.
- [4] 许坤, 冯岩松, 赵东岩, 等. 面向知识库的中文自然语言问句的语义理解[J]. 北京大学学报(自然科学版), 2014, 50(1): 85-92.
- [5] Wang X J, Zhang L, Ma W Y. Answer ranking in community question-answering sites: US8346701[P]. 2013.
- [6] Angelino E, Larus-Stone N, Alabi D, et al. Learning certifiably optimal rule lists for categorical data[C]//ACMS ICKDD International Conference on Knowledge Discovery & Data Mining, 2017: 35-44.
- [7] Moldovan D, Pasca M, Marabagiu S, et al. Performance issues and error analysis in an open-domain question answering system[J]. ACM Transactions on Information Systems, 2003, 21(2): 133-154.
- [8] Mikolov T, Karafiát M, Burget L, et al. Recurrent neural network based language model[C]//Conference of the International Speech Communication Association, Makuhari, 2010: 1045-1048.
- [9] Sutskever I, Vinyals O, Le Q V. Sequence to sequence learning with neural networks[C]//Proceedings of the 27th International Conference on Neural Information Processing Systems, 2014, 4: 3104-3112.
- [10] 郭健, 任永功. 云计算环境下的关联挖掘在图书销售中的研究[J]. 计算机应用与软件, 2014(11): 50-53.
- [11] Li L, Lu R, Choo K K R, et al. Privacy-preserving-out-sourced association rule mining on vertically partitioned databases[J]. IEEE Transactions on Information Forensics & Security, 2016, 11(8): 1847-1861.
- [12] Oliveira S R M, Zaiane O R A. A unified framework for protecting sensitive association rules in business collaboration[J]. International Journal of Business Intelligence & Data Mining, 2006, 1(3): 247-287.
- [13] Prager J, Radev D, Brown E, et al. The use of predictive annotation for question answering in TREC8[C]//Conference of the 8th Text Retrieval, 1999: 399-411.
- [14] Li X, Roth D. Learning question classifiers[C]//19th International Conference on Computational Linguistics, 2002: 1-7.
- [15] Li X, Roth D. Learning question classifiers: the role of semantic information[J]. Natural Language Engineering, 2015, 12(3): 229-249.
- [16] Loni B. A survey of state-of-the-art methods on question classification[J]. Electrical Engineering Mathematics & Computer Science, 2011.
- [17] 郑捷. NLP 汉语自然语言处理原理与实践[M]. 北京: 电子工业出版社, 2017.
- [18] Kim Y. Convolutional neural networks for sentence classification[J]. arXiv: 1408.5882, 2014.
- [19] Kalchbrenner N, Grefenstette E, Blunsom P. A convolutional neural network for modelling sentences[J]. arXiv: 1404.2188, 2014.
- [20] Mou L, Peng H, Li G, et al. Discriminative neural sentence modeling by tree-based convolution[J]. arXiv: 1504.01106, 2015.
- [21] Komninos A, Manandhar S. Dependency based embeddings for sentence classification tasks[C]//Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, 2016: 1490-1500.
- [22] Merkel A, Klakow D. Improved methods for language model based question classification[C]//Conference of the International Speech Communication Association, Antwerp, 2007: 322-325.
- [23] 李鑫, 黄萱菁, 吴立德. 基于错误驱动算法组合分类器及其在问题分类中的应用[J]. 计算机研究与发展, 2008, 45(3): 535-541.
- [24] Schapire R E. Theoretical views of boosting and applications[C]//Proceedings of the 10th International Conference on Algorithmic Learning Theory, 1999: 13-25.
- [25] Brill E. Transformation-based error-driven learning and natural language processing: a case study in part-of-speech tagging[J]. Computational Linguistics, 1995, 21(4): 543-565.
- [26] Li F, Zhang X, Yuan J, et al. Classifying what-type questions by head noun tagging[C]//International Conference on Computational Linguistics, 2008: 481-488.
- [27] Chang X, Yu Y L, Yang Y. Robust top-k, multiclass SVM for visual category recognition[C]//ACM SIGKDD International Conference on Knowledge Discovery and Data Mining, 2017: 75-83.
- [28] Shi H, Li H, Zhang D, et al. An efficient feature generation approach based on deep learning and feature selection techniques for traffic classification[J]. Computer Networks, 2018, 132: 81-98.