

面向脑电情感识别的改进多分类RVM模型研究

张雪英,王薇蓉,孙颖,宋春晓

太原理工大学 信息工程学院,太原 030024

摘要:从相关向量机(RVM)和支持向量机(SVM)的相似性以及RVM的稀疏特性出发,将RVM应用于脑电信号(EEG)的情感识别中。针对一对一(OAO)和一对多(OAA)两种多分类方法各自的特点和不足,提出了一种全新的两层多分类模型(OAA-OAO),改进现有OAO算法中无效投票影响最终决策的现象。设计情感EEG信号识别对比实验,验证基于RVM的改进多分类算法在脑电信号情感识别中的应用。对于实验室采集的情感脑电信号,提取其非线性特征(功率谱熵、样本熵和Hurst指数)并采用主成分分析法进行降维。将OAA-OAO-RVM算法分别和OAO-SVM、OAO-RVM两种识别网络进行对比,分析RVM的识别性能以及OAA-OAO多分类算法的分类性能。结果表明,采用降维后的最优特征集合作为识别网络的输入向量得到的识别性能更高,且RVM表现出的性能优于SVM。同时,改进后的OAA-OAO算法较传统OAO模型的平均识别率提高了7.89%,证明OAA-OAO算法可有效去除一部分无效投票从而使分类精度得到显著提高,验证了此模型是一种有效的多分类模型。

关键词:相关向量机;支持向量机;多分类;脑电信号;情感识别

文献标志码:A **中图分类号:**TP18;TP399 **doi:**10.3778/j.issn.1002-8331.1801-0337

张雪英,王薇蓉,孙颖,等.面向脑电情感识别的改进多分类RVM模型研究.计算机工程与应用,2019,55(9):112-117.
ZHANG Xueying, WANG Weirong, SUN Ying, et al. Research on improved multi-classification RVM for emotional recognition of EEG signal. Computer Engineering and Applications, 2019, 55(9): 112-117.

Research on Improved Multi-Classification RVM for Emotional Recognition of EEG Signal

ZHANG Xueying, WANG Weirong, SUN Ying, SONG Chunxiao

College of Information Engineering, Taiyuan University of Technology, Taiyuan 030024, China

Abstract: Based on the similarity of Relevance Vector Machine (RVM) and Support Vector Machine (SVM) and the sparse characteristics of RVM, RVM is applied to the electroencephalogram (EEG) signal emotional recognition. Aiming at the characteristics and deficiencies of the two methods of One-Against-One (OAO) and One-Against-All (OAA), this paper proposes a new two-layer multi-classification model (OAA-OAO) to improve the effect of invalid voting on the final decision-making in the existing OAO algorithm. A series of emotional EEG signal recognition experiments are designed to verify the effectiveness of improved multi-classification algorithm based on RVM in EEG emotion recognition. For the emotional EEG signal collected by the laboratory, this paper extracts the nonlinear features (power spectral entropy, sample entropy and Hurst index) and reduces the dimension by Principal Component Analysis (PCA). OAA-OAO-RVM is compared with OAO-SVM and OAO-RVM respectively, the recognition performance of RVM and the classification performance of OAA-OAO is analyzed. The results show that using the optimal feature set after dimension reduction as input vector of the recognition network has higher recognition rate, and the performance of RVM is better than that of SVM. At the same time, the average recognition rate of OAA-OAO is 7.89% higher than that of OAO, which proves that the OAA-OAO algorithm can effectively remove part of the invalid votes so that the classification accuracy can be improved obviously and this model is an effective multi-classification model.

基金项目:国家自然科学基金(No.61371193)。

作者简介:张雪英(1964—),女,博士,教授,主要研究方向为语音信号处理、音频水印、煤矿安全预警及信息化,E-mail:tyzhangxy@163.com;王薇蓉(1991—),女,硕士研究生,研究领域为脑电信号的情感识别研究;孙颖(1981—),女,博士,讲师,研究方向为情感语音处理;宋春晓(1991—),女,硕士研究生,研究领域为情感语音识别,特征提取,特征优化。

收稿日期:2018-01-22 **修回日期:**2018-03-05 **文章编号:**1002-8331(2019)09-0112-06

CNKI网络出版:2018-10-09, <http://kns.cnki.net/kcms/detail/11.2127.TP.20180929.1817.002.html>

Key words: Relevance Vector Machine (RVM); Support Vector Machine (SVM); multi-classification; electroencephalogram (EEG) signal; emotional recognition

1 引言

人类的情感状态在一定程度上对其自身的认知和行为存在很大的影响,因此,对人类情感的分析已成为一个重要的研究课题^[1-2]。脑电信号是一种复杂的非线性信号,而非线性指标可以很好地揭示大脑的混沌行为,所以利用脑电信号对人类情感进行识别能较准确地反应人类真实的情感变化^[3-4]。蔡宏志等人使用功率谱熵作为特征验证了其对于脑电特征变化具有良好的识别能力^[5];李立对脑电信号的分析验证了非线性特征更适用于情感脑电的特征提取与识别^[6];Isotani等人证明了正性、负性和中性三种情绪状态下与大脑不同神经群体的活动明显相关^[7];Jatupaiboon等人通过对正负两种情绪状态的脑电信号进行分析得出其前向通道和频段段的分类效果较好^[8]。

在情感脑电的分类研究中,普遍采用监督学习方法,中国科学院的赵国联等人通过对多种针对脑电等生理信号进行情绪识别的分类算法进行分析比较发现,在这些分类算法中,使用最广泛且识别率较好的分类器为SVM^[9]。但SVM也存在一些不可忽视的问题:在核函数的选择上,受Mercer条件的限制;实验结果对惩罚因子的设置十分敏感等^[10],这些因素使得SVM会对脑电信号的识别精度造成一定影响。Tipping于2001年提出一种与SVM类似的模式识别方法:相关向量机(Relevance Vector Machine, RVM)^[11-12]。由于RVM具有较高的稀疏性且核函数的选择不受限制等特点,使得RVM已经在故障诊断及预测、图像处理、人脸识别、语音识别、医疗诊断等领域取得了一定成果^[13-14]。在对脑电信号的研究领域中,Han等人使用AR模型提取癫痫脑电信号的特征验证了RVM在脑电癫痫诊断中的良好适用性^[15],但对于脑电信号的情感识别等领域尚存在一些空白。鉴于此,本文提出采用不受上述条件限制的相关向量机作为脑电信号的情感识别网络,从而提高脑电信号的情感识别结果。

由于RVM和SVM都是二分类器,而在实际应用中,通常需要对多种状态进行识别,因此,需要选择合适的多分类算法来实现多分类的功能。目前常用的多分类方法有一对一(One Against One, OAO)、一对多(One Against All, OAA)等,其中,前者分类精度较高且应用最广泛^[16-17]。在OAO算法中,待测样本要遍历所有的二分类器,使其会产生一部分的无效投票,从而降低识别精度;而OAA算法中训练样本的不均衡特点会导致待测样本被错分的概率增加。综上,这两种方法都会使SVM和RVM的分类精度受限^[14]。

首先将RVM算法用于脑电信号的情感识别中,并在已有研究的基础上,针对上述两种多分类方法各自的特点,提出了一种改进的两层多分类模型:一对多——一对一(One Against All-One Against One, OAA-OAO)。经过对实验室采集的情感脑电信号进行情感分类实验验证,得出RVM对于脑电信号的情感识别精度优于SVM,且改进后的多分类模型较以往算法在分类精度及计算复杂度上得到了很大程度的提高。

2 脑电信号识别原理与方法

2.1 脑电信号情感识别原理

脑电信号作为一种特殊的生理信号,是脑活动的产物,用来描述头皮表面脑细胞的变化情况。Kalaivani通过对脑电信号的研究发现当大脑处在紧张、激动、兴奋等情感状态时,脑电波中 β 节律信号的波动最为明显,而情绪的脑机制研究表明大脑的不同结构参与了情绪的加工^[18]。因此,脑电信号可以实时地反映出人类的情感活动状态,从而获得更深入和更全面的情感认知信息。完整的脑电信号情感识别系统构成包括情感EEG数据集、预处理、特征提取和模式识别等。脑电信号情感识别系统构成如图1所示。

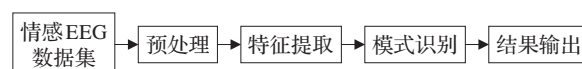


图1 情感脑电识别系统构成

2.2 相关向量机分类原理

相关向量机是一种基于贝叶斯理论的核函数算法。该算法引入超参数对权值进行约束,并结合自相关定理来移除相关性较小的样本点,从而获得一个较为稀疏的分类模型^[12],其基本分类原理如下所示:

假设训练样本的集合为 $\{x_n, t_n\}_{n=1-N}$,其中,目标函数 $t_n \in \{0, 1\}$ (0和1为类别标号),在RVM的分类模型中不考虑附加的噪声函数,二分类RVM模型的分类函数定义为:

$$y(x; w) = \sum_{n=1}^N w_n K(x, x_n) + w_0 \quad (1)$$

式(1)中, $K(x, x_n)$ 为模型选定的核函数, w_n 为模型的权值。

将logistic sigmoid函数引入分类函数中,完成对线性模型 $y(x, w)$ 的归一化,以实现输入向量对应的目标值做出概率预测,根据伯努利分布,则样本集的似然概率为:

$$p(t|w) = \prod_{n=1}^N \sigma\{y(x_n; w)\}^{t_n} [1 - \sigma\{y(x_n; w)\}]^{1-t_n} \quad (2)$$

为避免过拟合现象, RVM 模型中将 w_n 设为均值为 0, 方差为 α^{-1} 的高斯先验分布, 超参数 α 服从形状参数和尺度参数均为 0 的 Gamma 共轭先验分布, 即:

$$p(w|\alpha) = \prod_{n=0}^N N(w_n|0, \alpha_n^{-1}) \quad (3)$$

$$p(\alpha) = \prod_{n=0}^N \text{Gamma}(\alpha_n|0, 0) \quad (4)$$

通过超参数对权值进行约束是 RVM 模型的重要特征, 大部分的 α 在不断的迭代更新中趋于无穷, 与之对应的 w 则趋于 0, 最终使 RVM 模型稀疏化。

初始化超参数 α , 采用 Laplace 逼近方法计算权值的最大后验概率估计值 w_{MP} , 因为:

$$p(w|t, \alpha) = \frac{p(t|w)p(w|\alpha)}{p(t|\alpha)} \quad (5)$$

则使得 $p(w|t, \alpha)$ 为最大值时的 w_{MP} 可通过最大化式(6)得到:

$$\log\{p(w|t, \alpha)\} = \sum_{n=1}^N [t_n \log y_n + (1 - t_n) \log(1 - y_n)] - \frac{1}{2} w^T A w \quad (6)$$

其中, $y_n = \sigma\{y(x_n; w)\}$, $A = \text{diag}(\alpha_i)$ 。

利用拉普拉斯方法对上述 \log 函数进行二次逼近:

$$\nabla_w \nabla_w \log p(w|t, \alpha)|_{w_{MP}} = -(\Phi^T B \Phi + A) \quad (7)$$

式中, $B = \text{diag}(\beta_1, \beta_2, \dots, \beta_N)$ 为一个对角阵, $\beta_n = \sigma\{y(x_n)\}[1 - \sigma\{y(x_n)\}]$, $\Phi = [\varphi(x_1), \varphi(x_2), \dots, \varphi(x_N)]^T$, $\varphi(x_n) = [1, K(x_n, x_1), K(x_n, x_2), \dots, K(x_n, x_N)]^T$, 将式(7)等号右边取负并求逆可求得协方差矩阵:

$$\Sigma = (\Phi^T B \Phi + A)^{-1} \quad (8)$$

利用 Σ 和 w_{MP} 对超参数 α 完成更新:

$$\alpha_n^{\text{new}} = \frac{\gamma_n}{w_{MP}^2} \quad (9)$$

$$w_{MP} = \Sigma \Phi^T B t \quad (10)$$

式中, $\gamma_n = 1 - \Sigma_n$, Σ_n 为协方差矩阵对角线上的第 n 个元素。

3 实验设计与结果分析

3.1 实验数据采集与预处理

本实验所选的被试皆为在校大学生和研究生且无精神疾病以及脑神经损伤。鉴于语音情感识别技术的日益成熟, 已被广泛应用于医疗、情感障碍、远程教育等领域^[19-20], 表明了语音信号中包含有较为完整的情感信息。因此, 本实验采用情感语音刺激诱发产生脑电信号, 实验素材为从 TYUT2.0 情感语音库^[21]中筛选出符合要求的不同的情感语音各 50 句作为标准刺激, 每种语句的时长在 1 000~2 000 ms 左右, 另选择 250 Hz 的纯音信号作为靶刺激, 16 名被试需要对声音刺激进行快速按键反应, 四种情感依次为悲伤、生气、惊奇、中性。考

虑到数据的准确性和稳定性, 每名被试需重复进行一次实验。

使用 E-prime 软件设计实验程序, 美国 Neuroscan 公司的 64 导 Ag/AgCl 电极记录脑电 (EEG), 其中, 脑电信号实时采集的采样率为 1 000 Hz, 每个导联的电极阻抗均小于 5 k Ω 。在本实验中选择 FC1、FC2、FC3、FC4、C1、C2、C3、C4、CP1、CP2、CP3、CP4 位置处的电极, 共 12 导的脑电数据进行情感识别, 以鼻尖为参考电极, 使用仪器自带的软件对脑电信号进行预处理, 脑电信号的滤波通带为 0.5~30 Hz。图 2 中虚线框内的电极即为实验所选择的电极。




图2 64导联的电极信号分布图

3.2 特征提取

学术界一般将脑电波按频段的不同划分为五种基本节律 ($\theta, \delta, \alpha, \beta, \gamma$)。其中, θ 频段和 δ 频段与人的睡眠状态相关; α 波的出现受睁眼和闭眼的影响; 当大脑皮层处在紧张、激动、兴奋等状态时, β 节律信号的波动剧烈, 通常被认为与人类的精神和情感活动紧密相关; 与 β 频段相比, γ 频段更侧重于人类的感知行为, 当人受到强烈的感官刺激 (如视频、图片等材料) 或者高度集中精力去执行一项任务时, γ 波会有增强趋势。考虑到本文选用的诱发刺激为单一的听觉刺激, 对被试的感官刺激可能不够强烈, 从而使诱发得到的 γ 波段增强趋势不明显, 因此, 选取与人类大脑皮层兴奋状态极为紧密的 β 频段作为实验信号最为合适。图 3 所示为提取的其中一名被试对某一“悲伤”语句产生的脑电信号的五种节律波, 对五种波段的波形进行分析, 可以看出 β 波变异性最大, 波动明显, 对情感状态变化的表现比其余四种节律波都更为显著。从五种信号的幅值波动范围来看, β 波和 γ 波的幅值范围最大, 而其余三种波的

幅值波动范围较窄。由于本实验所提取的 β 波段起伏趋势最为明显,并且在情感脑电识别领域的优越表现已得到广大研究者的接受和认可,例如,在文献[22]中,陈曾等人通过提取 EEG 信号的 β 波段来进行情感识别的研究,验证了将脑电信号的 β 波段用于情感的识别的可行性和有效性。因此,本文选取脑电信号的 β 波段作为实验信号。

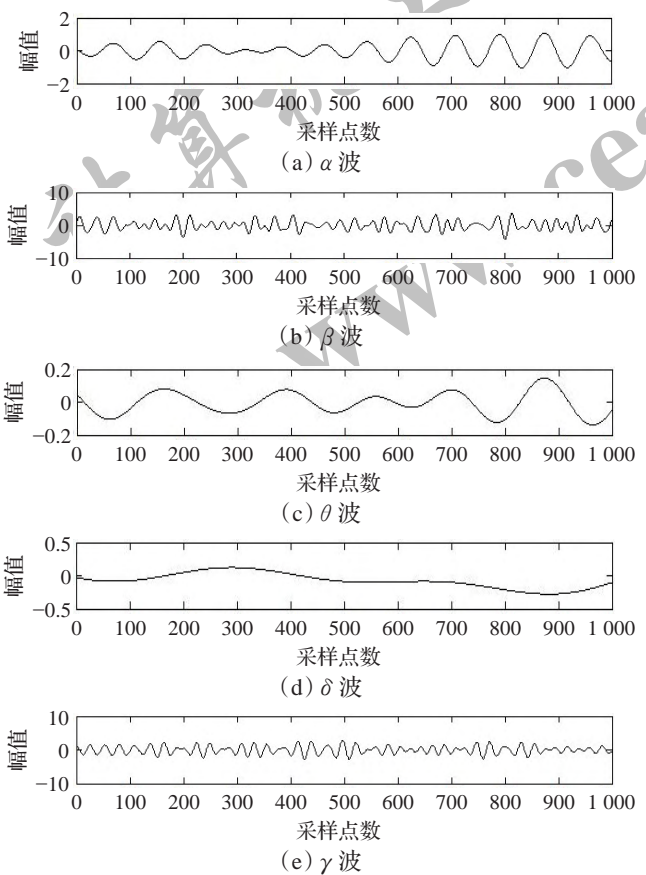


图3 “悲伤”时脑电信号的五种节律波

由于脑电信号是一种复杂的,非平稳的非线性动力学信号,而脑电信号可以实时的反映出人类的情感活动状态。因此,非线性方法更适用于脑电信号的情感识别。本文分别提取 EEG 信号的三种非线性特征:功率谱熵、样本熵以及 Hurst 指数。为了判断上述提取特征区分情感状态的能力强弱,文中设计了一系列 EEG 特征的情感识别实验,采用不同特征的组合分别作为 OAO-RVM 分类器的输入,从实验室采集的 EEG 数据中选取悲伤(560)、生气(560)、惊奇(560)、中性(560)四类情感的数据,以多次实验的平均值作为最终识别结果,每次实验随机抽取数据集的 70% 作为训练样本,30% 作为测试样本。选取识别效果最优的特征组合。

- 组合一:将功率谱熵与样本熵融合。
- 组合二:将功率谱熵、样本熵与 Hurst 指数融合。
- 组合三:采用主成分分析法(Principal Component Analysis, PCA)对组合二的融合特征集进行降维。

实验结果如表 1 所示。

表1 不同特征组合的识别率对比结果

实验 编号	特征 类型	情感类别				平均识 别结果
		悲伤	生气	惊奇	中性	
1	组合一	43.63	45.37	52.25	48.75	47.50
2	组合二	51.87	42.50	53.75	59.37	51.87
3	组合三	63.75	90.62	77.87	71.87	76.02

从表 1 中可以得出:实验 2 和实验 1 比较,平均识别率由 47.50% 提高到 51.87%,提高了 4.37%。在实验 2 中添加的 Hurst 指数特征使得悲伤、惊奇和中性三类情感都得到了改善,分别提高了 8.24%、1.5%、10.02%,由此可以推测,单一的特征维数的累加会使识别结果有所提高;实验 2 和实验 3 比较,平均识别率由 51.87% 提升到 76.02%,提高了 24.15%,当对第三组实验中的特征全集做了降维之后,悲伤、生气、惊奇和中性四类情感的识别率都有较为明显的提高,分别提高了 11.88%、48.12%、24.12%、12.5%,这说明 PCA 算法从融合的特征集中选取了最有判别力的特征维度,有效地去除了冗余特征,更好地描述了情感 EEG 信号中的有效信息,从而使分类器可以更准确地对情感 EEG 信号进行判别。另一方面,纯粹的特征维数的累加在提升识别率的同时也有可能造成数据冗余,对分类效果造成影响。因此,将采用组合三的特征集合作为改进多分类 RVM 模型的输入特征向量。

3.3 OAA-OAO-RVM 多分类模型

在 OAO 算法中,对于 k 类的样本,需要构造 $k(k-1)/2$ 个 RVM 二分类器,每一个待测样本需要经过全部的子分类器进行判别并投票。设函数 $f_{ij}(x)$ 用来识别 i, j 两类样本,当 $f_{ij}(x) < 0$ 时,判定 x 属于第 i 类,否则为第 j 类,由最大投票策略来决定 x 的所属类别。从理论上讲,任意两个不相关类别进行比较时,各类的得票概率应相等且不影响最终识别结果。

对此,本文设计了一组实验来分析非相关类别的得票结果是否降低了 RVM 分类器的分类精度。在实验 4 中,第 i 类待测样本不需要遍历所有的子分类器,只需由包含正确类别的 $k-1$ 个二分类器 $f_{ij}(x)(j=1,2,\cdots,k, j \neq i)$ 对其进行投票,同样根据最大投票制度来确定待测样本的所属类别。实验结果如表 2 所示。

表2 去除不相关类别的 OAO-RVM 识别结果

实验 编号	特征 类型	情感类别				平均识 别结果
		悲伤	生气	惊奇	中性	
4	组合三	88.75	88.00	81.87	80.00	84.66

对比实验 3 和实验 4,悲伤、惊奇和中性三种情感的识别率分别提升了 25.00%、4.00%、8.13%,生气的识别率降低了 2.62%,总体平均识别率上升了 8.64%。可以看出,在 OAO 模型中去除由不相关类别构建的子分类

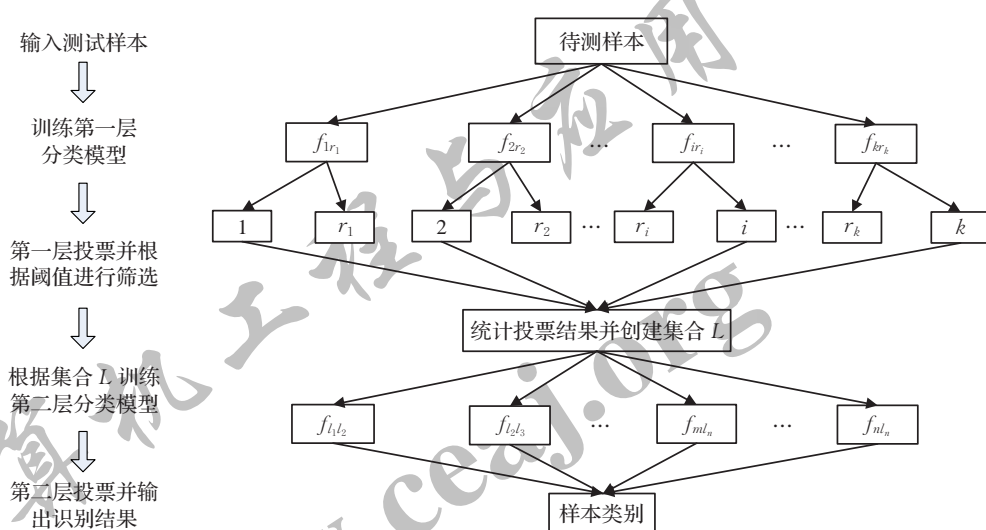


图4 基于RVM的OAA-OAO多分类模型

器,除了对“生气”的识别结果稍有降低,其他三种情感的识别率均有显著提高。对此实验结果进行分析可知,在OAO模型中,非相关类别的得票结果,影响了分类器的分类精度以及最终的判别结果。

为此,针对OAO算法的上述不足,结合OAO和OAA各自算法的特点,提出一种结合这两种算法的多分类模型:OAA-OAO,通过这个模型来尽可能地消除不相关类别对RVM分类器识别精度的影响。具体过程如下。

同样对于 k 类的样本,在第一层模型中,任意的第 $i(i=1,2,\dots,k)$ 类样本都与其他剩余的类别训练一个RVM二分类器,则第一层共有 k 个子分类器。对第一层的 k 个子分类器应用OAO算法,设函数 $f_{ir_i}(x)$ 为判决函数,当 $f_{ir_i}(x)>0$ (r_i 表示除去 i 类的所有类别)时,认为 x 属于第 i 类并得一票,否则 r_i 得一票,其中,对 r_i 的投票不计入总票数,记为无效投票,采用上述投票制来统计待测样本属于某一类别的票数。因此,在下层模型训练之前,需要预先设定一个阈值 t ,由此阈值来最终确定待测样本的可能所属类别集合 $L\{l_1, l_2, \dots, l_n\}(n \leq k)$,如果第一层中第 i 类的投票结果大于等于阈值,即:

$$\text{vote}(i) \geq t \quad (11)$$

$\text{vote}(i)$ 为第 i 类的投票结果,满足此判定条件的类别 i 将进入第二层模型的构建,否则此类别被淘汰。由此,根据第一层模型的筛选结果来决定第二层RVM子分类器的构建,将集合 L 中的元素两两组合按照OAO模型进行训练,设函数 $f_{mn}(x)$ 用来识别 $m, n(m, n \in L)$ 两类样本,判定方法如上文所述,采用最大投票法决定待测样本的最终判定类别。综上所述,基于RVM的OAA-OAO算法如图4所示。

3.4 基于改进多分类RVM算法的脑电信号情感识别结果与分析

本文采用OAO-SVM、OAO-RVM以及上述改进的

多分类RVM模型分别作为识别网络,对比三者在相同情感EEG数据集上的表现来分析OAA-OAO-RVM分类器的性能。实验5~7所用样本训练集和测试集同实验1~4一致,实验结果如表3所示。

表3 三种识别网络的识别结果

实验 编号	识别网络	情感类别				平均识 别结果
		悲伤	生气	惊奇	中性	
5	OAO-SVM	66.87	63.75	63.75	65.63	65.00
6	OAO-RVM	63.75	90.62	77.87	71.87	76.02
7	OAA-OAO-RVM	82.50	98.75	83.75	70.62	83.91

从表3中可以得到以下结论:

(1)从两种不同分类器的识别结果来看,对比实验5和实验6,RVM的平均识别率要比SVM高出11.02%。并且针对单一的四种情感识别结果来看,除了悲伤的识别率略微降低了3.12%,其他三种情感的识别率都有明显提高,依次提高了26.88%、14.12%、6.24%。

可以得出,对于EEG信号的情感识别,RVM表现出的性能普遍优于SVM,这与RVM模型具有的稀疏特性有关,验证了采用RVM作为情感EEG信号的识别网络的有效性和优越性。

(2)从采用不同多分类算法的识别结果来看,对比实验6、7的实验结果,本文改进的多分类算法比OAO算法的平均识别率高出7.89%,且除中性的情感识别率降低1.25%之外,基于OAA-OAO算法的RVM对每种情感的识别性能均有提升,分别提高了18.75%、8.13%、5.88%。此外,由于在OAA-OAO-RVM模型中,不是每个待测样本都需要遍历 $k(k-1)/2$ 个子分类器,使得此模型的计算复杂度较传统的OAO算法大大降低。由此可得,将两种多分类算法结合之后的识别网络性能得到了提升。图5则更加直观地描述了三种识别网络对上述EEG信号的情感识别结果。




图5 三种识别网络的识别结果对比

综上可得,相关向量机作为脑电信号的情感识别网络较支持向量机有更好的识别性能,可以更有效地区分情感EEG信号。同时,当OAA和OAO两种算法结合之后,能够更准确地判别情感EEG信号中的有效信息,表现出的分类性能也更优。由此证明,本文提出的基于改进多分类算法的RVM在脑电信号情感识别中的优势较为显著,可以有效地提高情感EEG的识别率。

4 结语

本文从相关向量机和支持向量机的相似性以及相关向量机模型具有的稀疏性出发,将相关向量机应用于情感脑电信号的识别,并提出了一种改进的OAA-OAO多分类模型。实验结果说明,与应用较广泛的SVM的识别性能相比,RVM对情感EEG信号的识别性能更为显著。此外,同常用的多分类算法OAO相比,本文提出的将OAO和OAA算法结合的模型更适合与区分不同情感的脑电信号,表现出的分类性能更优。

参考文献:

- [1] 聂聃. 基于脑电的情感识别[D]. 上海: 上海交通大学, 2012.
- [2] 姚慧, 孙颖, 张雪英. 情感语音的非线性动力学特征研究[J]. 西安电子科技大学学报, 2016(5).
- [3] 时文飞, 叶西宁. 基于脑电信号的ILDB情感特征提取算法[J]. 华东理工大学学报, 2016, 42(2): 254-249.
- [4] 聂聃, 王晓韡, 段若男, 等. 基于脑电的情绪识别研究综述[J]. 中国生物医学工程学报, 2012, 31(4): 596-606.
- [5] 蔡宏志, 程龙龙, 陈滨津, 等. 想象动作中动态脑电的信息熵研究[J]. 中国生物医学工程学报, 2007, 26(1): 74-77.
- [6] 李立. 基于脑电信号样本熵的情感识别[D]. 太原: 太原理工大学, 2014.
- [7] Isotani T, Lehmann D, Pascual-Marqui R D, et al. Source localization of brain electric activity during positive, neutral and negative emotional states[J]. International Congress, 2002, 1232(2): 165-173.
- [8] Jatupaiboon N, Pan-Ngum S, Israsena P. Emotion classification using minimal EEG channels and frequency

bands[C]//10th International Joint Conference on Computer Science and Software Engineering, 2013.

- [9] 赵国联, 宋金晶, 葛燕, 等. 基于生理大数据的情绪识别研究进展[J]. 计算机研究与发展, 2016, 53(1): 80-92.
- [10] Demidova L, Klyueva I, Sokolova Y, et al. Intellectual approaches to improvement of the classification decisions quality on the base of the SVM classifier[J]. Procedia Computer Science, 2017, 103: 222-230.
- [11] Tipping M E. Sparse bayesian learning and the relevance vector machine[J]. Journal of Machine Learnig Research, 2001(1): 211-244.
- [12] Tipping M E. The Relevance vector machine[C]//Advances in Neural Information Processing Systems, 1999: 652-658.
- [13] Xu Xiangmin, Mao Yunfeng, Xiong Jiani, et al. Classification performance comparison between RVM and SVM[C]//IEEE International Workshop on Conference on Anti-Counterfeiting, Security, Identification, 2007.
- [14] 柳长源. 相关向量机多分类算法的研究与应用[D]. 哈尔滨: 哈尔滨工程大学, 2013.
- [15] Han M, Sun L. EEG signal classification for epilepsy diagnosis based on AR model and RVM[C]//International Conference on Intelligent Control and Information Processing, 2010: 134-139.
- [16] Huang J, Hu X, Geng X. An intelligent fault diagnosis method of high voltage circuit breaker based on improved EMD energy entropy and multi-class support vector machine[J]. Electric Power Systems Research, 2011, 81(2): 400-407.
- [17] Xu J. An extended one-versus-rest support vector machine for multi-label classification[J]. Neurocomputing, 2011, 74(17): 3114-3124.
- [18] Kalaivani M, Kalaivani V, Anusuya Devi V, et al. Analysis of EEG signal for the detection of brain abnormalities[C]//IJCA Proceedings of International Conference on Simulations in Computing Nexus, 2014: 1-6.
- [19] Raju V V V, Gangamohan P, Gangashetty S V, et al. Application of prosody modification for speech recognition in different emotion conditions[C]//Region 10 Conference, 2017: 951-954.
- [20] Kadiri S R, Yegnanarayana B. Epoch extraction from emotional speech using single frequency filtering approach[J]. Speech Communication, 2017, 86: 52-63.
- [21] 张雪英, 张婷, 孙颖, 等. 情感语音数据库优化及PAD情感模型量化标注[J]. 太原理工大学学报, 2017, 48(3): 469-474.
- [22] 陈曾, 刘光远. 脑电信号在情感识别中的应用[J]. 计算机工程, 2010, 36(9): 168-170.