

## 一种基于信道状态信息的室内人员行为检测方法

党小超<sup>1,2</sup>, 黄亚宁<sup>1</sup>, 郝占军<sup>1,2</sup>, 司 雄<sup>1</sup>

(1. 西北师范大学 计算机科学与工程学院, 兰州 730070; 2. 甘肃省物联网工程研究中心, 兰州 730070)

**摘 要:** 传统室内人员行为检测方法检测准确率较低, 稳定性较差。为此, 提出一种基于信道状态信息(CSI)的室内人员行为检测方法。采集 CSI 原始数据包后使用 Kalman 滤波算法对其进行过滤, 运用 SVM 算法对过滤后的数据作分类处理并建立指纹库。同时, 利用 PSO 算法修正 SVM 中的参数, 然后采用 SVM 算法处理从真实环境内实时采集到的数据后, 将该实时数据与指纹库的数据一一匹配。在此基础上, 实现室内人员的行为检测。实验结果表明, 相比 LIFS、FIMD 方法, 该方法可以更精细地识别室内人员的动作行为, 且稳定性更高。

**关键词:** 行为检测; 信道状态信息; 支持向量机; 粒子群算法; 卡尔曼滤波

**中文引用格式:** 党小超, 黄亚宁, 郝占军, 等. 一种基于信道状态信息的室内人员行为检测方法[J]. 计算机工程, 2018, 44(8): 79-85.

**英文引用格式:** DANG Xiaochao, HUANG Yaning, HAO Zhanjun, et al. An indoor personnel behavior detection method based on channel state information[J]. Computer Engineering, 2018, 44(8): 79-85.

## An Indoor Personnel Behavior Detection Method Based on Channel State Information

DANG Xiaochao<sup>1,2</sup>, HUANG Yaning<sup>1</sup>, HAO Zhanjun<sup>1,2</sup>, SI Xiong<sup>1</sup>

(1. College of Computer Science and Engineering, Northwest Normal University, Lanzhou 730070, China;

2. Gansu Province Internet of Things Engineering Research Center, Lanzhou 730070, China)

**【Abstract】** The traditional indoor personnel behavior detection method has low accuracy and poor stability. To solve this problem, an indoor personnel behavior detection method based on Channel State Information(CSI) is proposed. After collecting the CSI raw data package, it uses Kalman filtering algorithm to filter it, and uses the SVM algorithm to classify the filtered data, and then builds the fingerprint database. At the same time, the PSO algorithm is used to modify the parameters of the SVM, then the real time data collected from the real environment is processed by SVM, and the real-time data is matched with the data of the fingerprint library. On this basis, indoor personnel behavior detection is realized. Experimental results show that, compared with LIFS and FIMD method, this method can identify the behavior of indoor personnel more accurately and has higher stability.

**【Key words】** behavior detection; Channel State Information(CSI); Support Vector Machine(SVM); Particle Swarm Optimization(PSO); Kalman filtering

**DOI:** 10.19678/j.issn.1000-3428.0048168

### 0 概述

随着无线传感器网络(Wireless Sensor Networks, WSN)的不断进步与发展, 人们已经不局限于只对传统室内定位与位置感知进行研究。近年来, 智能家居、军事、工业等领域均开始利用无线电进行位置感知, 如典型的基于 UWB(Ultra Wideband)的雷达系统<sup>[1]</sup>。而目前较新颖的基于商用 Wi-Fi 设备的室内

定位技术, 在室内入侵检测、校园安全、商场人员检测、病人监护、家中老人小孩的实时检测等多个领域中<sup>[2]</sup>, 均有较好的发展优势。

传统的室内定位技术进行位置服务与环境感知时, 主要依据接收信号强度(Received Signal Strength Indication, RSSI)<sup>[3]</sup>技术。但从实验结果中可以发现, 这类室内定位技术的精度较低, 造成该现象的主要原因是 RSSI 的稳定性较低, 其定位结果会受时间

**基金项目:** 国家自然科学基金(61762079, 61363059, 61662070); 甘肃省科技重点研发项目(1604FKCA097, 17YF1GA015); 甘肃省科技创新项目(17CX2JA037, 17CX2JA039)。

**作者简介:** 党小超(1963—), 男, 教授, 主研方向为物联网、传感器网络; 黄亚宁, 硕士研究生; 郝占军(通信作者), 副教授; 司 雄, 硕士研究生。

**收稿日期:** 2017-07-29

**修回日期:** 2017-10-27

**E-mail:** zhanjunhao@126.com

影响。相比 RSSI 技术,信道状态信息(Channel State Information, CSI)在时间分辨率、频率分辨率、稳定性等方面都具有优势<sup>[4]</sup>。

文献[5]提出基于 CSI 模型的低成本高精度被动式目标定位方法 LIFS, 其将 CSI 的特点有效地应用于目标定位中, 但该方法未考虑检测区域与检测率的关系。文献[6]将相位信息应用在唇语检测系统中, 能够达到更细粒度的定位效果, 但是其相位信息不易获取, 并且在检测过程中要利用专用设备 USPR, 导致方法稳定性和实用性不高。文献[7]的 FIMD 系统利用 CSI 的稳定性, 在静态环境下实现了更细粒度的人员检测, 但其未取得高检测率, 且系统性能会受实验环境的影响。文献[8]的 BFP 系统利用 CSI 进行行为无关移动检测, 其整体性能较好, 但算法的效率较低。文献[9]将 SVM 应用在基于 RSSI 的室内人员定位中, 但基于 RSSI 的室内人员检测精度较低。

针对以上方法存在的不足, 本文提出一种基于 CSI 的室内人员行为检测方法 Wi-SK。首先采集 CSI 数据, 利用振幅信息作为特征值, 选择 Kalman 滤波算法对原始的 CSI 数据进行过滤, 剔除异常值; 然后使用 SVM 对滤波后的数据作分类处理, 并使用 PSO 修正 SVM 中的参数后建立指纹库; 最后在真实环境中的检测区域内实时采集数据, 并利用 SVM 处理实时提取的特征值, 将在真实环境下采集的实时数据与指纹库的数据进行匹配, 在此基础上, 进行人员行为的检测。

## 1 相关理论

### 1.1 信道状态信息

随着无线网络的普及和正交频分复用(Orthogonal Frequency Division Multiplexing, OFDM)技术的发展, 传统的信号传播格局被改变。在 802.11/g/n 标准下, 通道响应可以从商用 Wi-Fi 设备中提取出 CSI, 其以子载波的振幅和相位信息揭示了信号从发送端到接收端的通信链路间的信道状态<sup>[10]</sup>。由于 RSSI 不能逐一区分多条信号传播路径, 为了更好地表示多径传播, 无线信道通常用信道脉冲响应(Channel Impulse Response, CIR)来进行建模<sup>[11]</sup>。在线性时间不变的情况下, CIR 可表示为:

$$h(\tau) = \sum_{i=1}^N a_i e^{-j\theta_i \delta(\tau - \tau_i)} \quad (1)$$

其中,  $a_i$ 、 $\theta_i$  和  $\tau_i$  分别表示第  $i$  条路径的振幅衰减、相位偏移和时间延迟,  $N$  表示传播路径总数,  $\delta(\tau)$  是狄拉克脉冲函数。

由于在多径传播过程中会造成频率选择性衰落, 为了更好地刻画多径传播, 可以选择信道频率响应(Channel Frequency Response, CFR)进行建模。

CFR 是 CIR 的傅里叶变换<sup>[12]</sup>, CIR 和 CFR 可以描绘小规模的多径效应并且广泛应用于通道测量。通过 Wi-Fi 设备可以 CSI 的形式获取 CFR 的一个样本<sup>[13]</sup>, 即利用兼容 IEEE 802.11a/g/n 的无线网卡可从每个接收数据包中获取一组 CSI, 每组 CSI 代表一个 OFDM 子载波的幅度和相位, 其表示为:

$$H(k) = \|H(k)\| e^{j\angle H(k)} \quad (2)$$

其中,  $H(k)$  为第  $k$  个子载波的 CSI,  $\|H(k)\|$  和  $j\angle H(k)$  分别表示第  $k$  个子载波的振幅与相位。由于振幅信息较稳定可提高算法的效率, 因此本文选用振幅作为特征值。

### 1.2 卡尔曼滤波

提取第 1.1 节所述的振幅数据后, 利用 Kalman 滤波算法将异常值剔除。该过程主要步骤为:

**步骤 1** 设  $X_k$  为  $k$  时刻的状态向量, 将系统向量转换为线性方程的形式, 则系统的状态转移方程<sup>[14]</sup>如下:

$$X_k = F_k X_{k-1} + B_k U_k + W_k \quad (3)$$

其中,  $F_k$  是状态转移矩阵,  $B_k$  是控制矩阵,  $U_k$  是控制向量,  $W_k$  是转移过程中的噪声矩阵。

**步骤 2** 若  $Z_k$  为  $k$  时刻系统的观测向量, 则观测方程为:

$$Z_k = H_k X_k + V_k \quad (4)$$

其中,  $H_k$  是观测矩阵,  $V_k$  是观测噪声。假设噪声服从高斯分布, 即:

$$W_k \sim N(0, Q_k), V_k \sim N(0, R_k) \quad (5)$$

其中,  $Q_k$  和  $R_k$  分别为  $W_k$  和  $V_k$  的协方差矩阵。

**步骤 3** 利用 Kalman 滤波估算  $k$  时刻系统的状态量<sup>[15]</sup>。

1) 计算系统  $k$  时刻状态的预测值:

$$X_k^- = F_k X_{k-1} + B_k U_k \quad (6)$$

2) 计算预测值的协方差矩阵:

$$P_k^- = F_k P_{k-1} F_k^T + Q_k \quad (7)$$

其中,  $P_{k-1}$  为协方差矩阵。

3) 计算 Kalman 增益矩阵:

$$K_k = P_k^- H_k^T (H_k P_k^- H_k^T + R_k)^{-1} \quad (8)$$

4) 根据观测值来修正预测值, 得到系统状态量的最优估计:

$$\hat{X}_k = X_k^- + K_k (Z_k - H_k X_k^-) \quad (9)$$

5) 更新协方差矩阵:

$$P_k = (I - K_k H_k) P_k^- \quad (10)$$

在已知初始状态量和协方差矩阵的前提下, 重复以上步骤, 最后得到任意时刻系统的最优值。图 1 所示为 CSI 信号在滤波前后的对比示意图, 图 1(a) 中方框标识的是被剔除的异常值。

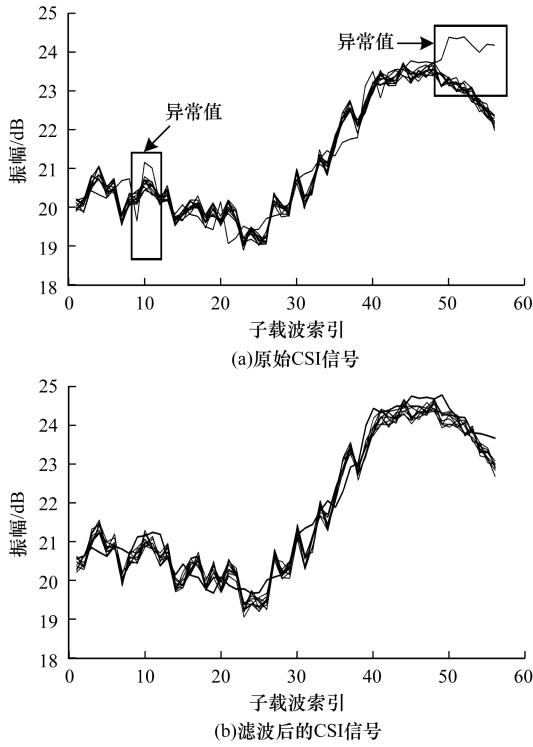


图1 CSI信号滤波前后对比

### 1.3 支持向量机

在机器学习中,SVM是一种与学习算法有关的监督学习模型,它可以进行数据分析、模式识别以及分类和回归分析<sup>[16]</sup>。给定一组训练样本,每个标记属于两类,一个SVM训练算法建立一个模型,将一个新实例分配给一个类或其他类,使它成为一个非概率的二元线性分类<sup>[17]</sup>。该特征可以有效结合CSI数据,从而降低算法时间复杂度,提高算法整体性能。第1.2节得到滤波后的振幅信息,本节利用SVM将滤波后的数据进行分类。

初始化阶段,将检测区域分为20个方格作为参考点,并按升序进行编号。然后,测试人员逐个遍历参考点,在每个参考点都进行站立、跳跃、半蹲、坐下4个动作。将此时所获得的CSI数据以及振幅、相位的变化传输到服务器。具体步骤如下:

**步骤1** 设 $T$ 为数据采样的周期,且 $T$ 为1s。在测试位置进行站立、跳跃、半蹲、坐下4个动作。假设接收端依次采样的样本训练集为: $\{(x_i, y_i)\}$ ,  $i=1, 2, \dots, n$ ,则SVM的回归函数为:

$$f(x) = w \cdot x + b \quad (11)$$

其中, $x$ 为从CSI振幅或相位数据中提取的特征, $w$ 为权向量, $b$ 为偏置向量。

**步骤2** 求解式(11)中的 $w$ 和 $b$ ,可得最小化目标函数<sup>[18]</sup>:

$$Q(w) = \frac{1}{2} \|w\|^2 + C \cdot R_{\text{emp}}(f) \quad (12)$$

其中, $C$ 为惩罚系数, $R_{\text{emp}}(f)$ 为损失函数。

**步骤3** 引入松弛因子,式(12)的优化目标函数转换为:

$$\min \frac{1}{2} \|w\|^2 + C \sum_{i=1}^l (\xi_i + \xi_i^*) \quad (13)$$

其中, $\xi_i, \xi_i^*$ 表示松弛因子。

**步骤4** 引入Lagrange函数,求解式(14)获得乘子 $\alpha_i, \alpha_i^*$ 。

$$\begin{aligned} \max = & \sum_{i=1}^l (\alpha_i - \alpha_i^*) y_i - \varepsilon \sum_{i=1}^l (\alpha_i + \alpha_i^*) - \\ & \frac{1}{2} \sum_{i,j=1}^l (\alpha_i^* - \alpha_i)(\alpha_j^* - \alpha_j) \langle x_i, x_j \rangle \end{aligned} \quad (14)$$

其中, $\varepsilon$ 为松弛变量。

**步骤5** 新的特征空间映射了原始数据,引入映射函数 $\varphi$ <sup>[19]</sup>,则SVM回归函数为<sup>[18]</sup>:

$$f(x) = w \cdot \varphi(x) + b \quad (15)$$

**步骤6** 式(15)的优化目标函数转化为:

$$\begin{aligned} \max = & \sum_{i=1}^l (\alpha_i - \alpha_i^*) y_i - \varepsilon \sum_{i=1}^l (\alpha_i + \alpha_i^*) - \\ & \frac{1}{2} \sum_{i,j=1}^l (\alpha_i^* - \alpha_i)(\alpha_j^* - \alpha_j) \langle \varphi(x_i), \varphi(x_j) \rangle \end{aligned} \quad (16)$$

**步骤7** 引入核函数 $k(x_i, x_j)$ 代替 $\langle \varphi(x_i), \varphi(x_j) \rangle$ ,式(16)转化为如下的优化目标函数:

$$\begin{aligned} \max = & \sum_{i=1}^l (\alpha_i - \alpha_i^*) y_i - \varepsilon \sum_{i=1}^l (\alpha_i + \alpha_i^*) - \\ & \frac{1}{2} \sum_{i,j=1}^l (\alpha_i^* - \alpha_i)(\alpha_j^* - \alpha_j) k(x_i, x_j) \end{aligned} \quad (17)$$

**步骤8** 最终SVM的预测函数为:

$$f(x, a_i, a_i^*) = \sum_{i=1}^l (a_i - a_i^*) k(x_i, x_j) + b \quad (18)$$

### 1.4 粒子群算法

传统SVM算法求解效率低,算法实时性较差<sup>[20]</sup>,考虑到PSO算法具有易搜索、收敛速度快、整体复杂度较低等优点。因此,本文选择PSO对SVM的参数和核函数进行修正,以提高算法的整体性能。当进行复杂搜索时,这一改进措施能够避免陷入局部最优解的情况<sup>[19]</sup>。PSO对SVM的参数和核函数进行修正的主要步骤如下:

**步骤1** 设 $D$ 维搜索空间中有 $n$ 个粒子。向量 $L_i = (x_{i1}, x_{i2}, \dots, x_{iD})$ 表示 $i$ 粒子的位置空间<sup>[19]</sup>,最优解为 $P_i = (p_{i1}, p_{i2}, \dots, p_{iD})$ 。

**步骤2** 设第 $g$ 个粒子的历史位置为局部最优解 $P_i (i=1, 2, \dots, n)$ 。

**步骤3** 第 $i$ 个粒子的速度用向量 $V_i = (v_{i1}, v_{i2}, \dots, v_{iD})$ 表示。

**步骤4** 按照如下公式进行每个粒子的位置变化:

$$\begin{aligned} V_{id}(t+1) = & w \times V_{id}(t) + c_1 \times \text{rand}() \times \\ & [P_{id}(t) - L_{id}(t)] + c_2 \times \text{rand}() \times \\ & [P_{gd}(t) - L_{id}(t)] \end{aligned} \quad (19)$$

$$\begin{aligned} L_{id}(t+1) &= L_{id}(t) + V_{id}(t+1) \\ 1 \leq i \leq n, 1 \leq d \leq D \end{aligned} \quad (20)$$

其中,速度变化区间为 $[-V_{\max}, V_{\max}]$ ,当第 $d(1 \leq d \leq D)$ 维的速度超过阈值或位置发生改变时,速度将取边界值, $c_1$ 、 $c_2$ 为加速因子, $\text{rand}()$ 是 $[0,1]$ 区间内的随机数。

步骤5 由于 PSO 算法随机产生位置与速度,因此通过式(19)、式(20)迭代,可以找到最优解。

## 2 Wi-SK 方法整体流程

本文 Wi-SK 方法主要包括 4 个模块:数据采集,数据处理,指纹库建立,特征信息匹配。Wi-SK 方法总体流程如图 2 所示。

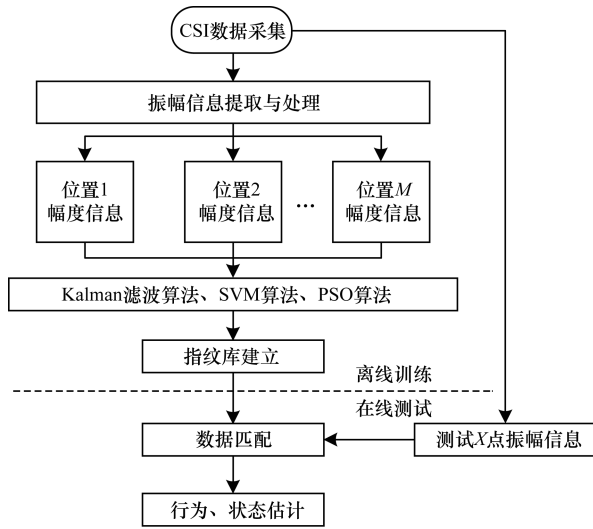


图2 Wi-SK 方法总体流程

### 2.1 离线训练阶段

在采集完 CSI 原始数据包后,进入离线训练阶段。在该阶段,首先收集各测试点的位置坐标,并对接收到的 CSI 原始数据进行处理,处理过程中先使用 Kalman 算法对原始数据进行滤波,再使用 SVM 算法对处理过的 CSI 数据实现分类;接着,将处理过的数据存到指纹库,并根据环境的变化情况实时更新指纹库。离线训练阶段具体步骤为:

步骤1 对 CSI 数据进行预处理,求出单个信道状态的频域模型,公式如下:

$$Y = HX + N \quad (21)$$

其中, $Y$ 为接收信号向量, $X$ 为发射信号向量, $H$ 为信道矩阵, $N$ 为高斯白噪声向量<sup>[18]</sup>。

步骤2 根据步骤1将所有子载波的 CSI 表示为:

$$CSI = \frac{Y}{X} \quad (22)$$

步骤3 将单个子载波的 CSI 表示为:

$$csi = |csi|e^{j\sin \angle csi} \quad (23)$$

其中, $|csi|$ 和 $\angle csi$ 分别表示对应于该子载波的幅度和相位。

步骤4 用 Kalman 滤波算法对步骤3中的振幅信息进行滤波处理。

步骤5 假设接收端依次采样的样本训练集为: $\{(x_i, y_i)\}, i=1, 2, \dots, n$ ,则 SVM 的回归函数为:

$$f(x) = w \cdot x + b \quad (24)$$

最小化目标函数为:

$$Q(w) = \frac{1}{2} \|w\|^2 + C \cdot R_{\text{emp}}(f) \quad (25)$$

式(25)的优化目标函数可以转换为<sup>[18]</sup>:

$$\min \frac{1}{2} \|w\|^2 + C \sum_{i=1}^l (\xi_i + \xi_i^*) \quad (26)$$

引入 Lagrange 函数,获得乘子 $\alpha_i, \alpha_i^*$ :

$$\begin{aligned} \max = & \sum_{i=1}^l (\alpha_i - \alpha_i^*) y_i - \varepsilon \sum_{i=1}^l (\alpha_i + \alpha_i^*) - \\ & \frac{1}{2} \sum_{i,j=1}^l (\alpha_i^* - \alpha_i)(\alpha_j^* - \alpha_j) \langle x_i, x_j \rangle \end{aligned} \quad (27)$$

则 SVM 回归函数可表示为:

$$f(x) = w \cdot \varphi(x) + b \quad (28)$$

式(25)的优化目标函数转化为:

$$\begin{aligned} \max = & \sum_{i=1}^l (\alpha_i - \alpha_i^*) y_i - \varepsilon \sum_{i=1}^l (\alpha_i + \alpha_i^*) - \\ & \frac{1}{2} \sum_{i,j=1}^l (\alpha_i^* - \alpha_i)(\alpha_j^* - \alpha_j) \langle \varphi(x_i), \varphi(x_j) \rangle \end{aligned} \quad (29)$$

引入核函数 $k(x_i, x_j)$ 代替 $(\varphi(x_i), \varphi(x_j))$ ,则式(29)转化为如下的优化目标函数:

$$\begin{aligned} \max = & \sum_{i=1}^l (\alpha_i - \alpha_i^*) y_i - \varepsilon \sum_{i=1}^l (\alpha_i + \alpha_i^*) - \\ & \frac{1}{2} \sum_{i,j=1}^l (\alpha_i^* - \alpha_i)(\alpha_j^* - \alpha_j) k(x_i, x_j) \end{aligned} \quad (30)$$

则最终的 SVM 预测函数为:

$$f(x, a_i, a_i^*) = \sum_{i=1}^l (a_i - a_i^*) k(x_i, x_j) + b \quad (31)$$

步骤6 利用第1.4节所述的 PSO 算法求得最优参数,再根据式(30)、式(31)结合幅度样本数据,从而构建 SVM 的分类模型。

### 2.2 在线行为检测阶段

在线行为检测阶段,发送端负责采集每个测试方格的实时 CSI 数据以及测试人员发生行为变化时的数据,再将采集到的数据发送给接收端。在线行为检测阶段主要步骤如下:

步骤1 在真实环境下采集实时数据。

步骤2 选择振幅作为特征值。

步骤3 设 $X_k$ 表示 $k$ 时刻系统的状态向量,则系统的状态转移方程如下<sup>[16]</sup>:

$$X_k = F_k X_{k-1} + B_k U_k + W_k \quad (32)$$

设 $Z_k$ 为 $k$ 时刻的观测向量,则观测方程为:

$$Z_k = H_k X_k + V_k \quad (33)$$

假设噪声服从高斯分布,即:

$$W_k \sim N(0, Q_k), V_k \sim N(0, R_k) \quad (34)$$

利用 Kalman 算法估算  $k$  时刻系统的状态量,步骤如下:

1) 计算系统  $k$  时刻状态的预测值:

$$\mathbf{X}_k^- = \mathbf{F}_k \mathbf{X}_{k-1} + \mathbf{B}_k \mathbf{U}_k \quad (35)$$

2) 计算预测值的协方差矩阵:

$$\mathbf{P}_k^- = \mathbf{F}_k \mathbf{P}_{k-1} \mathbf{F}_k^T + \mathbf{Q}_k \quad (36)$$

3) 计算 Kalman 增益矩阵:

$$\mathbf{K}_k = \mathbf{P}_k^- \mathbf{H}_k^T (\mathbf{H}_k \mathbf{P}_k^- \mathbf{H}_k^T + \mathbf{R}_k)^{-1} \quad (37)$$

4) 根据观测值来修正预测值,得到系统状态量的最优估计:

$$\hat{\mathbf{X}}_k = \mathbf{X}_k^- + \mathbf{K}_k (\mathbf{Z}_k - \mathbf{H}_k \mathbf{X}_k^-) \quad (38)$$

5) 更新系统状态量的协方差矩阵:

$$\mathbf{P}_k = (\mathbf{I} - \mathbf{K}_k \mathbf{H}_k) \mathbf{P}_k^- \quad (39)$$

**步骤 4** 利用 PSO 算法修正 SVM 算法中的参数  $C$ , 构建 SVM 分类模型对检测数据进行预测。

**步骤 5** 将实时采集的振幅数据与指纹库进行匹配。

**步骤 6** 设通过以上步骤得出的当前振幅的特征值为  $A$ , 离线阶段的阈值为  $B$ 。若  $A > B$ , 则可判断当前为非静止状态, 此时再次根据振幅的幅度变化进行匹配。图 3 所示为实验室环境下人员行为状态检测信号。从图 3(d) 可以看出, 此时的幅度波动较大, 说明动作幅度较大, 则可判断此时的行为是跳跃。图 3(b)、图 3(c) 的信号波动较小, 即动作较缓慢, 则可判断此时的行为是站立或半蹲。

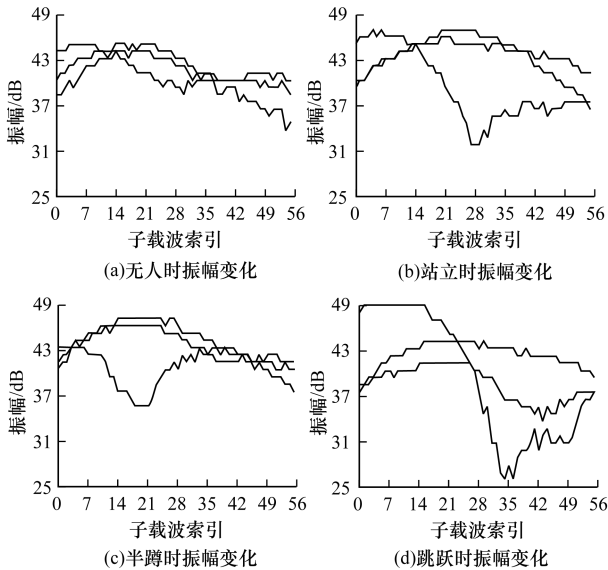


图 3 实验室环境下人员行为状态检测信号

### 3 实验结果与分析

#### 3.1 实验设备

本次实验所用的发射器和接收器均安装有支持 IEEE 802.11n 协议的 Atheros AR9580 NIC, 且安装了长度约为 1.5 m 的外部天线。所有发射器配备

Ubuntu 14.04 LTS, 32 bit 系统和 4.1.10 Linux 内核版本。驱动程序模块可以在接收到信号并将其保存为其他进程时从 Linux 内核获取 CSI。2 台英特尔酷睿 i3-4150 CPU 台式机, 一台作为发送端, 另一台作为接收端。所获得的数据在 C 程序中使用本文提出的 Wi-SK 算法进行处理。

#### 3.2 实验场景

本次实验分为 2 个场景: 实验室和大厅, 分别对应 NLOS 场景与 LOS 场景。实验室大小为 7 m × 5 m, 空旷大厅大小为 10 m × 8 m。实验场景平面结构如图 4 所示。

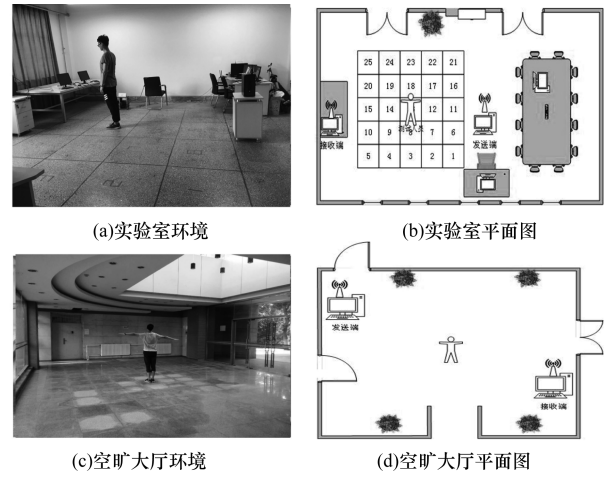


图 4 实验场景与平面部署

#### 3.3 系统性能分析

当监测区域中有人出现时, 利用部署好的实验设备接收数据包并发送给阅读器, 然后再转发到服务器。在本次实验中, 服务器端得到方向信息后, 目标将被检测。在检测过程中, 选用振幅信号作为特征值, 原因是振幅信号敏感度较高, 且容易获取。为证明振幅信号的这一特性, 本文分别在多径干扰较多的实验室内和较为空旷的大厅内进行对比测试, 结果如图 5 所示。从图 5 可以看出, 在实验室和大厅内测得的无人时 CSI 振幅变化存在明显区别, 图 5(b) 的信号波动较小, 整体趋势较平稳, 原因是空旷大厅内无过多的电磁干扰和多径干扰。因此, 本文实验选择振幅作为特征值是可行的。




图 5 实验室与空旷大厅无人时振幅信息对比

为验证本文 Wi-SK 方法的检测性能,本次实验将 Wi-SK 方法分别与 LIFS、FIMD、BFP 以及传统的基于 RSSI 的系统模型,在静态环境检测概率与动态环境检测概率、窗口大小、特征数、检测区域等方面,进行比较分析。

### 1) 静态环境下的检测概率

检测概率即为正确分类概率,在静态环境下称为 TN 率,图 6 所示为不同位置 and 不同时间点的 TN 率检测结果。从图 6 可以看出,经过多次测试,各方法的 TN 率均可达到 90% 以上。但是, RSSI 方法与 LIFS 方法的 TN 率值会受时间的影响,因此,会造成其性能不稳定的情况。而 Wi-SK 方法检测结果较平稳,整体性能优于其他 2 种方法。




图 6 静态环境下 3 种方法 TN 率对比

### 2) 动态环境下的检测概率

检测概率在动态环境下称为 TP 率,图 7 所示为不同位置 and 不同时间点的 TP 率检测结果。从图 7 可以看出,相比 RSSI 方法与 LIFS 方法, Wi-SK 方法可以更精确地检测人员的行为,即 Wi-SK 方法的效率更高。

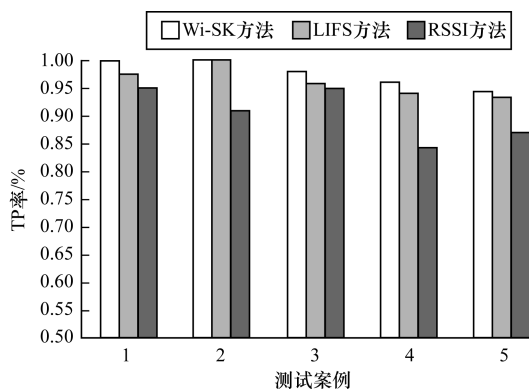


图 7 动态环境下 3 种方法 TP 率对比

### 3) 窗口大小的影响

由于窗口大小能够代表延迟的大小,且其对于检测率的整体性能起着重要作用。因此,本次实验选择窗口大小作为指标对不同方法的检测率进行评估。

从图 8 可以看出,3 种方法的检测率均随窗口大

小的增加而增加,但是当窗口大小超过某个阈值时, CSI 数据将通过人员的不同行为状态而产生差异,即对人员不同状态的检测率产生影响。当窗口较小时,系统很难检测到人员的存在,原因是方差的大小会降低系统的灵敏度,且系统对静态环境的区别度不高。从图中可以看出, Wi-SK 方法将滑动窗口大小设为 80 时可达较佳检测性能,且检测率较稳定。




图 8 检测率与窗口大小的关系

### 4) 特征数的影响

由于使用较多的特征数可能会导致较高的检测率,因此本文对传统的基于 RSSI 的方法和 FIMD 方法进行改进。FIMD 方法中使用相关矩阵的特征值,其最优值集中在前 2 个特征数。基于 RSSI 的方法不能在一段时间内保持稳定,其自身变化多端,对检测率造成相应的影响。而本文 Wi-SK 方法利用 CSI 稳定性高的特点,且实验的特征值使用的协方差矩阵更分散,因此检测率较高。

图 9 所示为检测率与特征数的关系。从图 9 可以看出,随着特征数的增加, Wi-SK 方法的检测率随之增加,且当特征数达到 5 时,其基本能够保持稳定状态。相比之下, FIMD 方法在特征数达到 4 之后,检测率有所下降,且不够稳定。




图 9 检测率与特征数的关系

### 5) 测试区域的影响

为测试人员在不同位置下的行为状态对检测率的影响,将实验区域划分成 20 个方格,并进行升序编号。在本次实验中,选择编号为 1~9 的格子进行

测试。

如图10所示,在4、5、6、7号格子区域内系统检测率较高,原因是这4个区域距离发送端与接收端较近,且无过多信号干扰。1~3格子的检测率都较低,原因是这3个区域距离接收端与发送端较远,且受到桌子、墙壁等多径效应的干扰。从图10还可以看出,Wi-SK方法的检测率高于其他2个方法。




图10 检测率与测试区域的关系

#### 4 结束语

本文提出一种基于CSI的室内人员行为检测方法Wi-SK。在数据处理方面,首先通过商用Wi-Fi设备采集CSI原始数据,将CSI中的振幅信息作为特征值,对其使用Kalman滤波、SVM算法、PSO算法进行相应处理,并建立指纹库;然后,在实验场景下采集实时数据,并将指纹库中的数据与实时采集的数据进行匹配,从而实现室内人员行为检测的目的。实验结果表明,Wi-SK方法在灵敏度、鲁棒性、检测率等方面均有较好表现,实用性较强。

#### 参考文献

- [1] 张伟江,余金森,郝平.基于线性参数加权评估机制的无线传感器网络节点定位[J].计算机工程,2017,43(2):156-162.
- [2] ZHOU Q, WU C, XING J, et al. Wi-dog: monitoring school violence with commodity WiFi devices [C]//Proceedings of International Conference on Wireless Algorithms, Systems, and Applications. Berlin, Germany: Springer, 2017:47-59.
- [3] 吴泽泰,蔡仁钦,徐书燕,等.基于K近邻法的WiFi定位研究与改进[J].计算机工程,2017,43(3):289-293.
- [4] YANG Z, ZHOU Z, LIU Y. From RSSI to CSI: indoor localization via channel response [J]. ACM Computing Surveys, 2013, 46(2):1-32.
- [5] WANG X, GAO L, MAO S, et al. CSI-based fingerprinting for indoor localization: a deep learning approach [J]. IEEE Transactions on Vehicular Technology, 2017, 66(1):763-776.
- [6] 高溪.基于信道状态信息的室内移动检测和定位技术研究[D].秦皇岛:燕山大学,2015.
- [7] XIAO J, WU K, YI Y, et al. FIMD: fine-grained device-free motion detection [C]//Proceedings of the 18th International Conference on Parallel and Distributed Systems. Washington D. C., USA: IEEE Press, 2012:229-235.
- [8] WANG G, ZOU Y, ZHOU Z, et al. We can hear you with Wi-Fi! [C]//Proceedings of the 20th Annual International Conference on Mobile Computing and Networking. New York, USA: ACM Press, 2014:593-604.
- [9] MATHECKEN P, RIHONEN T, WERNER S, et al. Constrained phase noise estimation in OFDM using scattered pilots without decision feedback [J]. IEEE Transactions on Signal Processing, 2017, 65(9):2348-2362.
- [10] LI Y, SESHADRI N, ARIYAVISITAKUL S. Channel estimation for OFDM systems with transmitter diversity in mobile wireless channels [J]. IEEE Journal on Selected Areas in Communications, 1999, 17(3):461-471.
- [11] QIAN K, WU C, ZHOU Z, et al. Inferring motion direction using commodity Wi-Fi for interactive exergames [C]//Proceedings of 2017 CHI Conference on Human Factors in Computing Systems. New York, USA: ACM Press, 2017:1961-1972.
- [12] XIE Y, LI Z, LI M. Precise power delay profiling with commodity WiFi [C]//Proceedings of International Conference on Mobile Computing and Networking. New York, USA: ACM Press, 2015:53-64.
- [13] LI J, LI Y, JI X. A novel method of Wi-Fi indoor localization based on channel state information [C]//Proceedings of International Conference on Wireless Communications and Signal Processing. Washington D. C., USA: IEEE Press, 2016:1-5.
- [14] 刘健,孔雨晨.使用线性卡尔曼滤波进行WiFi惯导的融合定位[J].电子测量技术,2017,40(4):1-4.
- [15] SJÖBERG M, KOSKELA M, VIITANIEMI V, et al. Indoor location recognition using fusion of SVM-based visual classifiers [C]//Proceedings of IEEE International Workshop on Machine Learning for Signal Processing. Washington D. C., USA: IEEE Press, 2010:343-348.
- [16] WANG J, JIANG H, XIONG J, et al. LiFS: low human-effort, device-free localization with fine-grained subcarrier information [C]//Proceedings of International Conference on Mobile Computing and Networking. New York, USA: ACM Press, 2016:243-256.
- [17] 杜晴岚.基于机器视觉的行人运动轨迹识别研究[D].西安:西安工业大学,2015.
- [18] 丁雪芳,王琪.基于改进支持向量机的Wi-Fi室内定位算法[J].计算机工程与应用,2016,52(6):90-93.
- [19] 李圣普,王小辉.基于PSO-SVM的电机故障检测[J].计算机系统应用,2016,25(3):136-141.
- [20] WANG Y, WU K, NI L M. WiFall: device-free fall detection by wireless networks [J]. IEEE Transactions on Mobile Computing, 2017, 16(2):581-594.

编辑 吴云芳