

## 基于全局相似度的社交网络个性化推荐算法

张艺豪<sup>1</sup>, 李 梁<sup>2</sup>, 赵清华<sup>1</sup>, 马建芬<sup>1</sup>, 段倩倩<sup>1</sup>

(1. 太原理工大学 信息与计算机学院, 太原 030024; 2. 太原师范学院 管理系, 山西 晋中 030619)

**摘 要:** 针对经典社交网络推荐算法忽略项目相似度信息的问题, 提出一种改进的社交网络个性化推荐算法。挖掘项目之间的全局项目相似度信息, 分析社交网络用户之间信任值的可靠度, 并将两者融合在一种模型中, 实现对用户的个性化推荐。在 Filmtrust 数据集与 Ciao 数据集上的实验结果表明, 与 PMF、SocialMF 和 SoRec 算法相比, 该算法能够提高推荐准确性, 降低在冷启动问题上的推荐误差。

**关键词:** 全局相似度; 个性化推荐; 社交网络; 数据挖掘; 机器学习

**中文引用格式:** 张艺豪, 李 梁, 赵清华, 等. 基于全局相似度的社交网络个性化推荐算法[J]. 计算机工程, 2018, 44(10): 204-208.

**英文引用格式:** ZHANG Yihao, LI Liang, ZHAO Qinghua, et al. Personalized recommendation algorithm of social network based on global similarity[J]. Computer Engineering, 2018, 44(10): 204-208.

## Personalized Recommendation Algorithm of Social Network Based on Global Similarity

ZHANG Yihao<sup>1</sup>, LI Liang<sup>2</sup>, ZHAO Qinghua<sup>1</sup>, MA Jianfen<sup>1</sup>, DUAN Qianqian<sup>1</sup>

(1. School of Information and Computer Science, Taiyuan University of Technology, Taiyuan 030024, China;

2. Management Department, Taiyuan Normal University, Jinzhong, Shanxi 030619, China)

**[Abstract]** Aiming at the problem of neglecting project similarity information in classical social network recommendation algorithm, an improved personalized recommendation algorithm for social network is proposed. The global project similarity information between projects is mined, and the reliability of trust values among social network users is analyzed, and the two are combined in a model to realize personalized recommendation to users. Experimental results on Filmtrust datasets and Ciao datasets show that, compared with PMF, SocialMF and SoRec algorithms, this algorithm can improve the accuracy of recommendation and reduce the recommendation error in cold start problem.

**[Key words]** global similarity; personalized recommendation; social network; data mining; machine learning

**DOI:** 10.19678/j.issn.1000-3428.0048752

### 0 概述

随着互联网的高速发展, 用户在海量互联网资源中一时难以搜索到自己的精确需求。推荐系统了解不同用户的个人喜好后给其推荐潜在需求商品, 能够提升用户体验并解决信息过载<sup>[1]</sup>问题。电子商务网站(如亚马逊、天猫网站)都搭建了自己的个性化推荐系统并获得了不少的收入增益。电子商务用户个人需求呈现长尾式分布<sup>[2]</sup>, 许多用户都有自己的独特需求与爱好, 目前个性化推荐系统已成为学术界与工业界的研究热点。

在推荐系统算法中, 协同过滤是易于解释、广泛应用的技术<sup>[3]</sup>。协同过滤从广义上分为基于内存的算法和基于模型的算法。基于内存的算法也

称为邻居方法, 分为用户邻居方法<sup>[4]</sup>与项目邻居方法<sup>[5]</sup>。用户邻居方法中每个用户与其他用户共同评分商品的记录, 采用余弦公式计算相似度并找出相似度最高的用户作为邻居, 根据邻居的历史购物商品为用户进行推荐。概率矩阵分解模型<sup>[6-7]</sup>提出用户的评分由2个低秩矩阵进行矩阵相乘来近似预测, 针对特定的用户与项目, 模型假设存在匹配的隐式用户特征向量与隐式项目特征向量。由于个性化推荐存在冷启动问题<sup>[8]</sup>, 新用户的评分记录很少甚至没有, 普通的模型无法很好地为新用户提供个性化推荐服务。为了解决冷启动与数据稀疏性问题, 研究者开始利用额外的信息进行模型训练, 比如社交网络中各个用户的信任关系<sup>[9]</sup>、用户进行交易项目的时间信息<sup>[10]</sup>等。文献[11]在概率

**基金项目:** 国家自然科学基金(51505324); 山西省国际科技合作计划项目(2013-036)。

**作者简介:** 张艺豪(1993—), 男, 硕士研究生, 主研方向为个性化推荐系统、模式识别; 李 梁, 讲师; 赵清华、马建芬、段倩倩, 副教授。

**收稿日期:** 2017-09-21    **修回日期:** 2017-10-24    **E-mail:** 328859599@qq.com

矩阵模型的基础上把用户信任融合到模型训练中,通过共享的低秩隐式用户特征矩阵进行项目评分和用户信任值的学习训练,巧妙地利用了社交网络用户之间的信任值,使其能够更好地训练用户特征向量。文献[12]认为用户的评分不仅取决于用户个人喜好,还受到社交网络中其他好友喜好的影响。文献[13]建立的社交网络模型不是对商品评分进行预测,而是融合社交网络信任信息单独预测用户特征向量,这种模型具有信任传播的效果。文献[14]提出将信任信息融合到模型正则项当中,迫使用户的特征向量与社交网络其他好友中相似用户的特征向量空间距离减小。

上述基于社交网络的推荐方法虽然利用了用户之间的信任关系,但忽略了项目之间的相似度信息。为此,本文挖掘项目之间的全局相似度信息,分析社交网络好友用户之间的相似度与信任值的可靠度,提出一种新的社交网络个性化推荐算法(Factored Item Similarity with Social Trust,FISS),并在 Filmtrust 数据集和 Ciao 数据集上进行对比实验。

## 1 概率矩阵分解与全局相似度

### 1.1 概率矩阵分解模型

概率矩阵分解模型假设评分矩阵可以分解为隐语义用户矩阵和项目矩阵,利用用户矩阵与项目矩阵的乘积去近似拟合用户评分矩阵,并假设评分矩阵服从均值为2个低秩隐语义矩阵乘积的高斯分布。用户评分数据的条件概率定义如下:

$$P(\mathbf{R}|\mathbf{U},\mathbf{V},\sigma_r^2) = \prod_{u=1}^N \prod_{i=1}^M [N(\mathbf{R}_{u,i}|g(\mathbf{U}_u^T \mathbf{V}_i),\sigma_r^2)]^{I_{u,i}^R} \quad (1)$$

$$g(x) = 1/(1 + e^{-x}) \quad (2)$$

其中, $N(\mathbf{R}_{u,i}|g(\mathbf{U}_u^T \mathbf{V}_i),\sigma_r^2)$ 是均值为 $g(\mathbf{U}_u^T \mathbf{V}_i)$ 、方差为 $\sigma_r^2$ 的正态分布。模型数据中共有 $N$ 个用户, $M$ 个物品, $\mathbf{R}_{u,i}$ 为用户 $u$ 对项目 $i$ 评分, $\mathbf{U}$ 和 $\mathbf{V}$ 代表用户和项目的隐语义特征。 $I_{u,i}^R$ 为指示函数,如果用户 $u$ 对项目 $i$ 评过分则函数值为1,否则为0。函数 $g(x)$ 分数映射到 $[0,1]$ 之间。另外模型还假设用户隐语义矩阵和项目隐语义矩阵都服从均值为0的高斯分布,定义如下:

$$P(\mathbf{U}|\sigma_u^2) = \prod_{u=1}^N N(\mathbf{U}|0,\sigma_u^2) \quad (3)$$

$$P(\mathbf{V}|\sigma_v^2) = \prod_{v=1}^M N(\mathbf{V}|0,\sigma_v^2) \quad (4)$$

基于贝叶斯概率公式最终推导出模型的损失函数为:

$$L = \frac{1}{2} \sum_{u=1}^N \sum_{i=1}^M I_{u,i}^R (\mathbf{R}_{u,i} - g(\mathbf{U}_u^T \mathbf{V}_i))^2 + \frac{\lambda_U}{2} \sum_{u=1}^N \|\mathbf{U}\|^2 + \frac{\lambda_V}{2} \sum_{v=1}^M \|\mathbf{V}\|^2 \quad (5)$$

其中,右侧第1项为误差的平方总和,第2项和第3项为正则化项<sup>[15]</sup>,从概率意义上说就是假设模型中

用户、项目隐语义服从均值为0的先验高斯分布,使模型的超参数变小,模型稳定,减小推荐结果的方差。

### 1.2 全局相似度

协同过滤邻居方法分为基于用户邻居方法和基于项目邻居方法。2种方法均利用项目之间的局部相似度,项目 $i$ 与项目 $j$ 之间的局部相似度通过共同购买过 $i$ 和 $j$ 的用户群的评分向量进行计算:

$$w_{i,j} = \cos(r_i, r_j) = \frac{\sum_{u \in G} r_{u,i} r_{u,j}}{\sqrt{\sum_{u \in G} r_{u,i}^2} \sqrt{\sum_{u \in G} r_{u,j}^2}} \quad (6)$$

其中, $w_{i,j}$ 为项目 $i$ 和 $j$ 的余弦相似度, $G$ 为购买过项目 $i$ 和 $j$ 的用户群。基于项目邻居方法计算所有项目与特定项目的相似度,然后选取相似度最高的 $k$ 个项目作为邻居项目,最终从邻居项目中选取用户未曾购买的项目进行推荐。一般情况下,电子商务网站项目数量远远小于用户数量,所以基于项目的邻居方法效率更高,更适合在线实时更新推荐系统。然而由于实际电子商务网站用户项目评分数据十分稀疏,许多项目对之间并没有共同购买过的用户群,那么基于项目的方法将无法计算这2个项目之间的相似度。因此邻居方法推荐性能存在瓶颈。

文献[16]针对推荐系统分数预测问题建立一种可以捕捉项目(商品)全局相似度的模型 FISM (Factored Item Similarity)。FISM 模型认为物品之间的相似度矩阵可以分解为项目隐语义矩阵和另一个同等大小的隐特征矩阵:

$$r_{u,i} = b_u + b_i + (n_u^+)^{-\alpha} \sum_{j \in R_u^+} p_j q_i^T \quad (7)$$

其中, $R_u^+$  是用户 $u$ 评分过的项目集合, $p_j$ 和 $q_i$ 表示项目隐特征向量, $n_u^+$ 表示被用户 $u$ 评分过的项目数量, $\alpha$ 表示模型的超参数,范围在 $[0,1]$ 之间。参数 $\alpha=1$ ,表示预测分数是项目 $i$ 与用户 $u$ 评分过的项目集合之间的平均相似度。如果项目 $i$ 与用户 $u$ 评分过的项目都相似,项目 $i$ 能够得到较高的分数。参数 $\alpha=0$ ,表示预测分数是项目 $i$ 与用户 $u$ 的评分项目相似度,的总和。FISM 模型通过矩阵因子学习项目之间的相似度,使项目之间没有共同购买的用户也能捕捉到项目之间的相似度,称之为全局相似度,它很好地突破了协同过滤中项目邻居方法的局部相似度的局限性。

## 2 融合全局项目相似度的社交网络推荐模型

### 2.1 全局项目相似度融合

项目全局相似度是一种提高社交网络推荐算法精度的重要信息,本文提出的 FISS 算法将社交网络用户信任关系与全局相似度融合在一种模型中,首先将式(7)更改如下:

$$r_{u,i} = b_u + b_i + (n_u^+)^{-\alpha} \sum_{j \in R_u^+} p_j \mathbf{V}_i^T + \mathbf{U}_u^T \mathbf{V}_i \quad (8)$$

本文认为预测分数不仅与项目全局相似度总和有关,还与用户隐语义矩阵、项目隐语义矩阵有着紧密联系,也就是与用户个人喜好、项目本身属性相关。通过调节参数  $\alpha$  可以控制全局相似度与隐语义矩阵对预测分数的影响比重。其中,项目是指针对某个特定用户购买过所有项目,也就是说本文只研究某个用户购买的项目之间的相似度,即用户的个人喜好。为了进一步融入社交网络信任关系,模型的损失函数定义如下:

$$L = \frac{1}{2} \sum_{u=1}^N \sum_{v=1}^M I'_{u,i} (r_{u,i} - U_u^T V_i)^2 + \frac{\beta}{2} \sum_{u=1}^N \sum_{f \in F(u)} \text{sim}(u, f) \|U_u - w_f U_f\|^2 + \frac{\lambda_U}{2} \sum_{u=1}^N \|U\|^2 + \frac{\lambda_V}{2} \sum_{v=1}^M \|V\|^2 + \frac{\lambda_P}{2} \sum_{j \in R_u^+} \|P\|^2 + \frac{\lambda_b}{2} (b_u^2 + b_i^2) \quad (9)$$

本文在式(9)中没有使用 Logistic 函数,对预测分数做了归一化预处理,将预测分数映射到 0 与 1 之间,减少了模型求梯度时的计算复杂度。其中,  $r_{u,i}$  定义见式(8),  $F(u)$  表示用户  $u$  的关注用户集合,也称为信任用户集合。  $\text{sim}(u, f)$  表示用户  $u$  和用户  $f$  的余弦相似度,定义如下:

$$\text{sim}(u, f) = \frac{\sum_{j \in I(u) \cap I(f)} r_{uj} r_{fj}}{\sqrt{\sum_{j \in I(u) \cap I(f)} r_{uj}^2} \sqrt{\sum_{j \in I(u) \cap I(f)} r_{fj}^2}} \quad (10)$$

其中,  $I(u)$  表示用户  $u$  购买过的项目集合,  $j$  表示用户  $u$  与用户  $f$  共同购买过的项目。  $r_{uj}$ 、 $r_{fj}$  表示用户  $u$ 、 $f$  在项目  $j$  上的评分。本文定义  $w_f$  表示用户  $f$  对其粉丝的信任可靠度,并认为某一个用户粉丝越多,这个用户就越值得信赖,或者称之为社交网络中某个领域的专家。

$$w_f = \frac{d_{-(f)}}{\sum_{v \in F_u^+} d_{-(v)}} \quad (11)$$

其中,  $d_{-(f)}$  表示用户  $f$  的粉丝数量,  $v$  表示用户  $u$  关注的用户集合。本文采用随机梯度下降的方法优化损失函数,对在模型学习过程中相似度高且信任关系强的 2 个用户,模型会迫使他们的隐式用户特征向量在空间上距离减小;相反地,对于相似度低、信任关系弱的 2 个用户,模型会迫使他们的隐式用户特征向量在空间上距离增大。

## 2.2 模型学习

为减少模型损失函数,得到近似精确隐式特征向量值,本文采用随机梯度下降优化模型,分别对特征向量  $b_u$ 、 $b_i$ 、 $U_u$ 、 $V_i$ 、 $P_j$  求导:

$$\text{error} = b_u + b_i + (n_u^+)^{-\alpha} \sum_{j \in R_u^+} P_j V_i^T + U_u^T V_i - r_{u,i} \quad (12)$$

$$\frac{\partial L}{\partial b_u} = \sum_{u=1}^N \sum_{v=1}^M I'_{u,i} \text{error} + \lambda_b b_u \quad (13)$$

$$\frac{\partial L}{\partial b_i} = \sum_{u=1}^N \sum_{v=1}^M I'_{u,i} \text{error} + \lambda_b b_i \quad (14)$$

$$\frac{\partial L}{\partial U_u} = \sum_{u=1}^N \sum_{v=1}^M I'_{u,i} \text{error} V_i + \beta \sum_{u=1}^N \sum_{f \in F(u)} \text{sim}(u, f) \cdot T_{uf} (U_u - w_f U_f) + \lambda_U U_u \quad (15)$$

$$\frac{\partial L}{\partial V_i} = \sum_{u=1}^N \sum_{v=1}^M I'_{u,i} \text{error} (U_u + (n_u^+)^{-\alpha} \sum_{j \in R_u^+} P_j) + \lambda_V V_i \quad (16)$$

$$\frac{\partial L}{\partial P_j} = \sum_{u=1}^N \sum_{v=1}^M I'_{u,i} \text{error} (n_u^+)^{-\alpha} + \lambda_P P_j \quad (17)$$

按照式(12)~式(17)以梯度相反的方向更新各个隐式特征向量,当  $\text{error}$  小于  $10^{-5}$  时,认为算法已经达到收敛,此时将学习到的各个特征向量利用式(8)预测用户最喜爱的项目,达到个性化推荐的效果。为了减少模型的复杂度,实验中设置  $\lambda_U = \lambda_V = \lambda_P = \lambda_b$ 。

## 3 实验结果与分析

### 3.1 数据集

本文实验采用文献[17]收集的 Filmtrust 数据集与 Ciao 数据集。Filmtrust 数据集是从国外 Filmtrust 网站上记录下来的数据总和,包括用户 ID、项目 ID、评分数据和社交网络关系信息。Ciao 数据集是从国外网上商品评论社区网站汇总的社交数据集,记录格式与 Filmtrust 数据集相同。数据集详细信息如表 1 所示,从表 1 可以看出,2 个数据集都非常稀疏。

表 1 数据集稀疏性分析

数据集	用户个数	项目个数	评分个数	社交网络关系记录个数	稀疏度
Filmtrust 数据集	1 508	2 071	35 497	1 853	0.011 3
Ciao 数据集	17 615	16 121	72 665	19 533	0.025 6

### 3.2 推荐精度评价指标

平均绝对误差 (Mean Absolute Error, MAE) 是绝对误差的平均值,均方根误差 (Root Mean Square Error, RMSE) 是误差的算术平方根,2 个指标均能很好地反映预测值误差的实际情况。公式分别定义如下:

$$M_{MAE} = \frac{1}{N} \sum_{i=1}^N |f_i - y_i| \quad (18)$$


$$R_{RMSE} = \sqrt{\frac{1}{N} \sum_{i=1}^N (f_i - y_i)^2} \quad (19)$$

其中,  $N$  为测试集数量,  $f_i$  为预测值,  $y_i$  为实际值。RMSE、MAE 指标均是误差指标,指标越小,推荐精度越高。

#### 3.2.1 实验对比算法

本文选取的对比算法分别为 PMF、SocialMF 和 SoRec 经典算法。PMF 算法是概率矩阵分解算法最基础的模型。SocialMF 算法提出的社交网络模型不同于先前的研究对分数进行预测,而是融合社交网络信任信息单独预测用户特征向量,这种模型取得了信任传播的效果。SoRec 算法在概率矩阵模型的基础上把用户信任融合到模型训练中,通过共享的

低秩隐式用户特征矩阵进行项目评分和用户信任值的学习训练,巧妙地利用了社交网络用户之间的信任值,使其能够更好地训练用户特征向量。本文所有实验结果均是重复5次实验所求的平均值,为了降低模型复杂度以及提高实验效率,本文实验所有算法正则项系数均设为0.01。



### 3.2.2 结果分析

本文主要设计2个实验。第1个实验将数据集按照不同的百分比分成训练集和测试集,训练集分别占80%、65%、50%、35%、20%,然后进行不同算法的实验并记录推荐误差指标值,实验结果如图1和图2所示。




图1 不同算法在2种数据集上的MAE指标比较

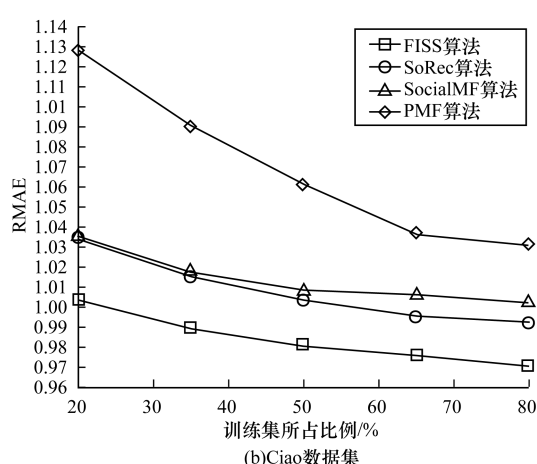



图2 不同算法在2种数据集上的RMSE指标比较

由图1可知,实验中的所有算法均在训练集为整个数据集的80%时推荐精度最高,随着训练集数量比重的减小,推荐精度逐步降低。PMF算法作为基本的概率矩阵分解模型,没有利用社交网络信息,所以误差指标最高,推荐效果最差;本文FISS算法精度最高且具有普适性。如对于Filmtrust数据集,在训练集百分比为80%的实验条件下,FISS算法相比PMF算法精度提高了8.4%,相比SoRec算法精度提高了7.6%,相比SocialMF算法精度提高了2.9%。大量研究表明误差减小0.01都可能引起推荐结果本质性的变化,说明本文算法较其他算法推荐效果更佳。由图2可知,FISS算法均方根误差在所有实验条件下均最小,SocialMF算法与SoRec算法以不同的方式融合了社交网络信任关系,相比PMF算法误差较小,然而

这2种算法都忽略了项目之间相似度的信息,FISS算法因为融合了社交网络和项目全局相似度信息,所以在RMSE指标上较其他社交网络算法表现更佳,达到了更好的推荐效果。

第2个实验本文分析推荐领域的冷启动问题。冷启动问题在推荐领域一直存在,新用户由于存在极少的购物记录,模型无法很好地捕捉到新用户的个人喜好。新项目由于没有任何用户购买过,无法很好地匹配到对应的感兴趣用户。新用户一般只有极少的历史购买项目行为,分析他们的个性化喜好对推荐系统来说一直是个挑战。从2种数据集中抽出购买记录少于5条的用户组成新的冷启动用户群并作为测试集,然后在不同的数据集上进行不同算法的实验并记录推荐误差指标,结果如表2所示。其中,All代表整体测试集,Coldstart代表冷启动用户测试集。

表 2 不同算法在 2 种数据集上针对冷启动问题的 RMSE 指标比较

算法	Filmtrust 数据集		Ciao 数据集	
	All	Coldstart	All	Coldstart
PMF 算法	0.851 4	0.922 1	1.030 7	1.063 2
SocialMF 算法	0.833 0	0.910 4	1.002 5	1.021 6
SoRec 算法	0.825 7	0.905 3	0.992 0	1.010 5
FISS 算法	0.807 8	0.896 0	0.970 6	0.981 4

在 Filmtrust 数据集与 Ciao 数据集上的实验结果表明,冷启动用户的推荐误差大于整体测试集的误差,证明新用户的个性化喜好较难捕捉到,推荐效果会变差。相比于其他 3 个算法,本文 FISS 算法在不同数据集上都表现最佳,推荐精度最高。在 Filmtrust 整体测试集上的实验,FISS 算法比 PMF 算法误差减小 0.043 6,比 SocialMF 算法误差减小 0.025 2,比 SoRec 算法误差减小 0.017 9。比较 2 种数据集整体测试集与冷启动测试集得出,社交网络推荐算法在 Ciao 数据集上冷启动误差提高了 0.010 8,在 Filmtrust 数据集上平均误差提高了 0.088 2,推荐效果大幅下降。这是因为 Ciao 数据集相比较 Filmtrust 数据集存在更多的社交网络信任记录,模型能够充分利用社交关系提升推荐算法性能,也证明了融合社交网络信息到推荐模型中可以有效提高推荐精度。

#### 4 结束语

社交网络推荐算法在概率矩阵分解基础上利用社交网络用户之间的信任关系作为额外信息,能够很好地解决数据稀疏和冷启动问题。本文基于社交网络推荐算法,挖掘项目之间的全局相似度以及分析用户之间信任的可靠度,提出一种结合项目全局相似度的社交网络关系个性化推荐算法。在 Filmtrust 数据集和 Ciao 数据集上进行了不同算法的对比实验与冷启动实验,结果表明,相比 PMF 算法、SocialMF 算法和 Sorec 算法,本文算法获得了更高的推荐精度,在冷启动问题上推荐误差大幅减小。下一步考虑将已知算法与时间、地理位置网络和社交网络信息进行结合,以提高推荐精度。

#### 参考文献

- [1] EDMUNDS A, MORRIS A. The problem of information overload in business organisations: a review of the literature [J]. International Journal of Information Management, 2000, 20(1): 17-28.
- [2] 王谷音, 叶丰滢. 长尾式商业模式应用环境分析[J]. 时代金融, 2017(15): 238.
- [3] LINDEN G, SMITH B, YORK J. Amazon.com recommendations: item-to-item collaborative filtering [J]. IEEE Internet Computing, 2003, 7(1): 76-80.
- [4] ZHAO Z D, SHANG M S. User-based collaborative-filtering recommendation algorithms on hadoop [C]//Proceedings of the 3rd International Conference on Knowledge Discovery and Data Mining. Washington D. C., USA: IEEE Press, 2010:

478-481.

- [5] SARWAR B, KARYPIS G, KONSTAN J, et al. Item-based collaborative filtering recommendation algorithms [C]//Proceedings of the 10th International Conference on World Wide Web. New York, USA: ACM Press, 2001: 285-295.
- [6] SALAKHUTDINOV R, MNH A. Probabilistic matrix factorization [C]//Proceedings of the 20th International Conference on Neural Information Processing Systems. [S. l.]: Curran Associates Inc., 2007: 1257-1264.
- [7] 李卫疆, 齐 静, 余正涛, 等. 融合信任传播和奇异值分解的社会化推荐算法 [J]. 计算机工程, 2017, 43(8): 236-242.
- [8] XUAN N L, VU T, LE T D, et al. Addressing cold-start problem in recommendation systems [C]//Proceedings of the 2nd International Conference on Ubiquitous Information Management and Communication. New York, USA: ACM Press, 2008: 208-211.
- [9] CHOW W S, LAI S C. Social network, social trust and shared goals in organizational knowledge sharing [J]. Information and Management, 2008, 45(7): 458-465.
- [10] SONG Y, ZHUANG Z, LI H, et al. Real-time automatic tag recommendation [C]//Proceedings of the 31st Annual International ACM SIGIR Conference on Research and Development in Information Retrieval. New York, USA: ACM Press, 2008: 515-522.
- [11] MA H, YANG H, LYU M R, et al. SoRec: social recommendation using probabilistic matrix factorization [C]//Proceedings of the 17th ACM Conference on Information and Knowledge Management. New York, USA: ACM Press, 2008: 931-940.
- [12] MA H, KING I, LYU M R. Learning to recommend with social trust ensemble [C]//Proceedings of the 32nd International ACM SIGIR Conference on Research and Development in Information Retrieval. New York, USA: ACM Press, 2009: 203-210.
- [13] JAMALI M, ESTER M. A matrix factorization technique with trust propagation for recommendation in social networks [C]//Proceedings of the 4th ACM Conference on Recommender Systems. New York, USA: ACM Press, 2010: 135-142.
- [14] MA H, ZHOU D, LIU C, et al. Recommender systems with social regularization [C]//Proceedings of the 4th ACM International Conference on Web Search and Data Mining. New York, USA: ACM Press, 2011: 287-296.
- [15] KOREN Y. Factorization meets the neighborhood [C]//Proceeding of the 14th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining. New York, USA: ACM Press, 2008: 426-434.
- [16] KABBUR S, NING X, KARYPIS G. FISM: factored item similarity models for top-N recommender systems [C]//Proceedings of the 19th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining. New York, USA: ACM Press, 2013: 659-667.
- [17] GUO G, ZHANG J, THALMANN D, et al. ETAF: an extended trust antecedents framework for trust prediction [C]//Proceedings of 2014 IEEE International Conference on Advances in Social Networks Analysis and Mining. Washington D. C., USA: IEEE Press, 2014: 540-547.

编辑 司森森