

基于多特征融合与双向 RNN 的细粒度意见分析

郝志峰^{1,2}, 黄 浩¹, 蔡瑞初¹, 温 雯¹

(1. 广东工业大学 计算机学院, 广州 510006; 2. 佛山科学技术学院, 广东 佛山 528000)

摘 要: 文本细粒度意见分析主要有属性抽取和基于属性的情感分类 2 个任务, 现有方法完成上述任务采用条件随机场(CRF)训练属性抽取模型, 并运用循环神经网络(RNN)训练基于属性的情感分类模型。但同时完成 2 个任务则无法找到属性和情感倾向的对应关系。针对该问题, 提出利用双向 RNN 构建基于序列标注的细粒度意见分析模型。通过融合文本的词向量、词性和依存关系等语言学特征, 学习文本的修饰和语义信息, 并设计一个时间序列标注模型, 同时抽取属性实体判断文本的情感极性。在真实数据集上的实验结果表明, 与 CRF、TD-LSTM、AE-LSTM 等模型相比, 该模型情感分类效果提升明显。

关键词: 特征融合; 词向量; 循环神经网络; 属性抽取; 细粒度意见分析

中文引用格式: 郝志峰, 黄 浩, 蔡瑞初, 等. 基于多特征融合与双向 RNN 的细粒度意见分析模型[J]. 计算机工程, 2018, 44(7): 199-204, 211.

英文引用格式: HAO Zhifeng, HUANG Hao, CAI Ruichu, et al. Fine-grained opinion analysis based on multi-feature fusion and bidirectional RNN[J]. Computer Engineering, 2018, 44(7): 199-204, 211.

Fine-grained Opinion Analysis Based on Multi-feature Fusion and Bidirectional RNN

HAO Zhifeng^{1,2}, HUANG Hao¹, CAI Ruichu¹, WEN Wen¹

(1. School of Computers, Guangdong University of Technology, Guangzhou 510006, China;

2. Foshan University, Foshan, Guangdong 528000, China)

[Abstract] Text fine-grained opinion analysis mainly includes attribute extraction and attribute-based sentiment classification. The existing methods accomplish the above tasks by adopting Conditional Random Field (CRF) training attribute extraction model and using a Recurrent Neural Network (RNN) to train attribute-based emotion classification model. However, the completion of two tasks at the same time can not find the corresponding relationship between attributes and emotional tendencies. To solve this problem, a two-dimensional RNN is proposed to build a fine-grained opinion analysis model based on sequence annotation. By merging the linguistic features of the text, such as word vectors, part of speech and dependence, it learns the text's modification and semantic information, designs a time series annotation model, and extracts attribute entities to determine the sentiment polarity of the text. Experimental results on real datasets show that compared with CRF, TD-LSTM, AE-LSTM and other models, the emotional classification effect of this model obviously improves.

[Key words] feature fusion; word vector; Recurrent Neural Network (RNN); attribute extraction; fine-grained opinion analysis

DOI: 10.19678/j.issn.1000-3428.0047729

0 概述

目前互联网每天都会产生大量的文本数据, 如电商评论数据、社交网站数据、新闻数据等。挖

掘和利用这些数据, 使其能应用到推荐系统、广告投放、形势预测等, 从而可以提高用户体验和服务质量。针对这些问题的数据挖掘和分析有很多研究, 如文本数据有关系抽取^[1]、情感分析和意见

基金项目: 国家自然科学基金-广东联合基金(U1501254); 广东省自然科学基金(2014A030306004, 2014A030308008); 广东省科技计划项目(2015B010108006, 2015B010131015); 广东特支计划项目(2015TQ01X140); 广州市珠江科技新星专项(201610010101); 广州市科技计划项目(201604016075)。

作者简介: 郝志峰(1968—), 男, 教授, 主研方向为机器学习、人工智能; 黄 浩(通信作者), 硕士研究生; 蔡瑞初, 教授; 温 雯, 副教授。

收稿日期: 2017-06-27 **修回日期:** 2017-08-30 **E-mail:** huanghaocn@126.com

挖掘^[2]、智能问答系统、用户行为预测分析等,其中,意见挖掘和情感分析是近年来非常热门的研究领域。

意见挖掘和情感分析是针对主观性文本自动获取有用的意见信息和知识,文献[3]对文本意见挖掘的定义、研究目的和现状进行了阐述,并介绍了成型的应用系统。文献[4]总结了文本倾向性分析的3类研究方法,分别是简单统计方法、机器学习方法和细粒度情感相关性分析方法。文献[5]通过抽取文本中不同语义情感强度词来判断整个文本最可能的情感极性。文献[6]总结了目前在情感分析和意见挖掘领域的具体细分的研究方向和现有方法。现有的这些方法是分阶段分任务完成,对同时抽取属性和判断情感分析则少有研究,同时完成2个任务存在的问题是无法知道哪些词是实体或属性,找出的评价词是对哪个实体或属性的评价等问题。细粒度意见分析和挖掘根据不同的应用领域属性或实体会有不同的含义。如针对电子商务评论属性是指产品的质量、价格、外观等;针对酒店评论属性是指环境、服务、价格、餐饮等。总之,细粒度意见挖掘和分析就是对于一个具体领域,通过文本数据挖掘出很细致的实体、属性、特征等,并分析用户对它们的主观情感倾向。

在上述研究基础上,本文研究的细粒度意见分析是在未给定属性或实体集合的情况下,通过一部分标注数据,用有监督方法来完成实体或属性的提取,并判断每个实体或属性的情感极性。具体是通过融合文本数据的多种语言学特征,利用循环神经网络为基础,构建一个时间序列标注模型,同时抽取属性和实体并判断它们的情感极性。

1 相关工作

细粒度意见挖掘和分析主要有2个任务:评价对象或评价词的抽取以及情感极性的判断。具体方法分为两类:一类是传统模板匹配和机器学习的方法;另一类是神经网络和深度学习的方法。对于细粒度意见挖掘任务的研究,集中在给定属性或实体,基于属性或实体来判断不同的情感倾向。如一条针对电子产品的评论,“性价比已经很高了,但是电池不怎么样,很快就没电了!”,如给定“价格”“电池”2个属性,从这条评论能够分析出“价格”是正面的,而“电池”是负面的。图1为现有方法模型的总体流程。首先找到实体和属性,然后基于找到的实体和属性判断情感倾向。

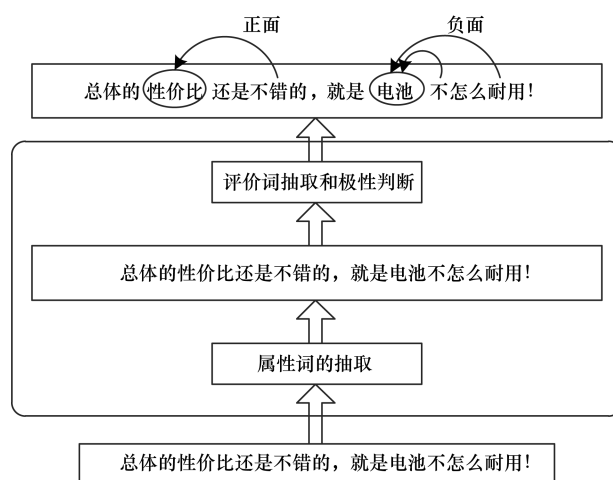


图1 传统属性抽取和极性判断方法流程

1.1 实体与属性抽取

属性抽取主要是从文本中提取出关键的词或词组以及一些实体或特征,一类是针对产品各方面属性的实体抽取,另一类是通用的命名实体识别,目前的研究主要集中在传统的机器学习方法上。如文献[7]通过关联规则挖掘出频繁的名词和名词短语作为产品的高频属性,然后通过情感词和低频的名词和名词短语的共现提取低频属性词,由此来提取属性。文献[8]通过候选特征和指定关系短语之间的共现程度提取出产品的属性和实体。文献[9]用条件随机场(Conditional Random Field, CRF)序列标注的方法,以词本身、词性、词上下文作为标注特征来标记和抽取属性词。文献[10]使用 skip-chain CRF 来完成产品命名实体识别和抽取,不仅考虑了相邻词之间的关系,而且还考虑了连接词两边的词之间关系。文献[11]使用依存解析树来识别属性中的依存关系,从而抽取属性。文献[12]使用依存关系树来发现属性词和评价词的候选值,然后完成筛选。文献[13]提出完整评价对象抽取方法,可以抽取低频和分词结构复杂的评价对象。

1.2 基于属性的情感分析

基于属性的文本情感分析目前很多研究都是运用神经网络和深度学习的方法。而深度学习在文本情感分析等自然语言处理方向的兴起,主要是神经网络语言模型和词向量表示的发展。神经网络语言模型最具代表性的是文献[14]提出的三层神经网络语言模型,其方法是根据前 $n-1$ 个词来预测第 n 个词,由此可以训练一个词向量表示。文献[15]使用循环神经网络(Recurrent Neural Network, RNN)来学习语言模型。而词向量最具代表性的是文献[16]中通过神经网络训练 CBOW 和 Skip-gram 语言模型所得的 Word2Vec 模型。

具体到意见挖掘和情感分析在深度学习中的研究,基本是以 Word2Vec 等模型训练好的词向量作为特征输入神经网络,如文献[17-18]用双向循环神经网络(BRNN)序列标注的模型来识别评论数据中的属性和实体等关键词。文献[19]利用 Sem Eval2014 评测数据集构建一个两层神经网络完成属性词分类,然后用词向量、属性词分类、句法依存关系作为卷积神经网络(CNN)的输入预测情感极性。

在基于给定属性词集合或目标词的情感分析任务中,文献[20]提出基于 LSTM 的 2 种改进模型,主要是以目标词在句子中的位置左右各接 LSTM 网络,并把目标词作为 LSTM 网络最后一个输入单元,这样可以充分利用目标词的语义信息。文献[21]借鉴文献[22]中的记忆网络而提出深度记忆网络,该记忆网络每次读取整个句子的信息作为记忆存储起来,比如上下文的语义信息,还加入了属性词的上下文和位置信息等,从而判断句子在该属性下的情感极性。文献[23]在 LSTM 中加入注意力机制,提出 2 种模型 AT-LSTM 和 ATAE-LSTM 来完成基于属性词的情感分类,在隐藏层中加上属性词,通过注意力机制来学习哪些上下文对属性词更重要。

在上述的研究中,首先是对句子完成属性抽取,然后基于抽取到的属性做情感极性分类任务,较少有同时完成 2 个任务的方法。而且用神经网络和深度学习的方法将基于词的表示学习的词向量作为特征输入网络,这样缺失了传统的语言学特征,如词性、依存关系等,本文将这些语言学特征结合词向量表示,能够更好地学习文本中的上下文语义信息,有利于属性抽取和情感极性判断。

2 细粒度意见分析联合模型

本文的细粒度意见分析联合模型还是以属性抽取和情感极性判断 2 个任务为出发点,提出的模型是在词向量的基础上,加入传统的语言学特征,能够更好地学习文本的修饰和语义信息,从而更准确地理解文本的上下文。细粒度意见分析模型的构建分为 3 个部分:文本特征提取和融合,双向循环神经网络模型的构建,序列标注模型的训练。

2.1 特征提取与融合

词向量是对文本的低维特征表示,它可以度量同义词以及相同上下文的词之间的关系。文中使用了 Word2Vec 模型来训练词向量,使用的语料是维基百科语料和实验数据集结合,具体使用了 skip-gram 语言模型,词向量的纬度为 50,上下文窗口为 5。如果语料足够丰富,学习出来的词向量就能准确表达词的语义。

词性可以提取出词与词之间的修饰关系,如给定文本中一个词的词性,可以推测它的前后相邻词的词性,这样有助于关键信息抽取。把输入的文本分词变成单个词序列,并利用 LTP 工具得到一个词性标注序列,而每个词的词性都是有固定类别(如名词-n、动词-v、形容词-p),本文取 20 个出现最多的词性标签。

依存关系可以表示文本中的语法关系和远距离语义信息,从而更好地理解上下文表达的语义。本文是通过 LTP 工具来标注词之间的依存关系,可以用三元组表示 (w_1, w_2, s) , 其中 w_1, w_2 表示 2 个词, s 表示它们之间的依存关系标签(如主谓关系-SBV、动宾关系-VOB)。 w_1, w_2 用词向量表示,关系标签 s 有 15 种,图 2 是一个词性标注和依存关系标注的实例。




图2 词性标注和依存关系的实例

对于一个文本预处理分词后,变成一个词序列为 $X = \{w_1, w_2, \dots, w_n\}$, 其对应的词性标注序列为 $P = \{p_1, p_2, \dots, p_n\}$, 对应的依存关系标签序列为 $L = \{s_1, s_2, \dots, s_n\}$, 每一种关系是输入序列中 2 个元素的关系对,记为 $R = \{r_1, r_2, \dots, r_n\}$, 其中 $r = (w_i, w_j)$, 所以,词 x_i 与 x_j 之间的依存关系可用三元组 (w_i, w_j, s_k) 表示。把这些特征都向量化作为模型的输入,其中每个时刻的输入 M 是由这些特征融合拼接所得。其中词性和依存关系标签使用 One-Hot 向量表示,依存关系对用 2 个词的词向量表示。式(1)是 M 的融合过程,其中, N 是词向量的纬度, N_1 是依存关系种类个数, N_2 词性标签种类个数。这里 w, s, r, p 的顺序并不是固定的,只要保证模型中全部使用相同的顺序即可,学习过程中会自动调整每一项的权重。

$$M(x_i) = ([w]_i^N; [s]_i^{N_1}; [r]_i^{N_2}; [p]_i^{N_2}) \quad (1)$$

2.2 属性抽取与极性分析联合模型

联合模型的构建是以循环神经网络(RNN)为基础,RNN 主要是用来解决序列问题,网络内部会对过去的信息进行记忆,保存在网络的内部状态,并应用于当前输出的计算中。对于有些序列问题,考虑到前面和后面的信息都会影响当前的信息,因此

就提出了双向循环神经网络(BRNN)。BRNN 是在每一个序列向前和向后各用一个标准 RNN,当前的输出与它前后时刻隐藏层的输出都有一定的关系,即最后的输出层是由前向和后向隐藏层决定。属性抽取 (Aspect Extraction) 与极性分析 (Polarity Classification) 联合模型是在 BRNN 的基础上构建的序列标注模型,简称为 AP-BRNN,模型中输入层是由前面融合的特征 M 构成,式(2)~式(4)是前后隐藏层、输出层的具体计算过程。

$$\vec{h}_t = f(\vec{W}M(x_t) + \vec{V}\vec{h}_{t-1} + \vec{b}) \quad (2)$$

$$\overleftarrow{h}_t = f(\overleftarrow{W}M(x_t) + \overleftarrow{V}\overleftarrow{h}_{t+1} + \overleftarrow{b}) \quad (3)$$

$$y_t = g(Uh_t + c) = g(U[\vec{h}_t; \overleftarrow{h}_t] + c) \quad (4)$$

其中, W, V, U 为权重矩阵, b, c 为偏置, h_t 表示 t 时刻隐藏层的输出。

上面的标准 RNN 训练过程中随着时间的推移,无法记忆长时依赖问题,因此,下面提出了对 RNN 的内部结构的改进模型 LSTM,它主要在隐藏层的输入和输出引入了 3 个控制门,分别是遗忘门 f_t 、输入门 i_t 、输出门 o_t 、记忆单元 c_t 。式(5)~式(10)是模型设计和计算过程。

$$i_t = \sigma(W_i \cdot [h_{t-1}, M(x_t)] + b_i) \quad (5)$$

$$f_t = \sigma(W_f \cdot [h_{t-1}, M(x_t)] + b_f) \quad (6)$$

$$o_t = \sigma(W_o \cdot [h_{t-1}, M(x_t)] + b_o) \quad (7)$$

$$g_t = \tanh(W_r \cdot [h_{t-1}, M(x_t)] + b_r) \quad (8)$$

$$c_t = i_t \circ g_t + f_t \circ c_{t-1} \quad (9)$$

$$h_t = o_t \circ \tanh(c_t) \quad (10)$$

其中, σ 表示 sigmoid 激活函数,式(10)中的 h_t 对应式(2)、式(3)中的 \vec{h}_t 和 \overleftarrow{h}_t 。

目前以 RNN 模型为基础来完成的各项任务中,模型的内部单元结构基本都用 LSTM,本文构建的序列标注模型内部基本单元也是 LSTM,这样就可以记忆上下文的远距离语义信息,从而可以更好地预测结果。整个模型结构如图 3 所示。

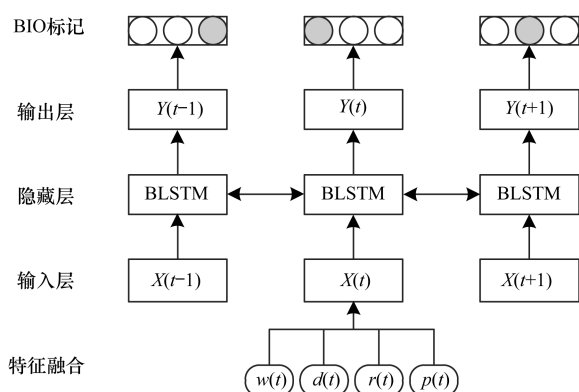


图 3 特征融合的 AP-BLSTM 序列标注模型

联合模型的输出层接一个激活函数进行分类,用三组实体标记(BIO),即 7 个类别(B1, I1, B2, I2, B3, I3, O)表示分类结果,从而区分出抽取的属性根据它的上下文不同有 3 种(正面,负面,中性)情感极性可能。这里 BIO 标记中的 B、I、O 分别表示当前词是属性词的开始、中间和非属性词标志,从标记结果中抽取一些词或词组作为属性词,而情感极性根据属性所在的标记组可以直接判断出来。

2.3 模型的训练

对于模型的训练过程和参数设置问题,为了加快模型的训练,使用了批量训练法,设置批量大小为 200,对于长度不等的句子进行填充,保证每次批量训练的句子长度一致。

句子中每个词的真实标记为 y ,模型预测输出值记为 \hat{y} ,目标函数是计算真实值和预测值的交叉熵,使用梯度下降算法求交叉熵的最小值,从而使预测值逐渐接近真实值。同时为了防止过拟合,设置了训练提前结束,具体是设定一个数值 $n = 50$,交叉熵在 n 次迭代没有达到之前的最好值就可以提前结束训练。交叉熵的计算方法如式(11)所示。

$$loss = -\frac{1}{m} \sum_m \sum_i y_i^j \log_a \hat{y}_i^j + \frac{\lambda}{2} ||\theta||^2 \quad (11)$$

其中, m 表示句子的索引, i 表示文本中词的索引, j 表示分类的索引, λ 是 L2 正则化项, θ 是它的参数。

3 实验评估

3.1 实验设置

本文实验数据来自文献[24]使用的数据集,该数据集是关于电子产品的评论,包括评论文本、抽取出的属性、评价词和情感极性。总数据量有 10 万多条,共有属性词 20 万个,属性词的情感极性分布为正面 81%、负面 13%、中性 6%。本文选取了其中 5 万条作为训练集,1 万条作为验证集,1 万条作为测试集。表 1 是选取的数据集中属性及属性的情感极性分布。

表 1 实验数据具体分布

数据集	数据量	属性总数	正面	负面	中性
训练集	50 000	90 521	73 998	11 833	4 430
验证集	10 000	19 847	15 831	3 011	1 005
测试集	10 000	20 633	16 769	2 776	1 088

在数据预处理阶段,用维基百科语料结合实验数据集一起训练词向量。同时提前预处理得到每一条数据的词性序列和依存关系序列。

3.2 评估标准

对于实验结果的评价标准,本文按照多标签分类来计算准确率(Precision)、召回率(Recall)和 F_{Score} 3 个指标。根据预测的标记序列抽取出属性并判断情感倾向后,以二元组(属性,情感极性)的方式呈现结果。如果有 N 个样本数据,每个样本的标注是该样本中出现的二元组属性集合,每个样本的预测值也是用二元组标注的结果。样本真实值为: (T_1, T_2, \dots, T_N) , 样本预测值为 (P_1, P_2, \dots, P_N) , 下面为 3 个评价指标的具体计算方法。

$$P_{\text{Precision}} = \frac{\sum_{i=1}^N |T_i \cap P_i|}{\sum_{i=1}^N |P_i|}$$

$$R_{\text{Recall}} = \frac{\sum_{i=1}^N |T_i \cap P_i|}{\sum_{i=1}^N |T_i|}$$

$$F_{\text{Score}} = \frac{2 \times P \times R}{P + R}$$

下面给出实验数据中出现的一个实例,包含样本的内容、样本的真实标签和样本的预测标签。可能出现的情况是真实标签有 3 个,实验结果可能只抽取出了 2 个。

实验数据的实例如下:

样本:总体的性价比还是不错的,拍摄效果也还可以,就是电池不怎么耐用!

真实值:(性价比, +1), (拍摄效果, +1), (电池, -1)

预测值:(性价比, +1), (电池, -1)

3.3 实验结果

具体实验分成 3 个组进行对比:

1) 是把属性抽取和基于属性的情感分析 2 个任务分两阶段完成,其中分阶段完成是 CRF 模型和 RNN 模型的组合,用 CRF 模型作为序列标注的基础模型,在属性抽取任务是目前效果最好的模型。在 CRF 模型中使用到的特征有词、词性、当前词的前后 2 个词以及它们的词性,然后在此基础上用 RNN 完成基于属性的情感分类问题。

2) 是相关工作中提到的 TD-LSTM、AE-LSTM、ATAE-LSTM 3 个模型,这 3 个模型也是在 CRF 模型完成属性抽取后,基于抽取的属性来判断情感极性。

3) 是文中 AP-BRNN 序列标注模型,直接完成属性抽取和情感极性判断,同时对比了在模型中只用词向量单一特征,以及加入词性和依存关系等特征的不同情况。

从表 2 的实验结果可以看出,分两阶段训练模

型效果并不太好,在用 CRF 模型抽取属性时,它的结果直接影响第二阶段基于属性的情感分类的准确率,所以,最后的综合效果会受到前后两阶段的影响。同时在第二阶段 RNN 训练时,还对比了基本 RNN、考虑属性词上下文内容(Context)的 RNN(C-RNN)、属性词(Aspect)与它的每一个上下文内容组合(AC-RNN)等 3 种情况。结果显示,在正确抽取到属性词时,属性词与它的上下文组合的情况能够提升情感分类的效果。从表 2 还可以看出,CRF 和 RNN 的组合模型中召回率要高于准确率,而本文多特征融合的 AP-BLSTM 模型不仅克服了分阶段结果的相互影响,而且有利于准确性提升和改进。

表 2 不同模型和特征的实验结果对比

模型和特征	$P_{\text{Precision}}$	R_{Recall}	F_{Score}
CRF + RNN	0.550 1	0.533 5	0.551 8
CRF + C-RNN	0.550 0	0.555 4	0.552 7
CRF + AC-RNN	0.562 0	0.558 8	0.560 4
TD-LSTM	0.572 8	0.544 3	0.558 2
AE-LSTM	0.576 3	0.561 2	0.568 6
ATAE-LSTM	0.587 2	0.568 7	0.577 8
AP-BLSTM(WE)	0.599 5	0.556 9	0.577 4
AP-BLSTM(WE + POS + Dep)	0.611 5	0.569 4	0.588 0

本文构建的融合多个特征的 AP-BLSTM 序列标注模型,可以通过训练一个模型直接抽取出属性并判断情感极性。实验对比了使用词向量(WE)单一特征、加入词性标注(POS)和依存关系(Dep)多特征等不同情况,表 2 结果显示效果有所提升,比分阶段模型组合的效果提高了 2%,同时多特征融合也好于只考虑词向量单一特征的模型。虽然效果提升并不是很多,但是整个模型的构建和训练变得简单。

最后选取了训练集和测试集中各 20% 的数据量,在 RNN 的多种衍生模型中,对比了相同的特征融合输入到 RNN、BRNN、LSTM 3 种不同模型,从表 3 的结果可以看出,BRNN 的效果明显比 RNN 要好,说明对于信息抽取和情感分析类任务,考虑上下文的影响是非常重要的,而双向 LSTM 效果是最好的,说明本文的细粒度意见分析任务需要考虑文本上下文的远距离依赖关系。图 4 为不同 RNN 模型对比结果。

表 3 RNN、BRNN、LSTM 特征融合对比结果

模型	$P_{\text{Precision}}$	R_{Recall}	F_{Score}
AP-RNN	0.486 2	0.478 9	0.482 5
AP-LSTM	0.491 5	0.472 5	0.481 8
AP-BRNN	0.501 8	0.500 0	0.500 9
AP-BLSTM	0.524 6	0.497 8	0.510 8

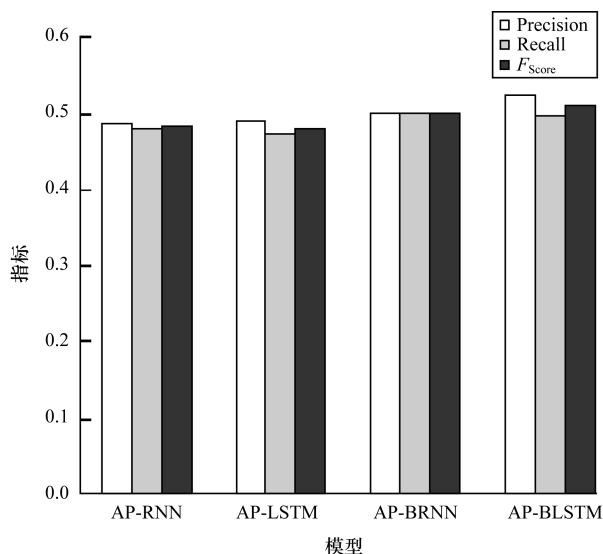


图 4 不同 RNN 模型对比结果

综合以上实验结果可以看出,本文构建的细粒度意见分析序列标注模型能够同时完成属性抽取和基于属性的情感分析任务,不需要像以前把 2 个任务分阶段去完成,而且比目前已有的方法效果有所提升。

4 结束语

本文在基于表示学习的词向量中融入传统的语言学特征,通过构建双向循环神经网络的序列标注模型,完成基于评论数据的细粒度意见分析任务,可以抽取出属性并同时分析基于属性的情感极性。实验结果表明,与传统的 CRF 模型相比,该模型效果有一定的提升。序列标注模型没有使用较多的人工标注、特征及模版函数,只是用工具生成词性标注和依存关系,然后把把这些特征融合输入 RNN 和 LSTM,通过标注结果可以直接抽取属性并判断情感极性。下一步将在序列标注模型中加入注意力机制,针对属性词的不同上下文学习出不同的权重。此外,考虑用无监督或半监督的方法来利用大量的无标注文本数据,从而更好地去挖掘和理解文本的语义。

参考文献

- [1] 章剑锋,张奇,吴立德,等. 中文观点挖掘中的主观性关系抽取[J]. 中文信息学报,2008,22(2):55-59.
- [2] 赵妍妍,秦兵,刘挺. 文本情感分析[J]. 软件学报,2010,21(8):1834-1848.
- [3] 姚天昉,程希文,徐飞玉,等. 文本意见挖掘综述[J]. 中文信息学报,2008,22(3):71-80.
- [4] 厉小军,戴霖,施寒潇,等. 文本倾向性分析综述[J]. 浙江大学学报(工学版),2011,45(7):1167-1174.
- [5] HAO Z, CHEN J, CAI R, et al. Chinese sentiment

- classification based on the sentiment drop point[C]//Proceedings of International Conference on Intelligent Computing. Berlin, Germany: Springer,2013:55-60.
- [6] LIU B. Sentiment analysis and opinion mining[J]. Synthesis Lectures on Human Language Technologies, 2012,5(1):155-167.
- [7] HU M, LIU B. Mining and summarizing customer reviews[C]//Proceedings of the 20th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining. New York, USA: ACM Press, 2004: 168-177.
- [8] POPESCH A M, ETZIONI O. Extracting product features and opinions from reviews[M]. Berlin, Germany: Springer,2007:9-28.
- [9] JAKOB N, GUREYYCH I. Extracting opinion targets in a single-and cross-domain setting with conditional random fields[C]//Proceedings of 2010 Conference on Empirical Methods in Natural Language Processing, [S.l.]: Association for Computational Linguistics, 2010:1035-1045.
- [10] HAO Z, WANG H, CAI R, et al. Product named entity recognition for Chinese query questions based on a skip-chain CRF model[J]. Neural Computing and Applications,2013,23(2):371-379.
- [11] ZHUANG L, JING F, ZHU X Y. Movie review mining and summarization[C]//Proceedings of the 15th ACM International Conference on Information and Knowledge Management. New York, USA: ACM Press, 2006: 43-50.
- [12] KOBAYASHI N, INUI K, MATSUMOTO Y. Extracting aspect-evaluation and aspect-of relations in opinion mining[C]//Proceedings of EMNLP-CoNLL'07. Washington D. C., USA: IEEE Press,2007:1065-1074.
- [13] 杨凤芹,宋美佳,孙铁利,等. 面向中文产品评论的完整评价对象抽取方法[J]. 计算机工程,2017,43(6):169-176.
- [14] BENGIO Y, DUCHARME R, VINCENT P, et al. A neural probabilistic language model[J]. Journal of Machine Learning Research,2003,3(1):1137-1155.
- [15] MIKALOV T, KARAFIAT M, BURGET L, et al. Recurrent neural network based language model[C]//Proceedings of Conference on International Speech Communication Association. Chiba, Japan: [s. n.], 2010:1045-1048.
- [16] MIKOLOV T, SUTSKEVER I, CHEN K, et al. Distributed representations of words and phrases and their compositionality[C]//Proceedings of IEEE International Conference on Neural Information Processing Systems. Washington D. C., USA: IEEE Press,2013:3111-3119.
- [17] IRISOY O, CARDIE C. Opinion mining with deep recurrent neural networks[C]//Proceedings of IEEE Conference on Empirical Methods in Natural Language Processing. Washington D. C., USA: IEEE Press,2014: 720-728.

(下转第 211 页)

- [3] DONG X, GABRILOVICH E, HEITZ G, et al. Knowledge vault: a Web-scale approach to probabilistic knowledge fusion [C]//Proceedings of the 20th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining. New York, USA: ACM Press, 2014: 601-610.
- [4] 安 波, 韩先培, 孙 乐, 等. 基于分布式表示和多特征融合的知识库三元组分类 [J]. 中文信息学报, 2016, 30(6): 84-89.
- [5] COLLOBERT R, WESTON J, BOTTOU L, et al. Natural language processing (almost) from scratch [J]. Journal of Machine Learning Research, 2011, 12(1): 2493-2537.
- [6] ZENG D, LIU K, LAI S, et al. Relation classification via convolutional deep neural network [EB/OL]. [2017-06-10]. <http://www.aclweb.org/anthology/C/C14/C14-1220.pdf>.
- [7] BORDES A, USUNIER N, GARCIA-DURAN A, et al. Translating embeddings for modeling multi-relational data [C]//Proceedings of the 26th International Conference on Neural Information Processing Systems. [S. l.]: Curran Associates, Inc., 2013: 2787-2795.
- [8] WANG Z, ZHANG J, FENG J, et al. Knowledge graph and text jointly embedding [EB/OL]. [2017-06-10]. <http://www.aclweb.org/anthology/attachments/D/D14/D14-1167.Attachment.pdf>.
- [9] WANG Z, ZHANG J, FENG J, et al. Knowledge graph embedding by translating on hyperplanes [C]//Proceedings of the 28th AAAI Conference on Artificial Intelligence. [S. l.]: AAAI Press, 2014: 1112-1119.
- [10] LIN Y, LIU Z, SUN M, et al. Learning entity and relation embeddings for knowledge graph completion [C]//Proceedings of the 29th AAAI Conference on Artificial Intelligence. [S. l.]: AAAI Press, 2015: 2181-2187.
- [11] JI G, HE S, XU L, et al. Knowledge graph embedding via dynamic mapping matrix [EB/OL]. [2017-06-10]. <http://or.nsf.gov.cn/bitstream/00001903-5/149814/1/1000014952718.pdf>.
- [12] SOCHER R, CHEN D, MANNING C D, et al. Reasoning with neural tensor networks for knowledge base completion [C]//Proceedings of the 26th International Conference on Neural Information Processing Systems. [S. l.]: Curran Associates, Inc., 2013: 926-934.
- [13] MIKOLOV T, CHEN K, CORRADO G, et al. Efficient estimation of word representations in vector space [EB/OL]. [2017-06-10]. <http://www.surdeanu.info/mihai/teaching/ista555-spring15/readings/mikolov2013.pdf>.
- [14] XIE R, LIU Z, JIA J, et al. Representation learning of knowledge graphs with entity descriptions [C]//Proceedings of the 30th AAAI Conference on Artificial Intelligence. [S. l.]: AAAI Press, 2016: 2659-2665.
- [15] ZHANG D, YUAN B, WANG D, et al. Joint semantic relevance learning with text data and graph knowledge [EB/OL]. [2017-06-10]. <http://wing.comp.nus.edu.sg/~antho/W/W15/W15-4004.pdf>.
- [16] LONG T, LOWE R, CHEUNG J C K, et al. Leveraging lexical resources for learning entity embeddings in multi-relational data [EB/OL]. [2017-06-10]. <http://aclweb.org/anthology/P16-2019>.
- [17] TIAN F, GAO B, CHEN E H, et al. Learning better word embedding by asymmetric low-rank projection of knowledge graph [J]. Journal of Computer Science and Technology, 2016, 31(3): 624-634.
- [18] BORDES A, GLOROT X, WESTON J, et al. A semantic matching energy function for learning with multi-relational data [J]. Machine Learning, 2014, 94(2): 233-259.

编辑 吴云芳

(上接第204页)

- [18] LIU P, JOTY S, MENG H. Fine-grained opinion mining with recurrent neural networks and word embeddings [C]//Proceedings of ACM Conference on Empirical Methods in Natural Language Processing. New York, USA: ACM Press, 2015: 1433-1443.
- [19] WANG B, LIU M. Deep learning for aspect-based sentiment analysis [EB/OL]. [2017-05-21]. <http://web.stanford.edu/class>.
- [20] TANG D, QIN B, FENG X, et al. Effective LSTMs for target-dependent sentiment classification [EB/OL]. [2017-05-21]. <http://www.aclweb.org/>.
- [21] TANG D, QIN B, LIU T. Aspect level sentiment classification with deep memory network [EB/OL]. [2017-05-21]. <http://wing.comp.nus.edu.sg/>.
- [22] SUKHBAATAR S, WESTON J, FERGUS R. End-to-end memory networks [J]. Neural Information Processing Systems, 2015(1): 2440-2448.
- [23] WANG Y, HUANG M, ZHU X, et al. Attention-based LSTM for aspect-level sentiment classification [C]//Proceedings of IEEE EMNLP'06. Washington D. C., USA: IEEE Press, 2016: 606-615.
- [24] ZHANG Y, ZHANG H, ZHANG M, et al. Do users rate or review?: boost phrase-level sentiment labeling with review-level sentiment classification [C]//Proceedings of the 37th International ACM SIGIR Conference on Research & Development in Information Retrieval. New York, USA: ACM Press, 2014: 1027-1030.

编辑 索书志