

基于深度自编码多维特征融合的慢动目标检测

张文涛^a, 许治国^a, 郑霖^b, 杨超^b

(桂林电子科技大学 a. 电子工程与自动化学院; b. 广西无线宽带通信与信号处理重点实验室, 广西 桂林 541004)

摘 要: 针对强杂波环境下慢动目标检测存在的多普勒频移低、杂波干扰强、特征提取困难等问题, 提出一种多维特征融合的检测算法。利用时频变换和脉冲压缩解析回波信息, 提取目标回波时频域和距离像的特征, 将特征串联输入到深度自编码网络中进行融合。深度自编码网络通过自主学习提取目标不同维度的特征, 增强多维特征联合检测性能。仿真结果表明, 与直接利用单域特征的深度自编码以及利用 SVM 进行目标检测的算法相比, 该算法能有效融合时频域与距离像特征, 实现特征互补, 提高目标检测的鲁棒性与识别精度。

关键词: 目标检测; 深度自编码; 特征提取; 多维特征融合; 时频变换; 脉冲压缩

中文引用格式: 张文涛, 许治国, 郑霖, 等. 基于深度自编码多维特征融合的慢动目标检测[J]. 计算机工程, 2019, 45(5): 143-148, 154.

英文引用格式: ZHANG Wentao, XU Zhiguo, ZHENG Lin, et al. Slow moving target detection based on multi-dimensional feature fusion using deep autoencoder[J]. Computer Engineering, 2019, 45(5): 143-148, 154.

Slow Moving Target Detection Based on Multi-dimensional Feature Fusion Using Deep Autoencoder

ZHANG Wentao^a, XU Zhiguo^a, ZHENG Lin^b, YANG Chao^b

(a. School of Electronic Engineering and Automation; b. Guangxi Key Laboratory of Wireless

Wideband Communication and Signal Processing, Guilin University of Electronic Technology, Guilin, Guangxi 541004, China)

[Abstract] To address the problems of low Doppler frequency shift, strong clutter interference, difficult feature extraction in slow moving target detection under strong clutter environment, a target detection method based on multi-dimensional feature fusion is proposed. Firstly, the echo information is analyzed by using time-frequency transform and pulse compression, and the features of the target echo in the time-frequency domain and range image are extracted. Then, the features are connected in series into deep autoencoder network for fusion. Finally, the deep autoencoder network is used to extract different dimensions of target characteristics, and enhance the joint detection performance of multi-dimensional features based on autonomous learning. Simulation results show that compared with the target detection based on single domain feature using deep autoencoder and the target detection using SVM, the proposed method can fuse the features of the time-frequency domain and range image effectively, having advantages of both, and improve the robustness and recognition precision of target detection.

[Key words] target detection; deep autoencoder; feature extraction; multi-dimensional feature fusion; time-frequency transform; pulse compression

DOI: 10.19678/j.issn.1000-3428.0050465

0 概述

强杂波环境下的慢动目标检测一直是具有挑战性的课题。由于目标和障碍物的回波具有类似的电磁特性, 并且受到多径效应及慢速特性等影响^[1], 目标回波能量极其微弱, 难以检测^[2], 传统的慢动目标

检测性能难以满足实际需求。目前, 国内外学者提出的方法主要从模式识别的角度出发, 聚焦于特征提取和分类器设计。这些方法通常利用时域波形^[3]、时频分析^[4]、稀疏分解^[5]等预定义目标回波特征, 结合数据约简技术优化特征选取, 以机器学习算法如决策树、贝叶斯分类、Adaboost 等构建特征检测

基金项目: 国家自然科学基金(61371107, 61565004, 61571143); 国家科技重大专项“高精度位置测量系统在线标定技术研究”(2017ZX02101007-003)。

作者简介: 张文涛(1976—), 男, 教授、博士、博士生导师, 主研方向为雷达信号处理、光电检测技术; 许治国, 硕士研究生; 郑霖, 教授、博士; 杨超, 博士研究生。

收稿日期: 2018-02-09 **修回日期:** 2018-03-12 **E-mail:** 781483226@qq.com

器对目标进行分类识别^[6]。其特征多为人工设计,是否最优未经验证,且分类器的构建都是基于浅层机器学习算法,难以充分挖掘和表示目标的特征,检测性能有限。

深度学习的兴起为非平稳信号的分析 and 处理提供了新的思路——通过搭建含有多层隐藏层的神经网络,将数据进行特征映射,获取数据深层本质信息^[7]。文献[1]通过 WVD 时频变换解析回波信息,并以时频域数据作为目标特征输入深度自编码网络完成检测。文献[2]计算目标在每一个方位角下的 RCS 值,以 RCS 三维效果图作为深度自编码输入完成目标的形状识别。文献[4]通过短时傅里叶变换 (Short-Time Fourier Transform, STFT) 将人类运动产生的强非平稳和微多普勒信号映射到时频域,利用深度自编码网络提取特征完成对人类运动跌倒检测。但是,上述检测方法存在以下问题:在强杂波或低信噪比条件下,将目标数据映射到某个域上对其解析能力有限,难以全面描述目标,导致特征区别不明显,影响检测性能;深度学习模型的输入通常是目标回波信息的简单变换,较少考虑预处理与深度学习模型的匹配度。

如何提取有代表性和区别力的特征成为慢动目标检测的关键因素。一方面,目标的出现导致环境散射特性发生变化,在时频平面上体现为不同的时频密度分布^[8],且时频域包含有目标的多普勒信息;另一方面,由于目标的慢速移动,通过累积多个回波脉冲并进行脉冲压缩可获取目标的距离迁移信息,目标的多普勒信息和距离迁移是慢动目标最基本的特征^[9]。将 2 个不同维度的特征进行融合输入到深度自编码网络,能够有效综合多维特征之间的优势获得目标更全面的特征表达^[10-11],实现最大程度解析回波数据,挖掘数据更深层次特征,提高识别精度。为此,本文提出一种基于深度自编码的慢动目标检测方法,通过时频变换和脉冲压缩提取目标回波的时频域和距离像的特征。

1 基于深度学习的慢动目标检测

对于慢动目标检测而言,由于建筑群、静态障碍物等造成强杂波干扰,目标回波信号严重衰减甚至被淹没,导致回波信号呈现出较强的非平稳特性^[12],目标的慢速移动使环境呈现出不同的散射特性,因此为了获得目标的有效信息,需要对回波信号进行预处理。传统基于深度自编码的慢动目标检测方法主要是利用时频变换、稀疏分解等将回波信号映射到另一个域上以解析回波信息,并且通过深度学习模型将输入数据转化为更抽象的表达,完成目标的特征提取以及分类,其主要步骤如图 1 所示。




图 1 传统慢动目标检测流程

传统基于深度学习的目标检测预处理主要通过将回波信号映射到某一个域上以解析回波信息,并结合深度学习模型完成目标检测。然而单一域上的特征难以全面描述目标特性,对回波信息解析能力有限,丢失了部分有效信息。如果单一域解析的特征对目标描述较差,则丢失的有效信息无法从分类训练中恢复^[12],而回波信号预处理的好坏决定了目标检测的性能。

本文结合 LFM 信号特性,考虑将回波信息映射到不同角度或者不同特性的多个域上充分解析回波,选取互补性好、冗余性小的特征。由于通过时频变换可以较为准确地捕获目标慢速移动产生的多普勒频率的变化,脉冲压缩可以揭示目标由于移动导致的时域上距离迁移信息,通过将回波数据的时频域和距离像特征进行融合,充分利用回波信息,再结合深度自编码网络完成对目标特征的提取,提高多维特征联合检测性能,获得比传统基于单域特征的慢动目标检测更高的识别率。

2 深度自编码网络

为提取回波信号时频域和距离像特征之间的互补信息,实现特征有效融合,本文采用深度自编码网络对多维特征进行融合分类,实现特征的分级表达,准确揭示目标运动信息,感知环境的变化,完成目标检测。

2.1 自编码器

自编码器是一个 3 层或 3 层以上的无监督学习神经网络,包括输入层、隐藏层以及输出层^[13],其原理如图 2 所示。




图 2 自编码器原理

对于每一个数据集 $\{\mathbf{x}^d\}_{d=1}^M$ 中的输入信号 \mathbf{x}^d , 输入层和隐藏层构成编码器将原始信号 \mathbf{x}^d 变换成编码信号 \mathbf{h}^d :

$$\mathbf{h}^d = f_{\theta}(\mathbf{x}^d) = s(\mathbf{W}\mathbf{x}^d + \mathbf{b}), \theta = (\mathbf{W}, \mathbf{b}) \quad (1)$$

隐藏层和输出层构成解码器负责将编码信号 \mathbf{h}^d 重构出原始信号 \mathbf{x}^d :

$$\tilde{\mathbf{x}}^d = g_{\theta'}(\mathbf{h}^d) = s(\mathbf{W}'\mathbf{h}^d + \mathbf{b}'), \theta' = (\mathbf{W}', \mathbf{b}') \quad (2)$$

其中, θ, θ' 为网络参数, \mathbf{W}, \mathbf{W}' 为权值矩阵, 通常取 $\mathbf{W}' = \mathbf{W}^T$, \mathbf{b}, \mathbf{b}' 为偏置向量, $\tilde{\mathbf{x}}^d$ 为重构的输出信号, f, g 是激活函数, 此处选用 sigmoid 函数, $s(x) = 1/(1 + e^{-x})$ 。

对模型参数的调节实际上就是最小化重构误差, 主要包括均方误差和交叉熵形式^[1], 本文采用交叉熵代价函数, 输出信号 $\tilde{\mathbf{x}}^d$ 与原始信号 \mathbf{x}^d 的重构误差表示为:

$$L(\mathbf{x}^d, \tilde{\mathbf{x}}^d) = -\sum_n [\mathbf{x}^d \log_a \tilde{\mathbf{x}}^d + (1 - \mathbf{x}^d) \log_a (1 - \tilde{\mathbf{x}}^d)] \quad (3)$$

其中, 对数底 a 在不同情况下的值不同, 在机器学习通常 $a = e$ 。

对整个数据集 M 个样本的损失函数定义为:

$$J(\mathbf{W}, \mathbf{b}) = \frac{1}{M} \sum_{d=1}^M \sum_{i=1}^n L(\mathbf{x}^d, \tilde{\mathbf{x}}^d) + \frac{\lambda}{2} \|\mathbf{W}\|^2 \quad (4)$$

其中, n 表示样本的维数, M 表示样本的个数, λ 表示权重衰减系数。式(4)等号右边第1项表示整个数据集的重构误差, 第2项表示正则化权重惩罚项, 通过限制权值大小防止过拟合。

2.2 稀疏和降噪自编码

为使自编码器具有更强的特征表达能力, 通过添加稀疏惩罚项, 约束隐藏层激活度, 用尽可能少的神经元来表示原始数据, 从而学习到输入信号更抽象、更有代表性的稀疏特征表示^[14-15]。稀疏自编码器 (Sparse AutoEncoder, SAE) 的代价函数表示为:

$$J_{\text{sparse}} = J(\mathbf{W}, \mathbf{b}) + \beta \sum_{j=1}^K D_{KL}(\rho, \hat{\rho}_j) \quad (5)$$

$$D_{KL}(\rho, \hat{\rho}_j) = \rho \log_a \frac{\rho}{\hat{\rho}_j} + (1 - \rho) \frac{1 - \rho}{1 - \hat{\rho}_j} \quad (6)$$

其中, K 为隐藏层神经元的数量, $\rho \in (0, 1)$ 为稀疏性参数, $\hat{\rho}_j$ 为神经元 j 的平均激活度, β 为相应的稀疏惩罚因子。

在代价函数中加入稀疏约束项, 并使其最小化, 可以使得 $\hat{\rho}_j$ 更接近 ρ 。将 ρ 设置为一个趋于 0 的小数, 使得隐藏层神经元的平均激活度保持在较小的范围内实现网络稀疏性。

在 SAE 的基础上, 对输入数据 \mathbf{x} 进行加噪处理可

得到降噪 SAE^[6], 并且通过降噪 SAE 学习如何去除这些噪声, 恢复原始数据, 从而增强网络的抗噪能力, 提高模型的泛化能力和鲁棒性, 其原理如图 3 所示。




图3 降噪自编码器原理

2.3 深度自编码网络原理

深度自编码网络是由多个自编码器堆叠而成, 将前一层自编码器的输出作为其后一层自编码器的输入, 以此类推, 并在网络顶端加入分类器^[7], 其原理如图 4 所示。




图4 逐层初始化示意图

通过逐层贪婪训练法训练每个自编码器, 完成参数初始化, 再利用 Softmax 分类器并通过 BP 算法对全局参数进行有监督精调, 完成特征的分级提取, 其训练过程如图 5 所示。

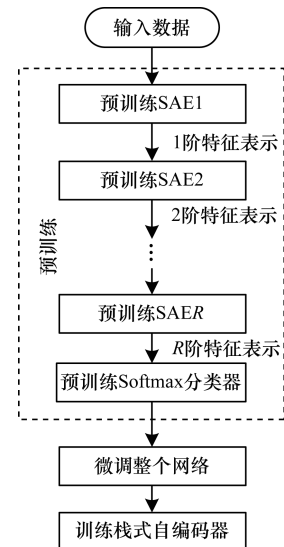


图5 深度自编码训练流程

深度自编码网络具有强大的特征表达能力,通过非线性模型将原始数据转化为更为抽象的表达,能更好地挖掘输入的更深层次、更抽象的特征,采用逐层贪婪训练算法使网络参数初始化至容易收敛的值,再经过全局精调映射到类别信息,加入稀疏性的约束,提高网络泛化能力和鲁棒性。

3 算法设计

多普勒信息和距离迁移是慢动目标最基本的特征信息。

WVD 变换利用时频二维分布描述非平稳信号的幅频特性随时间变化的情况,具有独特的信息保留优势以及理想的时频聚集性,且相对于线性时频变换能更加直观、合理地描述信号的瞬时功率谱密度^[1],揭示目标移动的多普勒信息,其定义如下:

$$W_s(t, f) = \int_{-\infty}^{+\infty} s(t + \tau/2) s^*(t - \tau/2) e^{-j2\pi f\tau} d\tau \quad (7)$$

其中, $s(t)$ 为回波信号, $s^*(t)$ 是其共轭函数,经过采样后其 WVD 为一个矩阵,记为 $\mathbf{p}(n \times n)$, n 为 $s(t)$ 的采样点数。

多径效应引起的交叉项干扰,会损失部分有效信息,导致对回波信息提取不够充分。而由于 LFM 信号有良好的自相关性,经匹配滤波进行脉冲压缩可得到较高的峰值,且对多普勒频移不敏感,通过多脉冲的积累有效刻画了目标的慢速移动产生的距离迁移信息,可以与 WVD 变换形成优势互补。

为充分利用回波信息,提取更抽象、更有效的特征,本文综合考虑慢速移动目标特性,选取冗余性小、互补性大的融合特征,分别使用 WVD 变换和脉冲压缩对回波数据进行预处理,检测流程如图 6 所示,其中包含 1 个输入层、5 个隐藏层以及 1 个输出层。




图 6 目标检测流程

经过预处理将提取的时频域和距离像特征串接在一起完成特征融合,得到样本数据组成矢量 $\mathbf{X} = (x_1, x_2, \dots, x_n)$, 归一化后作为深度自编码网络的输入,采取逐层贪婪算法进行预训练完成网络初始化,再结合 Softmax 分类器使用 BP 算法进行有监督微

调,通过计算概率将样本数据映射到对应类别信息,完成分类检测。对于输入样本 \mathbf{x}^d , Softmax 分类器将其归入类别 l 的概率为:

$$P_l = \frac{e^{\theta_l^T \mathbf{x}^d}}{\sum_{l=1}^2 e^{\theta_l^T \mathbf{x}^d}} \quad (8)$$

其中, θ_l 为参数向量。输出样本所属类别为概率最大的类别。

4 实验与结果分析

4.1 场景模型

为验证算法的有效性,本文设计了对比实验。实验采用的回波模型是由目标回波、瑞利杂波以及高斯白噪声组成的非平稳回波。回波模型可用下式表示:

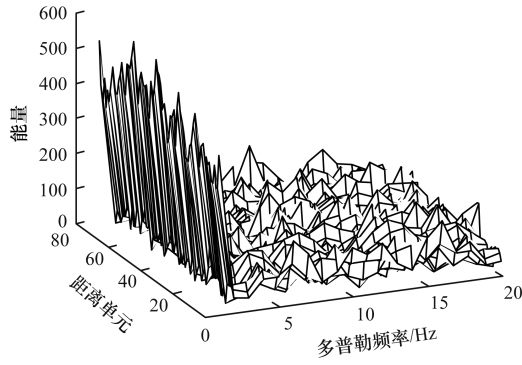
$$r(t) = \sum_i \alpha s(t - \tau_i) e^{j2\pi f_d t} + c(t) + n(t) \quad (9)$$

其中, $s(t)$ 为发射的 Chirp 脉冲信号, α 为对应的回波幅值系数, $c(t)$ 为瑞利杂波, $n(t)$ 为高斯白噪声。由于目标的慢速移动,回波的时延不同, $\tau_i = 2R(i)/c$ 表示目标第 i 个回波的时延,其中, $R(i) = R_0 - V_g t$ 表示回波传输的距离, R_0 为目标的初始距离, c 为光速, V_g 表示目标运动的第 g 个速度。场景及系统参数如表 1 所示。


表 1 场景及系统参数设置

参数	取值
载频/GHz	2.4
带宽/MHz	100
采样率/MHz	100
脉冲重复周期/s	0.075
脉冲持续时间/s	5×10^{-7}
杂波速度均值/($\text{m} \cdot \text{s}^{-1}$) ²	1.5
杂波功率均值/ W^2	3.2
目标初始距离(R_0)/m	36
目标回波幅值系数 α	0.58
信杂比(SCR)/dB	-15
目标速度/($\text{m} \cdot \text{s}^{-1}$)	[2,4](以 0.01 步长均匀取值)

为更好地提取目标回波的时频域和距离像特征,从不同的角度解析回波信号,获取目标的多普勒信息以及距离迁移信息,本文截取回波信号的前 75 个采样点用作分析处理,并且累积多个脉冲作为样本数据,速度取值是以 0.01 m/s 的步长遍历 2 m/s ~ 4 m/s,并在此基础上加入不同信噪比的高斯白噪声进行测试实验。在强杂波环境下,目标回波和纯杂波的距离-频率谱如图 7 所示。由图 7 可见,在目标出现之后,两者的距离-多普勒谱变化细微,这是因为目标能量相比杂波能量微弱,且目标速度较低,与杂波频谱范围重叠,传统算法难以解析该情况下的目标。




(a)纯杂波




(b)目标回波+杂波

图 7 在强杂波环境下距离-频率谱图

对目标回波和纯杂波脉冲压缩,得到的距离像如图 8 所示。



(a)纯杂波




(b)目标回波+杂波


图 8 回波距离像

由图 8 可以看出,在强杂波环境下,距离像在有目标的位置出现了峰值,且在经过多个脉冲重复周期之后目标发生了 1 个距离迁移。这是因为与纯杂波的回波相比,目标的出现与移动导致距离像发生了变化。

回波数据经 WVD 变换之后时频维波形如图 9 所示,从图中可以看出,由于目标的出现,时频平面的分布在图中标示位置也发生了一些变化。



(a)纯杂波



(b)目标回波+杂波

图 9 WVD 变换时频图

4.2 实验比较与分析

实验采取 4.1 节产生的回波数据,并在 Matlab R2016b 平台上进行仿真分析。回波样本数据共 10 000 个,其中 5 000 个样本为纯杂波,另外 5 000 个样本中有目标,分别利用脉冲压缩和 WVD 对回波数据进行预处理后,得到 75×75 维时频域特征与 75 维的距离像特征,将特征串联成 5 700 维向量并归一化后输入到深度自编码网络中进行特征融合,其结构为:5 700(输入层)-3 500(隐藏层)-2 000(隐藏层)-1 000(隐藏层)-400(隐藏层)-100(隐藏层)-2(输出层),并在网络顶端加入逻辑回归层。通过逐层贪婪算法进行预训练完成网络初始化,利用 Softmax 分类器对网络进行全局微调,通过多维特征融合完成目标检测。实验为提高网络的鲁棒性,在预训练中加入了噪声和稀疏约束,并在微调阶段加入 Dropout 防止网络过拟合,最终参数如表 2 所示。

表 2 深度自编码网络仿真参数

属性	取值
学习速率	0.1
加噪系数	0.3、0.4、0.2、0.1、0
稀疏惩罚因子	0.5、0.4、0.4、0.3、0.2
Dropout 系数	0.1
训练次数	30
批尺寸	100

在对比实验中,本文采用同一组网络参数,预处理分别采用:STFT 结合深度自编码(STFT + DAE)、WVD 变换结合深度自编码(WVD + DAE)以及融合特征结合主成分分析降维后利用 SVM 分类(联合 + SVM)。实验使用识别率 P 作为算法的性能指标:

$$P = \frac{N_{\text{clu-clu}} + N_{\text{tar-tar}}}{N_T} \quad (10)$$

其中, N_T 代表正常环境和出现目标环境的样本数, $N_{\text{clu-clu}}$ 表示将正常环境判别为正常环境的数量, $N_{\text{tar-tar}}$ 表示将出现目标环境判别为异常环境的数量。最终实验结果如图 10 所示。




图 10 不同算法性能对比

由图 10 可知,本文算法的识别率相比于单域特征整体提高 6% 以上,而且随着信噪比的增加,多维特征融合后的识别率更快接近 100%。特别在强杂波和低信噪比下,单维特征区别不明显、难以分辨,而通过多维特征联合检测的识别率仍然保持较高的水平,说明通过时频域特征和距离像特征的融合,更加有效解析了回波信号多普勒信息与目标距离迁移信息,利用 2 个不同域上的互补特征,实现特征间的优势互补,全面刻画目标信息。再通过深度自编码网络自主学习,实现复杂函数逼近,从不同角度刻画出目标的慢速移动信息,深度挖掘目标在慢速移动过程中在不同域上变化的相关性,改善了原始特征的空间分布,从而实现特征之间的深度融合,提高目标识别性能。此外,相比于将融合特征结合 SVM 的检测方法而言,本文算法性能明显提高。这说明本文算法不仅可以降低特征维度,提取出区分性更好的融合特征,而且不需要事先定义特征,更好地逼近非线性分类函数,同时由于运用了降噪 SAE,增强了目标检测的抗噪性能。

5 结束语

基于深度自编码,本文提出一种多维特征融合的慢动目标检测算法。结合时频分析和脉冲压缩选取冗余性小、互补性大的时频域特征和距离像特征,利用深度自编码强大的特征表达能力,将特征进行有效融合,提取出区分度更大的深度特征。实验结果表明,本文预处理过程能够实现特征之间优势互补,增强多维特征联合检测性能,为后续目标识别提供保障,相比单域特征目标检测方法提高了识别率和鲁棒性。下一步考虑借鉴随机矩阵理论,将不同回波信号的协方差矩阵特征值的差异作为回波信号的预处理参数,尝试与深度学习结合对目标进行检测。

参考文献

- [1] 刘凯,林基明,郑霖等. 基于深度自编码网络的慢速移动目标检测[J]. 计算机工程, 2018, 44(2): 129-134.
- [2] 陈小龙,关键,于晓涵等. 基于短时稀疏时频分布的雷达目标微动特征提取及检测方法[J]. 电子与信息学报, 2017, 39(5): 1017-1023.
- [3] LIANG Jing, LIANG Qilian. Sense-through-foilage target detection using UWB radar sensor networks[J]. Pattern Recognition Letters, 2010, 31(11): 1412-1421.
- [4] JOKANOVIC B, AMIN M G, ZHANG Yimin, et al. Multi-window time-frequency signature reconstruction from undersampled continuous-wave radar measurements for fall detection[J]. IET Radar Sonar and Navigation, 2014, 9(2): 173-183.
- [5] ZHAI Shijun, JIANG Ting. A novel sense-through-foilage target recognition system based on sparse representation and improved particle swarm optimization-based support vector machine [J]. Measurement, 2013, 46 (10): 3994-4004.
- [6] 赵飞翔,刘永祥,霍凯. 基于栈式降噪稀疏自动编码器的雷达目标识别方法[J]. 雷达学报, 2017, 6(2): 149-156.
- [7] QI Yumei, SHEN Changqing, WANG Dong, et al. Stacked sparse autoencoder-based deep network for fault diagnosis of rotating machinery[J]. IEEE Access, 2017, 5: 15066-15079.
- [8] WU Qisong, ZHANG Yimin, TAO Wenbin, et al. Radar-based fall detection based on Doppler time-frequency signatures for assisted living[J]. IET Radar Sonar and Navigation, 2015, 9(2): 164-172.
- [9] JOKANOVIC B, AMIN M G, AHMAD F. Effect of data representations on deep learning in fall detection[C]// Proceedings of Sensor Array and Multichannel Signal Processing Workshop. Washington D. C., USA: IEEE Press, 2016: 1-5.
- [10] 康妙,计科峰,冷祥光,等. 基于栈式自编码器特征融合的 SAR 图像车辆目标识别[J]. 雷达学报, 2017, 6(2): 167-176.
- [11] JOKANOVIC B, AMIN M. Fall detection using deep learning in range-Doppler radars[J]. IEEE Transactions on Aerospace and Electronic Systems, 2018, 54(1): 180-189.

(下转第 154 页)




图 8 不同传感器网络下算法预测误差对比

由图 8 可以看出,在传感器网络均匀分布时,其具有较高的预测精度,在此基础上增加传感器密度,预测精度虽有所提高,但效果并不明显。但是,如果场景中的传感器网络分布稀疏不均,其预测精度会大幅降低,原因是传感器网络中存在“盲区”,用户在场景中的部分行为不能被及时准确地捕捉。因此,在传感器的布置过程中,应根据其型号与性能,尽量做到均匀分布,以发挥 PRF 算法的性能优势。

4 结束语

本文提出一种集成分类算法 PRF,该算法引入惩罚项因子,使用训练数据集属性权值再分配的方法重新建立新的决策树,从而兼顾算法的精确度与多样性。实验结果表明,与 Bagging 算法、Adaboost 算法相比,该算法具有较高的分类精确度与噪声鲁棒性。但是,由于 PRF 算法需要在每次迭代中重新对属性权值进行分配,因此其运行时间较长,且该算法每次迭代都依赖上一次迭代的实验结果,导致其很难在并行计算机群上运行。因此,提高算法的运行速度并开发出可以并行运行的集成分类算法,将是下一步的研究方向。

参考文献

- [1] 宋朋涛,李超,徐莉婷,等.基于个人计算机的智能家居边缘计算系统[J].计算机工程,2017,43(11):1-7.
- [2] ZHANG Le, SUGANTHAN P N. Random forests with ensemble of feature spaces [J]. Pattern Recognition, 2014, 47(10):3429-3437.
- [3] GOPIKA D, AZHAGUSUNDARI B. A novel approach on ensemble classifiers with fast rotation forest algorithm[J]. International Journal of Innovative Research in Computer and Communication Engineering, 2014, 2(8):25-30.
- [4] 周文谊,王吉源.一种模糊森林学习方法及其行人检测应用[J].计算机工程,2017,43(3):304-308,315.
- [5] BREIMAN L. Bagging predictors [J]. Machine Learning, 1996, 24(2):123-140.
- [6] HAN Jiawei. Data mining: concepts and techniques [M]. San Francisco, USA: Morgan Kaufmann Publishers Inc., 2005.
- [7] LOH W Y. Classification and regression trees [J]. Wiley Interdisciplinary Reviews Data Mining and Knowledge Discovery, 2011, 1(1):14-23.
- [8] FREUND Y, SCHAPIRE R E. Experiments with a new boosting algorithm [EB/OL]. [2017-12-15]. <https://cseweb.ucsd.edu/~yfreund/papers/boostingexperiments.pdf>.
- [9] HO T K. The random subspace method for constructing decision forests [J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 1998, 20(8):832-844.
- [10] BREIMAN L. Random forests [J]. Machine Learning, 2001, 45(1):5-32.
- [11] FAWAGREH K, GABER M M, ELYAN E. Random forests: from early developments to recent advancements [J]. Systems Science and Control Engineering, 2014, 2(1):602-609.
- [12] BERNARD S, ADAM S, HEUTTE L. Dynamic random forests [J]. Pattern Recognition Letters, 2012, 33(12):1580-1586.
- [13] MARTÍNEZ-MUÑOZ G, SUÁREZ A. Out-of-bag estimation of the optimal sample size in Bagging [J]. Pattern Recognition, 2010, 43(1):143-152.
- [14] QUINLAN J R. C4.5: programs for machine learning [M]. San Francisco, USA: Morgan Kaufmann Publishers Inc., 1992.
- [15] MARGINEANTU D D, DIETTERICH T G. Pruning adaptive boosting [C]//Proceedings of the 14th International Conference on Machine Learning. San Francisco, USA: Morgan Kaufmann Publishers Inc., 1997:211-218.

编辑 吴云芳

(上接第 148 页)

- [12] HAYKIN S, BHATTACHARYA T K. Modular learning strategy for signal detection in a nonstationary environment [J]. IEEE Transactions on Signal Processing, 1997, 45(6):1619-1637.
- [13] EROL B, AMIN M G. Fall motion detection using combined range and Doppler features [C]//Proceedings of Signal Processing Conference. Washington D. C., USA: IEEE Press, 2016:2075-2080.

- [14] GROZDIĆ D T, JOVICIC S T. Whispered speech recognition using deep denoising autoencoder and inverse filtering [J]. IEEE/ACM Transactions on Audio Speech and Language Processing, 2017, 59(12):15-22.
- [15] 牛玉虎,卷积稀疏自编码神经网络 [J]. 计算机与现代化, 2017(2):22-29.

编辑 刘盛龄