

基于独立空谱残差融合的联合稀疏表示高光谱图像分类

卢 佳, 保文星

(北方民族大学 计算机科学与工程学院, 银川 750021)

摘 要: 针对高光谱图像分类中存在的空间信息与光谱信息融合问题, 提出一种基于独立空谱残差融合的联合稀疏表示高光谱图像分类算法。使用类独立的光谱角初分类图像, 获得像元初始标记后按特定条件进行筛选再构造像元邻域空间。提取图像的全局空间信息, 并将其引入到空谱联合稀疏表示模型中, 使用单独的光谱信息字典与空间信息字典分别进行图像光谱与空间的联合稀疏表示残差计算。在此基础上, 使用残差融合算法确定图像类别。实验结果表明, 相对 SVM、KNN 等算法, 该算法能够提升高光谱图像的分类精度, 且分类结果更稳定。

关键词: 高光谱图像; 联合稀疏表示; 全局空间信息; 光谱信息; 残差融合

中文引用格式: 卢佳, 保文星. 基于独立空谱残差融合的联合稀疏表示高光谱图像分类[J]. 计算机工程, 2019, 45(1): 246-252.

英文引用格式: LU Jia, BAO Wenxing. Joint sparse representation hyperspectral image classification based on independent space-spectrum residual fusion[J]. Computer Engineering, 2019, 45(1): 246-252.

Joint Sparse Representation Hyperspectral Image Classification Based on Independent Space-spectrum Residual Fusion

LU Jia, BAO Wenxing

(School of Computer Science and Engineering, North Minzu University, Yinchuan 750021, China)

[Abstract] Aiming at the problem of spatial information and spectral information fusion in hyperspectral image classification, a joint sparse representation hyperspectral image classification algorithm based on independent space-spectrum residual fusion is proposed. Class-independent spectral angles are used to classify the images, and the initial labels of pixels are obtained, then the neighborhood space of pixels is constructed according to the specific conditions. The global spatial information of the whole image is extracted and introduced into the joint sparse representation model of space-spectrum. The joint sparse representation residual of image spectrum and space is calculated by using a separate spectral information dictionary and a spatial information dictionary respectively. On this basis, the residual fusion algorithm is used to determine image classes. Experimental results show that compared with SVM, KNN and other algorithms, this algorithm can improve the classification accuracy of spectral images and the classification results are more stable.

[Key words] hyperspectral image; joint sparse representation; global spatial information; spectral information; residual fusion

DOI: 10.19678/j.issn.1000-3428.0049037

0 概述

遥感图像分类是图像领域研究的热点问题之一, 具有广泛的应用前景^[1]。目前, 较典型的高光谱图像分类方法有 K 近邻法(K Nearest Neighbor, KNN)、决策树法、朴素贝叶斯法、支持向量机(Support Vector Machine, SVM)等^[2]。但是, 这些方法仅考虑高光谱图像的光谱信息, 没有进行空间信息的挖掘与利用。随着高光谱图像分类技术的飞速发展, 学者们开始

结合空谱信息分类对图像进行空间信息提取。部分研究者改进 SVM, 采用修改核函数的方法^[3-4]在图像分类中引入高光谱图像的空间信息, 并得到较理想的分类效果。文献[5]将光谱分类器与图像中像元的近邻信息相结合, 提出一种基于投票式的多分类器联合算法。文献[6]将相似性度量与 KNN 相结合, 提出一种基于加权空-谱聚类(Weighted Space-Spectrum Distance, WSSD)的分类方法。实践结果证明, 结合空间信息与光谱信息的图像分类方法能

基金项目: 国家自然科学基金“基于遥感的宁夏工业固体废物环境监测研究”(61461003); 北方民族大学校级创新项目(YCX1756)。

作者简介: 卢 佳(1992—), 女, 硕士, 主研方向为遥感图像处理与应用; 保文星(通信作者), 教授。

收稿日期: 2017-10-23 **修回日期:** 2018-01-13 **E-mail:** bwx71@163.com

够大幅提高分类精度。

近年来,稀疏表达在图像去噪、图像复原、人脸识别、高光谱图像解混可视化以及图像分类等领域得到广泛应用^[7-8]。文献[9]将稀疏表示用于高光谱遥感图像分类和目标检测中。为使分类结果具有较高的区域平滑性,文献[10]提出一种联合稀疏表示(Joint Sparse Representation, JSRC)。JSRC对所有位于局部邻域空间中的像元求解稀疏系数矩阵,然后计算邻域空间内所有像元的整体最小残差,以判断中心像元所属类别。上述方法虽然能够取得较好效果,但都只考虑高光谱图像的局部空间信息,并未深入探究图像的空间结构信息。

为更加有效地进行高光谱图像的空间特征提取,提高图像分类的精度,本文提出一种基于独立空谱残差融合联合稀疏表示高光谱图像分类算法ISSR-JSRC。使用类独立的光谱角分类(Class Independent Spectral Angle Classification, CISAC)方法进行高光谱图像初分类,得到各像元的初始标记后,根据初始标记构造像元邻域块,使用特定的筛选条件剥离邻域空间内相似度较小的干扰像元。在此基础上,充分挖掘高光谱图像的全局空间信息,使用信息字典求解图像的各独立特征信息稀疏表示系数。考虑到各特征信息具有不同的贡献率,采用残差融合算法确定最终的像元类别。

1 基于联合稀疏表示的高光谱图像分类

高光谱图像中各类地物呈现聚类的特点,其在一个小邻域空间内的像元较可能成为同一类别,即图像具有较高的空间相关性。联合稀疏表示模型充分考虑到这一特点,其假设位于一个小邻域空间内的像元可以用同一个字典中相同原子的不同线性组合表示^[10]。假设高光谱图像数据集为 $X = [x_i | x_1, x_2, \dots, x_N]$,其中, N 为总像素数。字典 $D = [D_1, D_2, \dots, D_i, \dots, D_C] \in \mathbb{R}^{b \times M}$,其中, C 代表样本的类别数, $\{D_i\}_{i=1,2,\dots,C}$ 为各类子字典, b 为波段数, M 为字典的原子数。以测试像元 x_i 为中心的邻域矩阵 $X = [x_i | x_1, x_2, \dots, x_i, \dots, x_k] \in \mathbb{R}^{b \times k}$,其联合稀疏表示模型如下:

$$A' = \operatorname{argmin} \|DA - X\|_F, \text{ s. t. } \|A\|_{\text{row},0} \leq K_0 \quad (1)$$

其中, $\|A\|_{\text{row},0}$ 为稀疏表示系数矩阵 A 的非零行, K_0 为稀疏级的上限, $\|\cdot\|_F$ 为Frobenius范数,用于计算重构误差。 $A = [a_1, a_2, \dots, a_i, \dots, a_k]$, a_i 为 X 中第 i 个像元(即中心像元)的稀疏向量。上述优化问题可由同步正交匹配追踪(Synchronous Orthogonal Matching Pursuit, SOMP)^[10]进行求解。SOMP认为相似的原子具有相同的稀疏特性。因此,在对相似原子进行稀疏表示时,假设稀疏原子位于相同的位置,其在过完备字典中选择的原子也

相同。

根据稀疏向量矩阵 A' 对于各个类别的最小残差,确定其类别为:

$$\text{label}(x)_i = \operatorname{argmin} r_i(X) = \operatorname{argmin} \|D_i A'_i - X\|_2 \quad (2)$$

其中, $r_i(X)$ 为邻域矩阵 X 由第 i 类子字典稀疏表示后的残差。

2 独立空谱残差融合联合稀疏表示分类

2.1 类独立光谱角初分类

计算测试像元与各类别训练集中像元的光谱角如下:

$$SA(x, y) = \arccos \left(\frac{\langle x, y \rangle}{\sqrt{\langle x, x \rangle \langle y, y \rangle}} \right) \quad (3)$$

其中, x, y 表示像元的光谱矢量, $SA(x, y)$ 计算测试光谱和目标光谱的光谱夹角^[11], $\langle \cdot, \cdot \rangle$ 为内积运算。

对于所有类别 $C_j (j \in 1, 2, \dots, c)$ 与训练样本 $x_i (i \in 1, 2, \dots, N)$,根据式(3)计算测试样本 y 与各个类别训练样本 x_{ij} 的光谱角 SAM_j 序列,对各类别的 SAM_j 序列进行升序排列,计算 $\sum_{m=1}^K SAM_j / K$,并作为测试样本 y 属于第 j 类的判断依据 SAM'_j 。测试样本 y 的类别确定如下:

$$\text{class}(y_j) = \operatorname{argmin}_{j=1,2,\dots,c} (SAM'_j)$$

本文通过CISAC方法的初分类得到原高光谱图像中各像元的初始标记。

2.2 高光谱图像的空间特征提取

形态学特征充分利用相邻像元的空间关联性和地物的几何特性^[12]。而纹理特征信息是一种全局信息,表示图像或者图像区域内地物的一种表面特征^[13]。形态学特征属于图像的几何空间特征,纹理特征属于图像的空间统计特征,本文结合这2种特征对图像空间信息进行充分挖掘。

2.2.1 基于数学形态学的特征提取

数学形态学是以一个已知大小和形状的结构元素来分析图像各像元间的空间关系,其基本运算包括膨胀、腐蚀、开运算和闭运算。膨胀和腐蚀定义如下:

$$A \oplus B = \{x: \hat{B}_x \cap A \neq \varphi\} \quad (4)$$

$$A \ominus B = \{x: B_x \subseteq A\} \quad (5)$$

其中, A 为待处理图像, B 为结构元素。

结合膨胀和腐蚀运算可实现形态学开运算和闭运算:

$$A \circ B = (A \ominus B) \oplus B \quad (6)$$

$$A \cdot B = (A \oplus B) \ominus B \quad (7)$$

本文通过选取不同尺度半径的圆盘结构元素,对各维高光谱图像进行多尺度的形态学特征提取。

2.2.2 基于灰度共生矩阵的纹理特征提取

灰度共生矩阵求解图像中每个像元的灰度级间联合条件概率密度,用其表示图像的纹理特征,从而描述图像任意 2 个像元间的灰度空间相关特性与纹理特征。改变图像纹理模板大小,设置不同的距离和角度,均可得到不同的灰度共生矩阵。为更直观地以共生矩阵描述纹理状况,通常用一些统计属性来表征灰度共生矩阵的特征。本文选取以下 3 种常见的统计属性。

1) 对比度:

$$f_1 = \sum_{n=0}^{L-1} n^2 \left\{ \sum_{i=0}^{L-1} \sum_{j=0}^{L-1} p(i, j) \right\} \quad (8)$$

对比度反映整幅图像的清晰度与纹理沟纹的深浅。对比度越大,纹理沟纹越深且图像越清晰^[12]。

2) 同质度:

$$f_2 = \sum_{i=0}^{L-1} \sum_{j=0}^{L-1} p(i, j) \frac{1}{1 + (i - j)^2} \quad (9)$$

同质度反映图像的局部灰度均匀度。

3) 熵:

$$f_3 = - \sum_{i=0}^{L-1} \sum_{j=0}^{L-1} p(i, j) \lg p(i, j) \quad (10)$$

熵反映图像本身所具有的信息量,描述图像纹理的复杂程度或非均匀程度^[12]。

2.3 算法步骤

基于联合稀疏表示的图像分类,其重点在于假设地物在一个小的邻域空间内具有高度空间相关性。由于图像中的地物边缘存在大量的干扰因素,直接构造邻域会引入大量非目标类像元。因此,本文使用初分类得到的初始标记来构造邻域空间,并剥离邻域空间内相似度较低的像元与训练像元。该过程既去除了大量误分类像元对中心像元的影响,也能够大幅降低地物边缘像元的干扰作用与训练像元对测试像元的影响。本文算法具体步骤如下:

1) 构建虚拟类别模块。使用初始类标记构造出整幅图像的分类标记图,根据分类标记图以测试像元为中心、大小为 $\sqrt{k} \times \sqrt{k}$ 构造邻域空间。由于初分类中存在误分类像元,因此需进行邻域空间内干扰像元的筛选,筛选原则为选择与测试像元初始标记相同的邻域空间内的像元进行邻域块构造,这样能大幅减少错误分类的干扰像元。由于以测试像元为中心的邻域空间中可能存在训练样本像元,本文将邻域空间内所有训练样本像元全部标记为 0,以非 0 标记为原则进行二次筛选并构造最终邻域空间,从而从根本上去除训练样本特征对测试样本信息的干扰。

2) 因为单一的字典极易忽略图像的局部信息,从而无法很好地显示图像块结构特性的区别。本文针对图像不同特征信息,使用不同特征信息字典进行稀疏表示,并使用具有单独特征信息的训练样本

直接构造特征信息字典。

3) 使用 SOMP 算法求解光谱、纹理、形态学的稀疏表示系数矩阵:

$$\begin{aligned} \mathbf{X}_{\text{光/纹/形}} &= \mathbf{D}_{\text{光/纹/形}} \mathbf{A}_{\text{光/纹/形}} \\ \mathbf{A}'_{\text{光/纹/形}} &= \operatorname{argmin} \|\mathbf{D}_{\text{光/纹/形}} \mathbf{A}_{\text{光/纹/形}} - \mathbf{X}_{\text{光/纹/形}}\|_F \\ \text{s. t. } \|\mathbf{A}_{\text{光/纹/形}}\|_{\text{row},0} &\leq K_0 \end{aligned} \quad (11)$$

4) 计算各特征信息稀疏表示系数矩阵对于各类特征信息字典的残差:

$$r_i = \|\mathbf{D}_i \mathbf{A}'_i - \mathbf{X}\|_2 \quad (12)$$

5) 根据最小残差准则计算各独立特征下的类别标记:

$$\text{label}(x)_{1,2,3} = \operatorname{argmin} r_i \quad (13)$$

由于本文采用 3 种信息进行稀疏表示,从而可以得到光谱信息的 $\text{label}(x)_1$ 、纹理信息的 $\text{label}(x)_2$ 、形态学信息的 $\text{label}(x)_3$ 。

残差融合方法步骤如下:

1) 如果 $\text{label}(x)_1 = \text{label}(x)_2 = \text{label}(x)_3 = i$, 则可判断测试像元属于第 i 类。

2) 如果 $\text{label}(x)_1 = \text{label}(x)_3 \neq \text{label}(x)_2 = i$ 或 $\text{label}(x)_2 = \text{label}(x)_3 \neq \text{label}(x)_1 = i$, 则判断测试像元属于第 i 类。

3) 如果 $\text{label}(x)_1 \neq \text{label}(x)_2 \neq \text{label}(x)_3 \neq i$ 或 $\text{label}(x)_1 = \text{label}(x)_2 \neq \text{label}(x)_3$, 对各特征信息的残差矩阵 \mathbf{r} 按列进行升序排列。对于所有的测试像元:排序后残差矩阵 \mathbf{r} 中前 M 位残差和为 $\sum_{j=1}^M \mathbf{r}_j(x)$, 纹理信息最小残差与前 M 位残差和的比值为 $e_2 = \mathbf{r}'(x) / \sum_{j=1}^M \mathbf{r}'_j(x)$, 形态学信息最小残差与前 M 位残差和的比值为 $e_3 = \mathbf{r}''(x) / \sum_{j=1}^M \mathbf{r}''_j(x)$ 。

如果 $e_2 < e_3$, 则判断测试像元所属类别为纹理信息最小残差所对应类别。

如果 $e_2 \geq e_3$, 则判断测试像元所属类别为形态学信息最小残差所对应类别。

本文独立空谱残差融合的联合稀疏表示分类算法描述如下:

输入 图像数据集、初分类训练样本比例、邻域空间尺寸 k 、各特征稀疏级 T

输出 各测试像元分类标记

1) 根据式(3)类独立光谱角分类方法对像元进行初分类,得到测试像元初始标记。根据初始标记构造各像元空间邻域块,进行邻域块内像元筛选。

2) 根据式(6)、式(7),采用尺度半径分别为 6、7 的圆盘结构元素对图像的各维特征图进行 1 次开闭运算以提取形态学特征。根据高光谱图像的纹理特点,使用 3 种基于灰度共生矩阵的统计量计算图像对比度、同质性、熵,用这 3 种统计量作为图像的纹理特征。

3) 使用各独立特征信息训练样本并直接构造特征独立字典。

4) 根据式(11)求解稀疏模型, 计算各独立信息的稀疏系数矩阵 A' 。

5) 根据式(12)计算各独立信息的稀疏系数矩阵对于各独立信息字典的残差。

6) 根据式(13)得到测试像元所对应的 3 种类别, 根据残差融合方法决定测试像元的具体类别。

独立空谱残差融合的联合稀疏表示分类算法流程如图 1 所示。

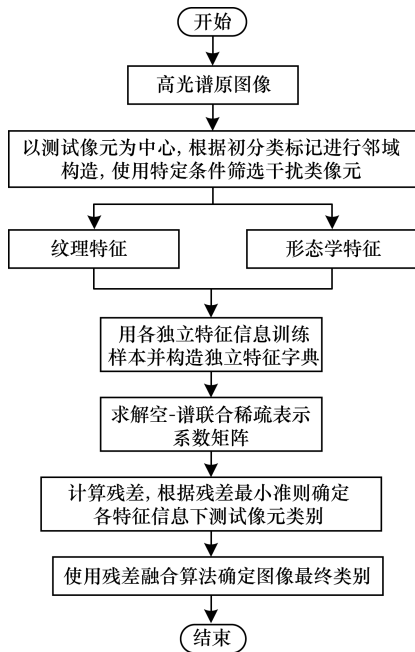


图 1 独立空谱残差融合的联合稀疏表示分类算法流程

3 实验结果与分析

3.1 对比算法

为验证本文算法的有效性, 将其与 SRC^[14]、SVM^[15]、KNN^[14]、cdSRC-KNN^[16]、SVMCK^[15]、JSRC^[17]、高斯滤波后的联合稀疏表示分类方法 (Gauss-JSRC) 进行对比分析。对于 KNN、SVM、SVMCK、cdSRC-KNN, 参数设置与原文献保持一致。对于数据集 1, JSRC 与 Gauss-JSRC 的邻域空间大小 $k=7 \times 7$, 稀疏级 $T=4$ 。对于数据集 2, 两者邻域空间大小 $k=3 \times 3$, 稀疏级分别为 25 与 45。以上涉及联合稀疏表示分类方法的实验在邻域块构造阶段, 均已去除训练样本特征对测试样本信息的影响。

3.2 评价指标

本次实验采用总体分类精度 (OA)、类别正确率 (CA)、平均分类精度 (AA) 和 Kappa 系数 4 个指标评价与衡量图像的分类效果^[16]。4 个指标计算如下:

1) OA 表示被正确分类样本个数占总测试样本

的比例:

$$OA = \frac{\sum_{i=1}^C M_{ii}}{N} \quad (14)$$

其中, M_{ii} 为正确分类样本的总数, N 为总的测试样本数, C 为总的类别数。

2) CA 指原属于第 i 类像元被正确分类为第 i 类的总数占第 i 类像元总数的比例:

$$CA_i = \frac{M_{ii}}{\sum_{j=1}^C M_{ji}} \times 100\% \quad (15)$$

其中, M 为 $L \times L$ 的混淆矩阵, M_{ji} 反映了类别 i 被分类为类别 j 的样本数量。

3) AA 指所有样本类别正确率的平均值:

$$AA = \frac{\sum_{i=1}^C CA_i}{C} \times 100\% \quad (16)$$

4) Kappa 系数是衡量分类精度的统计指标, 其可以精确反映分类结果的误差率:

$$Kappa = \frac{N(\sum_{i=1}^C M_{ii}) - \sum_{i=1}^C (\sum_{j=1}^C M_{ij} \sum_{j=1}^C M_{ji})}{N^2 - \sum_{i=1}^C (\sum_{j=1}^C M_{ij} \sum_{j=1}^C M_{ji})} \quad (17)$$

3.3 实验数据集及参数设置

本文选择 AVIRIS 与 ROSIS 两个高光谱遥感图像数据进行实验。

数据集 1 AVIRIS 的 Indiana Pines 数据拍摄于印第安纳州西北地区, 包括 220 个波段, 图像大小为 145×145 像素, 空间分辨率为 20 m, 谱间分辨率为 10 nm, 谱段范围为 $0.4 \mu\text{m} \sim 2.5 \mu\text{m}$, 包含 16 种地物。去除 20 个水汽吸收和低信噪比波段后, 选择剩下的 200 个光谱波段作为研究对象。在本组影像的各个类别中, 随机挑选 10% 的标记样本作为训练样本, 其余 90% 的标记样本作为测试样本。图 2 所示为训练样本与测试样本的图像信息。




图 2 数据集 1 图像信息

提取纹理特征: 使用大小为 21×21 的高斯模块遍历各维高光谱图像, 在模块内求取距离为 4, 角度分别为 0° 、 45° 、 90° 、 135° 的共生矩阵。提取所求共生矩阵的熵、对比度、同质性 3 个标量作为各维高光谱图像的纹理特征。

提取形态学特征: 建立半径为 6、7 的不同尺度大小的圆盘结构元素, 对各维高光谱图像进行一次开运算和一次闭运算, 得到图像的形态学特征。

本文 ISSR-JSRC 算法的关键步骤在于选取合适的初分类 CISAC 训练样本比例, 以及确定各特征信

息的最佳稀疏级 T 和邻域空间窗口尺寸 k 。本次实验通过分析不同 k 、 T 及样本比例对分类精度的影响来选取最优值,实验结果如图 3~图 5 所示。




图 3 CISAC 训练样本比例对分类精度的影响




图 4 各特征信息稀疏级 T 对分类精度的影响




图 5 邻域窗口大小 k 对分类精度的影响

由图 3 可以看出,随着训练样本比例的增大,分类精度先上升后下降。因此,本文选取 70% 样本作为 CISAC 初分类方法的训练样本。由图 4 可以看出,不同特征信息的最优稀疏级不同。因此,本文选择光谱信息稀疏级 $T=4$,纹理信息稀疏级 $T=10$,形态学信息稀疏级 $T=7$ 。由图 5 可以看出,随着邻域空间半径的增大,分类精度有所提高,当邻域大小 k 增长到一定范围时,分类精度增长趋于平缓。因此,本文选择邻域窗口大小为 $k=7 \times 7$ 。

数据集 2 ROSIS 的 University of Pavia 高光谱遥感图像数据拍摄于意大利帕维亚大学,其包含 115 个波段,图像大小为 610×340 像素,空间分辨率为 1.3 m,波段范围为 $0.43 \mu\text{m} \sim 0.86 \mu\text{m}$,包含 9 种地物。去除噪

声波段后,选择剩余的 103 个波段作为研究对象。在本组影像的各个类别中,随机挑选 9% 的标记样本作为训练样本,其余 91% 的标记样本作为测试样本。图 6 所示为训练样本与测试样本的图像信息。




图 6 数据集 2 图像信息

对于数据集 2,对其进行与数据集 1 同样的参数设置。经过实验比较分析,初分类选择 30% 的标定数据作为训练样本。设置光谱信息稀疏级 $T=25$,形态学信息稀疏级 $T=25$,纹理信息稀疏级 $T=40$,邻域空间大小 $k=3 \times 3$ 。

提取纹理特征:使用大小为 27×27 的模块遍历各维高光谱图像,在模块内求取距离为 8,角度分别为 0° 、 45° 、 90° 、 135° 的共生矩阵。提取所求共生矩阵的熵、对比度、同质性 3 个标量作为各维高光谱图像的纹理特征。

提取形态学特征:建立半径为 6、7 的不同尺度大小的圆盘结构元素,对各维高光谱图像进行一次开运算和一次闭运算,得到图像的形态学特征。

3.4 算法性能分析

针对数据集 1,各算法分类结果如表 1 所示。从表 1 可以看出,仅考虑光谱信息的分类方法 SVM、KNN、SRC 指标值低于考虑空间近邻信息的分类方法 cdSRC-KNN、JSRC、Gauss-JSRC 及结合多特征信息的分类方法 SVMCK。因此,结合空间近邻信息与图像的空间特征,有利于提高总体分类精度。Gauss-JSRC 算法分类精度较高的原因在于,高斯滤波本身就是对图像进行加权平均的过程,高斯滤波后图像中每个像素的值都是根据该像素与其所在邻域空间内其他像素加权平均后所得来,即其已经利用了像元邻域的空间信息。本文算法对高斯滤波后的图像进行联合稀疏表示,再一次考虑邻域空间信息,因此,其总体分类精度最高。综上,可得出以下结论:

1) 相较于 SVMCK 算法,本文算法不仅考虑了多特征,而且结合了图像的空间近邻信息。

2) 相较于 JSRC、Gauss-JSRC 算法,本文算法加入了整体空间信息,不仅考虑到像元的空间近邻信息,也考虑到整幅图像的空间结构信息,在此基础上算法进行空间特征信息的充分提取。

3) 在同等训练样本比例下,本文算法无论是总体分类精度、类别正确率、平均分类精度还是 Kappa

系数,都具有较好的效果,并且对多数类别地物的分类精度也较高,这充分验证了该算法的优越性。

表 1 数据集 1 中各算法分类精度结果对比

图像集中 地物类别	训练像素	测试像素	分类精度/%							
			SVM	KNN	SRC	JSRC	Gauss-JSRC	cdSRC-KNN	SVMCK	ISSR-JSRC
Alfalfa	6	48	77.73	83.66	55.12	86.94	94.89	10.00	85.84	98.64
Corn-notill	144	1 290	77.35	65.75	61.60	79.95	91.57	81.32	89.78	99.51
Corn-min	84	750	78.56	70.22	58.62	81.04	92.22	85.08	87.60	99.45
Corn	24	210	68.75	55.20	42.21	67.96	92.65	89.80	88.76	98.82
Pasture	50	447	88.87	91.80	87.29	92.35	91.65	93.61	96.83	99.89
Trees	75	672	89.12	83.27	95.30	89.22	93.87	95.53	97.85	99.90
Pasture-mowed	3	23	95.37	76.71	85.20	74.78	81.16	0.00	73.92	100.00
Hay-windrowed	49	440	95.09	94.60	96.44	99.95	100.00	87.33	98.64	100.00
Oats	2	18	67.65	77.15	36.67	1.11	19.44	0.00	54.44	85.19
Soybean-notill	97	871	78.64	68.28	71.10	87.62	94.05	85.69	90.36	99.26
Soybean-min	247	2 221	81.19	74.32	74.11	86.95	96.91	76.19	93.64	99.53
Soybean-clean	62	552	79.74	75.27	51.05	84.95	86.11	91.37	86.27	98.61
Wheat	22	190	92.26	85.86	96.85	71.20	88.74	100.00	98.84	100.00
Woods	130	1 164	92.72	93.24	91.85	96.41	98.68	93.49	98.87	99.94
Building	38	342	69.79	66.70	41.67	57.43	94.00	84.73	93.74	99.95
Stone-Street-Towers	10	85	97.96	97.20	91.90	94.35	90.00	97.78	95.06	100.00
OA	—	—	82.910	77.130	73.380	85.670	94.150	85.150	92.700	99.540
AA	—	—	83.170	73.020	71.060	78.230	87.870	67.590	88.770	98.670
Kappa	—	—	0.805	0.738	0.696	0.836	0.933	0.829	0.917	0.994

为测试不同训练样本比例对各算法总体分类精度的影响,随机挑选5%~30% 的标定数据作为训练样本进行重复实验,结果如图 7 所示。

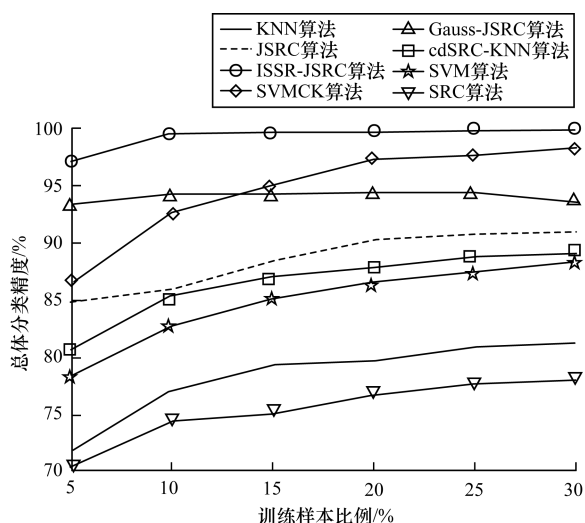


图 7 不同训练样本比例下各算法分类精度比较

从图 7 可以看出,随着训练样本比例的增加,各算法总体分类精度均有所提高,且当训练样本数

量达到一定比例后,总体分类精度的增长速度相对减缓。该结果表明,相对于仅考虑光谱特征的分类方法,基于空间信息与空间-光谱特征的分类方法具有较好的分类精度。其中,本文算法具有最优的分类表现,且在小样本情况下仍具有较高的分类精度。

由于数据集 2 具有较高的空间分辨率,因此其形状与纹理信息更具价值。针对数据集 2,各算法分类结果如表 2 所示,该结果与数据集 1 较相似。SVM、SRC、KNN 的分类精度总体较好,但其仍然低于结合空间近邻信息的 cdSRC-KNN、JSRC 与 Gauss-JSRC,也低于充分挖掘空间结构信息、结合多特征的 SVMCK。对于数据集 2,JSRC 分类精度较低,原因在于本数据集中各类地物分布区域较窄且分散,受背景像元影响较大,并不存在大范围的同类地物,因此,在去除邻域块内训练样本对测试样本影响后会导致该算法分类精度较低。而本文 ISSR-JSRC 算法在去除邻域块内训练样本对测试样本的影响后,仍具有最优的分类效果,再次验证了该算法的有效性与优越性。

表 2 数据集 2 中各算法分类精度结果对比

图像集中 地物类别	训练像素	测试像素	分类精度/%							
			SVM	KNN	SRC	JSRC	Gauss-JSRC	cdSRC-KNN	SVMCK	ISSR-JSRC
Asphalt	597	6034	84.12	77.63	77.48	70.79	98.36	86.56	79.85	99.29
Meadows	1 678	16 971	70.68	98.99	95.09	97.61	99.84	88.92	84.86	99.98
Grave	189	1 910	71.89	61.64	62.59	68.05	94.79	75.69	81.87	98.85
Metalsheets	276	2 788	98.50	81.18	84.58	87.29	96.10	97.26	96.36	97.64
Trees	121	1 224	99.41	99.25	99.43	99.91	99.94	100.00	99.37	99.97
Bare Soil	453	4 576	94.13	45.72	56.07	54.76	98.04	90.24	93.55	99.52
Bitumen	120	1 210	91.50	82.18	76.89	88.20	97.00	84.95	90.21	98.53
Bricks	331	3 351	92.61	87.21	77.22	82.50	79.90	74.99	92.81	99.10
Shadows	85	862	98.52	93.33	95.65	98.00	88.49	100.00	95.35	97.70
OA	—	—	81.630	84.650	83.470	84.720	96.830	87.670	87.180	99.440
AA	—	—	89.000	80.790	80.560	83.010	95.780	80.750	90.470	99.100
Kappa	—	—	0.769	0.791	0.776	0.794	0.947	0.833	0.830	30.993

4 结束语

本文通过深入挖掘高光谱图像像元之间的空间近邻信息与图像的全局空间信息,提出一种独立空谱残差融合的联合稀疏表示分类算法。实验结果表明,该算法具有较高的分类精度。但本文算法计算量较大,时间复杂度较高,解决该问题是下一步的研究方向。

参考文献

- [1] LI J, BIOUCAS-DIAS J M, PLAZA A. Semisupervised hyperspectral image classification using soft sparse multinomial logistic regression[J]. IEEE Geoscience and Remote Sensing Letters, 2013, 10(2): 318-322.
- [2] MELGANI F, BRUZZONE L. Classification of hyperspectral remote sensing images with support vector machines[J]. IEEE Transactions on Geoscience and Remote Sensing, 2003, 42(8): 1778-1790.
- [3] CAMPS-VALLS G, SHERVASHIDZE N, BORGWARDT K M. Spatio-spectral remote sensing image classification with graph kernels[J]. IEEE Geoscience and Remote Sensing Letters, 2010, 7(4): 741-745.
- [4] 刘建军, 吴泽彬, 韦志辉, 等. 基于空间相关性约束稀疏表示的高光谱图像分类[J]. 电子与信息学报, 2012, 34(11): 2666-2671.
- [5] TAN K, HU J, LI J, et al. A novel semi-supervised hyperspectral image classification approach based on spatial neighborhood information and classifier combination[J]. ISPRS Journal of Photogrammetry and Remote Sensing, 2015, 105: 19-29.
- [6] 黄鸿, 郑新磊. 加权空-谱与最近邻分类器相结合的高光谱图像分类[J]. 光学精密工程, 2016, 24(4): 873-881.
- [7] LI J, HUANG X, GAMBA P, et al. Multiple feature learning for hyperspectral image classification[J]. IEEE Transactions on Geoscience and Remote Sensing, 2015, 53(3): 1592-1606.
- [8] 王哲伟. 基于稀疏表示残差融合的人脸表情识别[D]. 江门: 五邑大学, 2011.
- [9] CHEN Y, NASRABADI N M, TRAN T D. Classification for hyperspectral imagery based on sparse representation[C]//Proceedings of Workshop on Hyperspectral Image and Signal Processing: Evolution in Remote Sensing. Washington D. C., USA: IEEE Press, 2010: 1-4.
- [10] CHEN Y, NASRABADI N M, TRAN T D. Hyperspectral image classification using dictionary-based sparse representation[J]. IEEE Transactions on Geoscience and Remote Sensing, 2011, 49(10): 3973-3985.
- [11] 刘万军, 杨秀红, 曲海成, 等. 基于光谱信息散度与光谱角匹配的高光谱解混算法[J]. 计算机应用, 2015, 35(3): 844-848.
- [12] 王增茂, 杜博, 张良培, 等. 基于纹理特征和形态学特征融合的高光谱影像分类法[J]. 光子学报, 2014, 43(8): 1-2.
- [13] 尹明, 谭熊, 张鹏强, 等. 一种基于纹理和光谱特征的高光谱影像信息向量机分类方法[J]. 测绘科学技术学报, 2015, 32(4): 368-372.
- [14] CHEN C, CHEN N, PENG J. Nearest regularized joint sparse representation for hyperspectral image classification[J]. IEEE Geoscience and Remote Sensing Letters, 2016, 13(3): 424-428.
- [15] ROSCHER R, WASKE B. Shapelet-based sparse representation for landcover classification of hyperspectral images[J]. IEEE Transactions on Geoscience and Remote Sensing, 2016, 54(3): 1623-1634.
- [16] CUI M S, PRASAD S. Class-dependent sparse representation classification for robust hyperspectral image classification[J]. IEEE Transactions on Geoscience and Remote Sensing, 2015, 53(5): 2085-2086.
- [17] FU W, LI S, FANG L. Spectral-spatial hyperspectral image classification via superpixel merging and sparse representation[C]//Proceedings of Geoscience and Remote Sensing Symposium. Washington D. C., USA: IEEE Press, 2015: 4971-4974.

编辑 吴云芳