

## 面向迁移学习的文本特征对齐算法

魏晓聪<sup>1,2</sup>, 林鸿飞<sup>1</sup>

(1. 大连理工大学 计算机科学与技术学院, 辽宁 大连 116024; 2. 大连外国语大学 软件学院, 辽宁 大连 116044)

**摘 要:** 源领域和目标领域特征空间的不一致导致迁移学习准确率下降。为此, 提出一种基于 Word2Vec 的不同领域特征对齐算法。只选取形容词、副词、名词、动词作为特征, 针对每种词性, 选择源领域和目标领域的枢纽特征, 分别在源领域和目标领域为该枢纽特征计算出与之语义相似度最大的非枢纽特征, 将其作为相似枢纽特征, 从而为每个枢纽特征构成一个相似枢纽特征对。将出现在这些领域中的每一个相似枢纽特征按照枢纽特征对进行特征替换, 从而将不同领域语义相似的特征进行对齐, 并在特征替换后的源领域和目标领域数据上进行机器学习。实验结果表明, 该算法的平均分类精度达到 88.2%, 高于 Baseline 算法。

**关键词:** 迁移学习; 特征对齐; 情感分析; 源领域; 目标领域

**中文引用格式:** 魏晓聪, 林鸿飞. 面向迁移学习的文本特征对齐算法[J]. 计算机工程, 2017, 43(2): 215-219, 226.

**英文引用格式:** Wei Xiaocong, Lin Hongfei. Transfer Learning Oriented Text Feature Alignment Algorithm[J]. Computer Engineering, 2017, 43(2): 215-219, 226.

## Transfer Learning Oriented Text Feature Alignment Algorithm

WEI Xiaocong<sup>1,2</sup>, LIN Hongfei<sup>1</sup>

(1. School of Computer Science and Technology, Dalian University of Technology, Dalian, Liaoning 116024, China;

2. School of Software, Dalian University of Foreign Languages, Dalian, Liaoning 116044, China)

**[Abstract]** The inconsistency between source domain and target domain feature spaces results in accuracy decline of transfer learning. To resolve this problem, this paper proposes a different domain feature alignment method based on Word2Vec. Adjectives, adverbs, nouns and verbs are selected as features. Pivot feature is selected from source domain and target domain for every part of speech. The most similar non-pivot feature is calculated for each pivot feature respectively from source domain and target domain as similar pivot feature. Then similar pivot feature pairs are constructed accordingly. Every similar pivot feature appearing in both domains is transformed according to similar pivot feature pairs. Consequently, the features which represent similar semantic information are aligned. Machine learning is performed on source domain and target domain data after feature transformation. Experimental result shows that the average accuracy of the proposed algorithm is 88.2%, higher than Baseline algorithm.

**[Key words]** transfer learning; feature alignment; emotion analysis; source domain; target domain

**DOI:** 10.3969/j.issn.1000-3428.2017.02.036

### 0 概述

近年来, 跨领域迁移学习在机器学习和自然语言处理领域得到了越来越多的关注。随着社会媒体(例如: 博客、社交网络)的崛起, 网络上涌现了大量的评论文本, 如何对这些海量文本快速而自动地检测情感极性(支持或反对), 即文本情感倾向性分析, 显得越来越重要。研究者已经针对这方面做了大量的工作<sup>[1-3]</sup>。然而, 传统的情感倾向性分析主要关注

文本来自同一领域, 即对某一领域的有标签的文本进行机器学习训练模型, 然后利用该模型对同样来自该领域的无标签的目标文本进行情感分析。但是, 在很多情况下, 手头有大量的有标签的文本, 而需要进行情感倾向性分析的无标签的目标文本却来自于不同的领域。人工标注文本既费时又费力, 而且存在很大的主观性。如果可以通过某种算法根据现有有标签的文本去判断其他领域无标签文本的情感倾向, 将大大节省人工标注文本的成本。因此, 如

**基金项目:** 国家自然科学基金(61572102, 61562080); 大连外国语大学科研基金(2014XJQN14)。

**作者简介:** 魏晓聪(1982—), 女, 讲师、博士研究生, 主研方向为自然语言处理、情感计算、机器学习; 林鸿飞, 教授、博士生导师。

**收稿日期:** 2016-01-15      **修回日期:** 2016-03-11      **E-mail:** weixiaocong@dlutl.edu.cn

何利用某一领域训练的模型对来自不同领域的文本情感极性进行准确的判断,即迁移学习要研究的问题。

不同领域的情感用词以及情感词概率分布有所不同。如在书籍的评论文本中,“exciting”和“graphic novel”表达了正面的情感,“boring”和“drowsy”表达的是负面的情感。而在电子产品领域,“durable”和“light”通常表达的是正面的情感,而“expensive”和“short battery life”表达的是负面的情感。这时,如果在书籍评论文本上进行机器学习训练,将得到的模型直接去预测电子产品领域评论文本,效果往往不好。因为,机器学习的一个重要的假设:训练数据和测试数据必须在同一特征空间下并且分布相同。因此,如何让训练数据和测试数据的特征对齐在同一特征空间下,是解决迁移学习问题的途径之一。

为此,本文提出一种解决不同领域特征对齐的算法,将深度学习引入到迁移学习当中。通过深度学习工具 Word2Vec 训练词向量挖掘出语义相关的特征,对不同领域语义相关的特征进行对齐。

## 1 相关研究

近年来,研究者提出了各种各样的迁移学习解决算法。文献[4]提出了结构对应学习(Structure Correspondence Learning, SCL)算法。考虑到来自源领域有标签数据和来自源领域以及目标领域的无标签数据,SCL 通过构建枢纽特征与非枢纽特征的关联模型完成迁移学习。文献[5]提出谱特征对齐(Spectral Feature Alignment, SFA)算法。该算法利用领域独立词作为桥梁,通过领域独立词以及谱聚类算法构建不同领域的领域特有性词的潜在公共空间,减少不同领域的差异进行迁移学习。文献[6]提出了一种基于特征变换的跨领域情感分析算法。首先选取枢纽特征,然后根据提出的关联度计算算法计算出源领域和目标领域依赖词。分别对这 2 个领域的文本进行特征变换,完成知识迁移。文献[7]将句子根据情感贡献度划分为 key view 和 detail view 视图。在 2 个视图上训练 2 个不同的基分类器并进行有效集成实现迁移学习。文献[8]借助联合非负矩阵因子分解框架以及枢纽特征将情感极性相同的多种输入特征进行联合从而完成迁移学习。文献[9]从自动构建的语义字典中选取相关的特征词来扩展特征向量帮助迁移学习。文献[10]提出了特征集成加样本选择(Feature Ensemble Plus Example Selection, SS-FE)算法,该算法为基于词性特征集成的标签适应性算法,它将其提出的特征集成模型(FE)与实例适应

性算法(PCA-SS)相结合完成迁移学习。文献[11]使用共享子空间构造(Common Subspace Construction, CSC)算法计算源领域和目标领域特征情感倾向,并将在 2 个领域都表达相同情感倾向的一些特征作为领域独立特征来构建公共特征子空间。然而,只有这些独立特征还不够。该工作将一些领域依赖特征选取出来。最后,基于公共特征子空间来表示评论文本并在其上训练模型来进行目标领域情感倾向预测。文献[12]提出通过不同领域的公共主题建立其他主题之间的对应关系来减小不同领域的分布差异,最终在优化目标函数的过程中自动发现主题并对其进行情感分类。另外,随着深度学习的持续加温,深度学习可以自动地从文本数据中抽象出特征,从而避免了手工特征的选取,这一特性吸引了一些学者将深度学习应用在文本分类迁移学习中,如文献[13-15]在多任务,如词性标注、命名实体识别和语言模型等进行迁移学习,构建了一个多任务深度神经网络迁移框架。

## 2 迁移学习下的特征不匹配解决算法

### 2.1 相关定义

领域:一个领域  $D$  由 2 部分组成,特征空间  $X$  和边缘概率分布  $P(X)$ 。 $X$  是所有特征向量组成的空间,是一个特定的学习样本。一般情况下,不同领域的特征空间和边缘概率分布是不同的。本工作只考虑一个源领域与一个目标领域的迁移学习问题。

源领域: $D_s = \{(X_{s_i}, Y_{s_i})\}_{i=1}^{n_s}$  是指某一领域的有标签评论文本。在本工作中, $X_{s_i}$  代表的是第  $i$  条有标签的评论, $Y_{s_i}$  是  $X_{s_i}$  的情感标签, $Y_{s_i} \in \{+1, -1\}$ 。 $+1$  和  $-1$  分别代表正向和负向的情感。 $n_s$  表示源领域的评论文本总数。源领域第  $i$  条评论文本表示为  $X_{s_i} = \{x_1^{s_i}, x_2^{s_i}, \dots, x_n^{s_i}\}$ , 其中,  $x_n^{s_i}$  表示第  $n$  个特征。

目标领域: $D_t = \{(X_{t_i})\}_{i=1}^{n_t}$  表示来自某一领域的无标签的评论文本。该领域与源领域不同但相关。 $X_{t_i}$  代表该领域中第  $i$  条评论, $n_t$  表示目标领域的评论文本总数,目标领域第  $i$  条评论文本表示为  $X_{t_i} = \{x_1^{t_i}, x_2^{t_i}, \dots, x_n^{t_i}\}$ , 其中,  $x_n^{t_i}$  表示第  $n$  个特征。

跨领域情感分类:定义迁移学习任务为将从源领域中学习的二元分类模型去对目标领域的情感标签  $Y_{t_i}$  进行预测。

### 2.2 相关概念

枢纽特征:在源领域和目标领域中频繁共同出现的一些特征,通常可以用作表达不同领域的公共知识,称之为枢纽特征。

非枢纽特征:除去枢纽特征之外的所有特征,称

之为非枢纽特征。

相似枢纽特征:在一个领域中,针对某一枢纽特征,如果某个非枢纽特征和它最相似,称之为相似枢纽特征。

### 2.3 Word2Vec 模型训练

Word2Vec 是基于深度学习的训练词向量工具。该工具从高维向量空间中学习词语的向量表达。这样的向量表达可以在低维空间上进行 cosine 相似性计算。本工作将训练得到的词向量文件进行上下文词与词之间的语义相似度计算。为每个枢纽特征寻找与之语义相似度高的非枢纽特征,从而为解决不同领域特征对齐问题做准备。首先,对源领域和目标领域的数据集进行预处理,去除标点符号、分词。接下来分别对每个领域进行 Word2Vec 模型训练,从而针对每一个领域得到一个训练好的 Word2Vec 模型。Word2Vec 训练模型流程描述为:输入源领域数据  $D_s = \{(X_{s_i})\}_{n_{s_i}=1}$  或目标领域数据  $D_t = \{(X_{t_i})\}_{n_{t_i}=1}$  以及词向量维数  $\theta$ 。对上述领域数据去除标点符号、分词,训练 Word2Vec 模型  $W_s$  或  $W_t$  并输出。

### 2.4 特征对齐迁移学习算法

源领域和目标领域之间的枢纽特征在领域之间起到了桥梁的作用,有助于迁移学习。这些高频共现词可以很好地表示公共知识。然而,只有枢纽特征这些公共知识还远远不够,如果能进一步地构建更多的公共知识会有利于迁移学习。通过观察发现,对于某个枢纽特征,如果能在源领域的非枢纽特征中找到一个语义上与之最相似的特征  $A$ ,在目标领域也找到这样一个特征  $B$ ,那么这 2 个特征  $A$  和  $B$  在语义上也应该是相似的。那么,将源领域评论文本中出现的每一个特征  $A$  都进行特征替换,表示为  $A\_B$ 。同理,将目标领域中出现的每一个特征  $B$  进行特征替换,也表示为  $A\_B$ 。这样就将不同领域上语义相同的特征进行了对齐,从而扩大了公共知识空间。形容词、副词、动词以及名词具有强烈情感<sup>[2]</sup>。构建具有情感特征词的公共知识空间会更加有利于迁移学习下的情感倾向性分析。因此,本文选择以上 4 种词性的枢纽特征,相似枢纽特征的选取也分别只针对这些词性。但是,在词性标注过程中会出现一个词被同时标注为多种词性的情况。譬如在本工作中,单词“read”会被同时标注为形容词、副词、动词以及名词。在这种情况下,只选取其一种词性,依据的顺序为形容词、副词、名词、动词。为了验证这个顺序的合理性,首先进行领域内实验。对来自同一领域的训练集和测试集进行分类,得到的平均准确率表示为  $Acc_{sd}$ ,将得到的分类模型直

接对来自另外一个领域的数据集进行预测,得到的平均准确率表示为  $Acc_{od}$ ,  $Acc$  表示上述两者的变化,  $Acc = \| Acc_{sd} - Acc_{od} \|$ , 结果如表 1 所示。由此可见,形容词在领域变化时的稳定性更好,其次是副词、名词、动词。因此,将依照这个顺序选取词性。

表 1 不同词性在领域变化中的稳定性

词性	Acc
形容词	0.004 0
副词	0.005 6
名词	0.011 9
动词	0.011 4

本文对源领域  $D_s$  和目标领域  $D_t$  进行词性标注,将 2 个领域词性为形容词的共现词提取出来,只选取其中共现的 top- $N$  个共现词作为枢纽特征,从而构造了枢纽特征集  $\{x_k\}_{k=1}^N$ 。其次,从枢纽特征集中选取枢纽特征  $x_k$ ,利用源领域 Word2Vec 训练的模型  $W_s$  进行相似度计算,求出与  $x_k$  最相似的、词性为形容词的非枢纽特征  $A$ 。同理,利用目标领域训练的 Word2Vec 模型  $W_t$  求出与  $x_k$  最相似的词性为形容词的非枢纽特征  $B$ ,对于枢纽特征  $x_k$  就构成了一个相似枢纽特征对  $(A, B)$ 。例如在 books 领域和 DVD 领域中,存在枢纽特征 annoying,通过在 books 领域训练 Word2Vec 词向量并计算语义相似度可以求出与 annoying 词性相同且语义最相关的特征为 defective,通过在 DVD 领域训练 Word2Vec 词向量并计算语义相似度可以求出与 annoying 词性相同且语义最相关的特征为 inferior,从而针对枢纽特征 annoying,找到了相似枢纽特征对 (inferior, defective),枢纽特征以及与源领域、目标领域的相似枢纽特征对应关系如图 1 所示。



图 1 枢纽特征与相似枢纽特征

为枢纽特征集中的每个枢纽特征都计算出上述所示的非枢纽特征对,对源领域和目标领域评论文本分别进行特征替换。例如在源领域评论文本中,如某条评论文本  $X_{s_i}$  中出现了特征  $A$ ,则对其进行特征替换,  $X_{s_i} = \{x_1^{s_i}, x_2^{s_i}, A\_B, \dots, x_n^{s_i}\}$ ,在目标领域评论文本中,如某条评论文本  $X_{t_j}$  出现了特征  $B$ ,则对其也进行特征替换:

$$X_{t_j} = \{x_1^{t_j}, x_2^{t_j}, A\_B, \dots, x_n^{t_j}\}$$

接下来,再对其他词性的特征进行如上所示的

处理。例如在源领域为 DVD, 目标领域为 Book 的分类任务中, DVD 领域中的某一条评论里出现了特征“inferior”, 就将该条评论中的此特征替换为“inferior\_defective”。同时, Book 领域中的某一条评论里出现了特征“defective”, 也将该条评论中的此特征替换为“inferior\_defective”。这样, 通过枢纽特征, 就将语义相似的特征词进行了对齐。特征替换之后的源领域、目标领域数据集  $D'_S = \{(X_{S_i}, Y_{S_i})\}_{i=1}^{n_S}$  和  $D'_T = \{(X_{T_i})\}_{i=1}^{n_T}$ 。在  $D'_S$  上进行机器学习训练, 得到模型  $M$ , 对  $D'_T$  的标签  $Y_{T_i}$  进行预测。特征对齐迁移学习算法流程描述为: 输入源领域已标注数据集  $D_S = \{(X_{S_i}, Y_{S_i})\}_{i=1}^{n_{S_i=1}}$ 、目标领域未标注数据集  $D_T = \{(X_{T_i})\}_{i=1}^{n_{T_i=1}}$ 、枢纽特征数量  $N$ 、源领域 Word2Vec 训练模型  $W_S$  以及目标领域 Word2Vec 训练模型  $W_T$ 。针对形容词、副词、名词、动词, 分别为每种词性从  $D_S$  与  $D_T$  中抽取数量为 top- $N$  的共现词  $\{x_k\}_{k=1}^N$ 。对于每个  $x_k$ , 通过  $W_S$  计算  $D_S$  非枢纽特征中与之最相似特征  $A$ , 通过  $W_T$  计算  $D_T$  中与之最相似特征  $B$ , 将出现在  $D_S$  中的每一个特征  $A$  特征替换为  $A\_B$ , 将出现在  $D_T$  中的每一个特征  $B$  特征替换为  $A\_B$ 。最后, 得到特征替换后的  $D'_S = \{(X_{S_i}, Y_{S_i})\}_{i=1}^{n_{S_i=1}}$  和  $D'_T = \{(X_{T_i})\}_{i=1}^{n_{T_i=1}}$ 。在  $D'_S$  上训练 SVM 分类器  $M$ , 通过  $M$  预测目标领域标签  $\{(Y_{T_i})\}_{i=1}^{n_{T_i=1}}$  并输出。

### 3 实验结果与分析

#### 3.1 数据集

本文数据集采用 Amazon 产品评论数据集<sup>[4]</sup>。该数据集广泛用于迁移学习的各种实验算法评测中。它包括 4 个领域的产品评论: books(B), DVDs(D), electronics(E), kitchen appliances(K)。每个领域分别有 1 000 条正向评论和 1 000 条负向评论文本。本文构建了 12 对迁移学习任务, D → B, E → B, K → B, K → E, D → E, B → E, B → D, K → D, E → D, B → K, D → K, E → K, 箭头前代表的是源领域, 箭头后代表的是目标领域。

#### 3.2 实验结果对比

为了验证提出的算法的有效性, 本文与 SCL-MI、SFA 以及 SS-FE 迁移学习算法进行对比实验, 结果如表 2 所示。本文采用支持向量机 (Support Vector Machine, SVM) 作为基准分类器, 采用传统的 Bag-of-Words 文本表示算法, 并对语料进行预处理, 去标点符号、全部转换为小写形式、分词、去停用词、去除数字等。本文采用 Word2Vec 训练模型, 词向量维度为 150, 每种词性的枢纽特征数量为 200 个, 采用精度 (Accuracy) 作为分类结果的评价标准。

表 2 不同算法下的迁移学习分类精度对比

领域	SCL-MI	SFA	SS-FE	本文算法
D → B	0.797	0.775	0.804	0.857
E → B	0.754	0.757	0.729	0.877
K → B	0.686	0.748	0.729	0.845
B → D	0.758	0.814	0.791	0.883
E → D	0.706	0.772	0.746	0.901
K → D	0.769	0.770	0.757	0.896
B → E	0.759	0.725	0.742	0.885
D → E	0.741	0.767	0.771	0.882
K → E	0.868	0.851	0.829	0.907
B → K	0.789	0.788	0.781	0.874
D → K	0.814	0.808	0.778	0.886
E → K	0.859	0.868	0.849	0.893

从表 2 可以看出, SCL-MI 平均准确率为 77.5%, SFA 为 78.7%, SS-FE 为 77.6%, 而本文算法为 88.2%, 在精度上优于其他 baselines 算法。这是因为 Word2Vec 能够很好地分析语义关系, 从而找到语义上相似的特征。本文使用 Word2Vec 分别针对每一个单独的领域训练词向量, 能更好针对某一领域捕捉语义相关词。由于具有强烈情感倾向的词对整个文本的情感倾向起到了主导作用, 因此本文工作只考虑形容词、副词、名词、动词这 4 种具有强烈情感的词性。借助这 4 种词性的枢纽特征, Word2Vec 将在不同领域与枢纽特征语义相似的特征选取出来, 对源领域和目标领域分别进行特征替换, 从而将出现在不同领域具有强烈情感倾向的语义上相似的特征统一成一种特征表示形式, 扩大了公共的语义情感特征空间, 构建了更多公共知识, 减小了领域差异性导致的情感特征词不匹配, 从而提高迁移了学习质量。利用基于深度学习的 Word2Vec, 一个优势还在于即使训练数据集规模比较小, 也能获得比较好的结果。本文工作针对每一个领域单独进行 Word2Vec 训练, 虽然每一个训练集规模只有 2 000 条评论, 但是也能获得该领域词之间的语义关系, 从而找到语义相关特征提高迁移学习质量。这将有利于本文将该工作扩展到更多的领域种类。只需要从每一个新的领域中获得一些未标注的训练语料 (这是很容易并且无需太多成本就可以获取到的), 就可以进行 Word2Vec 模型训练辅助迁移学习。

#### 3.3 参数敏感性

图 2 ~ 图 5 为每种词性的枢纽特征数量对整个实验结果的影响。当 Word2Vec 训练词向量的维数为 150 时, 总体来说, 每种词性的枢纽特征数量达到 200 个时, 迁移效果最好。图 6 为当每种词性的枢纽

特征数量达到 300 个时, Word2Vec 训练词向量的维数对实验准确率的影响。可以看到, 维数达到 150 维时, 实验结果最好。然而, 并不是维数越大越好。当维数继续增加时, 准确率下降。




图 2 Book 领域分类准确率




图 3 DVD 领域分类准确率




图 4 Electronics 领域分类准确率




图 5 kitchen appliances 领域分类准确率




图 6 词向量维数对分类准确率的影响

## 4 结束语

本文提出一种面向迁移学习的特征对齐算法。通过形容词、副词、名词、动词这 4 种词性的枢纽特征, 分别在源领域和目标领域计算非枢纽特征和枢纽特征语义相似度, 选取最相似的非枢纽特征作为相似枢纽特征, 将出现在这些领域的相似枢纽特征全部进行特征替换, 从而对不同领域语义相似的特征进行对齐。实验结果验证了该算法的有效性。在下一步工作中, 将利用维基百科或者 Google News 上训练的 Word2Vec 模型, 在具有更多种类领域的更大的数据集上进行实验。也将尝试通过深度学习算法自动学习特征, 而非人工选取特征进行迁移学习。

## 参考文献

- [1] Pang B, Lee L. Opinion Mining and Sentiment Analysis[J]. Foundations and Trends in Information Retrieval, 2008, 2(1/2): 1-135.
- [2] Liu B. Sentiment Analysis and Opinion Mining [J]. Synthesis Lectures on Human Language Technologies, 2012, 5(1): 1-167.
- [3] Pang B, Lee L, Vaithyanathan S. Thumbs Up?: Sentiment Classification Using Machine Learning Techniques [C]// Proceedings of the ACL-02 Conference on Empirical Methods in Natural Language Processing. Philadelphia, USA: ACL, 2002: 79-86.
- [4] Blitzer J, McDonald R, Pereira F. Domain Adaptation with Structural Correspondence Learning [C]// Proceedings of 2006 Conference on Empirical Methods in Natural Language Processing. Sydney, Australia: ACL, 2006: 120-128.
- [5] Sinno J P, Ni Xiaochun, Sun Jiantao, et al. Cross-domain Sentiment Classification via Spectral Feature Alignment [C]// Proceedings of the 19th International Conference on World Wide Web. New York, USA: ACM Press, 2010: 751-760.
- [6] 孟佳娜, 段晓东, 杨亮. 基于特征变换的跨领域产品评论倾向性分析 [J]. 计算机工程, 2013, 39(10): 167-171.

(下转第 226 页)

- [5] Udumyan N, Rouchier J, Ami D. Integration of Path-dependency in a Simple Learning Model: The Case of Marine Resources[J]. Computational Economics, 2014, 43(2):199-231.
- [6] Zervas P, Sergis S, Sampson D G, et al. Towards Competence-based Learning Design Driven Remote and Virtual Labs Recommendations for Science Teachers[J]. Technology, Knowledge and Learning, 2015, 20(2):185-199.
- [7] Anderson O R, Love B C, Tsai Meng-jung. Neuroscience Perspectives for Science and Mathematics Learning in Technology-enhanced Learning Environments [J]. International Journal of Science and Mathematics Education, 2014, 12(3):467-474.
- [8] 孙光福, 吴乐, 刘淇, 等. 基于时序行为的协同过滤推荐算法[J]. 软件学报, 2013, 24(11):2721-2733.
- [9] 李忠俊, 周启海, 帅青红. 一种基于内容和协同过滤同构化整合的推荐系统模型[J]. 计算机科学, 2009, 36(12):142-146.
- [10] Saparudin F A, Faisal N, Ghafar A S A. Distributed Resource Allocation for Femtocell Networks: Regret Learning with Proportional Self-belief [J]. Wireless Personal Communications, 2014, 79(1):453-471.
- [11] Campbell T, Longhurst M, Duffy A M. Science Teaching Orientations and Technology-enhanced Tools for Student Learning [J]. Research in Science Education, 2013, 43(5):2035-2057.
- [12] 彭泽环, 孙乐, 韩先培. 基于排序学习的微博用户推荐[J]. 中文信息学报, 2013, 27(4):96-99.
- [13] Cober R, Tan E, Slotta J, et al. Teachers as Participatory Designers: Two Case Studies with Technology-enhanced Learning Environments [J]. Instructional Science, 2015, 43(2):203-228.
- [14] Parreira J X, Castillo C, Donato D, et al. The Juxtaposed Approximate PageRank Method for Robust PageRank Approximation in a Peer-to-Peer Web Search Network [J]. The VLDB Journal, 2008, 17(2):291-313.
- [15] Montefinese M, Zannino G D, Ambrosini E. Semantic Similarity Between Old and New Items Produces False Alarms in Recognition Memory [J]. Psychological Research, 2015, 79(5):785-794.
- [16] 刘志勇, 刘磊, 刘萍萍. 一种基于语义网的个性化学习资源推荐算法[J]. 吉林大学学报(工学版), 2009, 39(2):391-398.
- [17] Lops P, Gemmis M, Semeraro G. Content-based and Collaborative Techniques for Tag Recommendation: An Empirical Evaluation [J]. Journal of Intelligent Information Systems, 2013, 40(1):41-61.
- [18] 朱郁筱, 吕琳媛. 推荐系统评价指标综述[J]. 电子科技大学学报, 2012, 41(2):163-172.

编辑 顾逸斐

(上接第 219 页)

- [7] Zhang Shaowu, Liu Huali, Yang Liang, et al. A Cross-domain Sentiment Classification Method Based on Extraction of Key Sentiment Sentence [C]//Proceedings of the 4th Conference on Natural Language Processing and Chinese Computing. Berlin, Germany: Springer, 2015: 90-101.
- [8] Zhou Guangyou, He Tingting, Wu Wensheng, et al. Linking Heterogeneous Input Features with Pivots for Domain Adaptation [C]//Proceedings of the 24th International Conference on Artificial Intelligence. Georgia, USA: AAAI Press, 2015: 1419-1425.
- [9] Bollegala D, Weir D, Carroll J. Cross-domain Sentiment Classification Using a Sentiment Sensitive Thesaurus [J]. IEEE Transactions on Knowledge and Data Engineering, 2013, 25(8):1719-1731.
- [10] Xia Rui, Zong Chengqing, Hu Xuelei, et al. Feature Ensemble Plus Sample Selection: Domain Adaptation for Sentiment Classification [J]. IEEE Intelligent Systems, 2013, 28(3):10-18.
- [11] Zhang Yuhong, Xu Xu, Hu Xuegang. A Common Subspace Construction Method in Cross-domain Sentiment Classification [C]//Proceedings of International Conference on Electronic Science and Automation Control. [S. l.]: Atlantis Press, 2015: 48-52.
- [12] Zhou Guanyou, Zhou Yin, Guo Xiyue, et al. Cross-domain Sentiment Classification via Topical Correspondence Transfer [J]. Neurocomputing, 2015, 159(1):298-305.
- [13] Bengio Y. Deep Learning of Representations for Unsupervised and Transfer Learning [J]. Unsupervised and Transfer Learning Challenges in Machine Learning, 2012, 7:19-41.
- [14] Glorot X, Bordes A, Bengio Y. Domain Adaptation for Large-scale Sentiment Classification: A Deep Learning Approach [C]//Proceedings of the 28th International Conference on Machine Learning. New York, USA: ACM Press, 2011: 513-520.
- [15] Collobert R, Weston J. A Unified Architecture for Natural Language Processing: Deep Neural Networks with Multitask Learning [C]//Proceedings of the 25th International Conference on Machine Learning. New York, USA: ACM Press, 2008: 160-167.

编辑 刘冰